



Fatores Intracontextuais do Desempenho no IDEB: Segmentação Socioeconômica e Análise Intragrupo nos Municípios do Maranhão

Darlon José Coqueiro

29 de maio de 2026

Resumo

Esta investigação analisa o desempenho educacional no IDEB EFAI 2023 (Índice de Desenvolvimento da Educação Básica, Anos Iniciais do Ensino Fundamental) das escolas da rede municipal, utilizando aprendizado de máquina não supervisionado para identificar padrões associados ao desempenho escolar em contextos de vulnerabilidade socioeconômica. Os dados integram microdados do Censo Escolar 2023 e indicadores socioeconômicos do IBGE (Instituto Brasileiro de Geografia e Estatística) para os 217 municípios do estado com dados disponíveis. A análise é conduzida em dois estágios: segmentação municipal via K-Means sobre renda per capita e IDHM (Índice de Desenvolvimento Humano Municipal), seguida de Random Forest Classifier e testes de Mann-Whitney para identificar os fatores que diferenciam municípios de alto e baixo desempenho dentro de cada grupo. Os resultados identificaram os fatores mais fortemente associados ao desempenho superior. Essas descobertas evidenciam a utilidade do aprendizado não supervisionado para análises educacionais descritivas e oferecem subsídios concretos para políticas educacionais e de alocação de recursos nos municípios. Esta pesquisa contribui para suprir a sub-representação do Maranhão na literatura de mineração de dados educacionais e propõe uma estrutura analítica replicável para outras regiões em desenvolvimento que busquem orientar estratégias de educação pública a partir de dados administrativos.

Palavras-chave: desempenho educacional; IDEB; IDHM; Censo Escolar; municípios maranhenses; aprendizado de máquina não supervisionado; políticas educacionais.

1 Introdução

A qualidade da educação básica é um dos principais determinantes do desenvolvimento humano e econômico de longo prazo (HANUSHEK; WOESSMANN, 2012). No Brasil, o Índice de Desenvolvimento da Educação Básica (IDEB) monitora o ensino público combinando fluxo escolar e proficiência em língua portuguesa e matemática numa medida comparável entre municípios, estados e redes de ensino (FERNANDES, 2007). Apesar dos avanços das últimas duas décadas, as disparidades regionais persistem: estados do Norte e do Nordeste ficam sistematicamente abaixo da média nacional, reflexo de desigualdades estruturais de renda, infraestrutura e serviços públicos (INEP, 2024).

O Maranhão está entre os casos mais críticos. Com um dos menores IDHMs do país e indicadores educacionais historicamente abaixo da média nacional, o estado concentra municípios em alta vulnerabilidade socioeconômica, onde os obstáculos para melhorar o desempenho escolar superam a capacidade de gestão local (IBGE, 2010; INEP, 2024). Isso coloca uma pergunta direta: o que diferencia, dentro de um mesmo patamar de vulnerabilidade, os municípios que sobem no IDEB daqueles que ficam estagnados?

A literatura internacional examinou amplamente a relação entre condições socioeconômicas, infraestrutura escolar, qualificação docente e o desempenho dos estudantes (RIVKIN; HANUSHEK; KAIN, 2005; COLEMAN et al., 1966). No Brasil, estudos com dados do IDEB e do Censo Escolar apontaram formação dos professores, tamanho das turmas e infraestrutura como variáveis relevantes (VASCONCELOS et al., 2021; SOARES; XAVIER, 2013). Análises voltadas especificamente para o Maranhão que isolem fatores intracontextuais (aqueles que operam mesmo quando o contexto socioeconômico é semelhante) são escassas.

Métodos de aprendizado de máquina têm sido aplicados a dados educacionais com resultados promissores, especialmente por sua capacidade de lidar com bases administrativas grandes e heterogêneas (BAKER; YACEF, 2009; ROMERO; VENTURA, 2020). Algoritmos de agrupamento identificam estruturas nos dados sem categorias predefinidas, o que os torna úteis para segmentar contextos antes de comparações (FACELI; LORENA; CARVALHO, 2021). Quando combinados com medidas de importância de variáveis e testes não paramétricos, essa abordagem permite identificar os fatores que mais diferenciam grupos de desempenho.

Este trabalho aplica essa lógica aos 217 municípios maranhenses com dados disponíveis no IDEB 2023 (Anos Iniciais do Ensino Fundamental, rede municipal). No primeiro estágio, os municípios são agrupados por contexto socioeconômico via K-Means, usando renda per capita e IDHM. No segundo, dentro de cada grupo, um Random Forest Classifier combinado com o teste de Mann-Whitney identifica quais características escolares e socioeconômicas separam municípios de alto e baixo desempenho. As variáveis analisadas vêm do Censo Escolar 2023: infraestrutura (internet, biblioteca, laboratório de

informática, saneamento), qualificação docente e indicadores de fluxo escolar.

O trabalho faz três contribuições principais. Primeiro, propõe e aplica ao contexto específico do Maranhão uma abordagem em dois estágios (segmentação socioeconômica seguida de análise intragrupo). Segundo, identifica os fatores escolares associados ao desempenho superior no IDEB entre municípios vulneráveis. Terceiro, disponibiliza um pipeline reprodutível para análises similares em outras unidades federativas. Os resultados têm uso direto para gestores e formuladores de políticas que precisam decidir onde concentrar recursos.

O restante do artigo está organizado da seguinte forma: o Capítulo 2 apresenta os trabalhos relacionados; o Capítulo 3 descreve os materiais e métodos; o Capítulo 4 apresenta os experimentos e resultados; o Capítulo 5 discute conclusões, limitações e direções futuras.

2 Trabalhos Relacionados

2.1 Aprendizado de Máquina na Análise Educacional

A mineração de dados educacionais (*Educational Data Mining*, EDM) consolidou-se como área de pesquisa a partir da segunda metade da década de 2000, quando Baker e Yacef (2009) mapearam o estado da arte e identificaram cinco grandes paradigmas: predição, agrupamento, mineração de regras de associação, descoberta com modelos e visualização. Em revisão atualizada, Romero e Ventura (2020) estenderam esse panorama e evidenciaram a predominância de técnicas supervisionadas para tarefas de classificação, especialmente para prever aprovação, evasão e desempenho em avaliações padronizadas.

No Brasil, a aplicação de algoritmos de aprendizado supervisionado a dados administrativos educacionais ganhou tração com a ampla disponibilização de microdados do INEP. Estudos baseados no Censo Escolar e no IDEB aplicaram técnicas de mineração de dados para identificar fatores associados a desempenho e evasão (COLPANI, 2018). A capacidade dessas técnicas de lidar com bases de alta dimensionalidade e distribuições assimétricas as torna adequadas a dados como os do Censo Escolar, que apresentam essas características.

Apesar dos avanços, a literatura nacional apresenta três lacunas persistentes:

- a) concentração de estudos em municípios das regiões Sul e Sudeste;
- b) uso de modelos globais que ignoram a heterogeneidade socioeconômica entre municípios;
- c) sub-representação de estados como o Maranhão, onde as condições de vulnerabilidade tornam inadequada a comparação direta com médias nacionais.

2.2 Aprendizado Não Supervisionado para Segmentação Contextual

O agrupamento (*clustering*) via K-Means, proposto por MacQueen (1967), é uma das técnicas de aprendizado não supervisionado mais amplamente utilizadas para segmentação de entidades em grupos homogêneos internamente e heterogêneos entre si. O algoritmo minimiza a inércia intragrupo por meio de iterações de atribuição e recentramento, requerendo apenas a especificação prévia do número de grupos k .

A seleção de k é um desafio clássico. O Método do Cotovelo (*Elbow Method*) avalia a variação da inércia, mas pode ser ambíguo em dados reais. O Silhouette Score, introduzido por Rousseeuw (1987), oferece uma métrica mais interpretável: para cada ponto, mede a

razão entre sua coesão intragrupo e sua separação do cluster mais próximo, produzindo um escore entre -1 e 1 (quanto mais alto, mais bem definido o agrupamento).

Em contextos educacionais, o K-Means tem sido empregado para segmentar escolas por perfil socioeconômico antes de comparações de desempenho, o que evita o confundimento entre contexto e eficácia escolar. A visualização dos clusters via Análise de Componentes Principais (ABDI; WILLIAMS, 2010) permite inspecionar graficamente a qualidade da separação em espaço bidimensional, mesmo quando as variáveis originais têm escalas incomparáveis.

A combinação de K-Means para segmentação contextual com testes intragrupo para identificação de fatores discriminantes representa uma abordagem metodológica que preserva a validade interna das comparações: ao comparar municípios dentro do mesmo cluster socioeconômico, reduz-se o risco de atribuir a fatores escolares diferenças que são, na verdade, determinadas pela renda ou pelo nível de desenvolvimento humano.

2.3 Estudos sobre IDEB e Fatores Socioeconômicos no Brasil

O IDEB foi concebido por Fernandes (2007) como uma medida composta que combina taxa de aprovação (fluxo) e proficiência em Língua Portuguesa e Matemática (Saeb/Prova Brasil), resultando em um indicador comparável ao longo do tempo e entre redes de ensino. Soares e Xavier (2013) examinaram os pressupostos estatísticos do índice, alertando para o risco de interpretações simplistas que ignoram a correlação entre fluxo e proficiência.

A relação entre qualificação docente e desempenho escolar é um dos achados mais robustos da literatura internacional. Rivkin, Hanushek e Kain (2005), em análise com dados do Texas, demonstraram que a qualidade do professor é o fator intraescolar com maior impacto sobre o aprendizado dos estudantes, superando infraestrutura e tamanho de turma. O efeito-escola, por sua vez, foi documentado desde o clássico relatório de Coleman et al. (1966), que identificou nos Estados Unidos que o contexto socioeconômico familiar explica a maior parte da variância no desempenho, enquanto fatores escolares têm efeito residual (embora real e acionável por políticas públicas).

Albernaz, Ferreira e Franco (2002) identificaram que qualidade e equidade no Ensino Fundamental variam sistematicamente com o nível socioeconômico das escolas, evidenciando que comparações entre municípios de contextos distintos tendem a confundir efeito-escola com efeito-contexto. No Brasil, Vasconcelos et al. (2021) analisaram a relação entre infraestrutura escolar e desempenho usando dados do Censo Escolar e do Saeb, encontrando associação positiva entre presença de laboratórios, bibliotecas e conexão à internet e os resultados dos estudantes. Em revisão da literatura sobre recursos escolares em países em desenvolvimento, Glewwe et al. (2014) confirmaram que qualidade docente e infraestrutura física têm efeitos positivos, mas heterogêneos, sobre o aprendizado, com magnitude dependente do contexto local. Hanushek e Woessmann (2012) demonstraram,

em perspectiva comparada entre países, que habilidades cognitivas têm efeito causal sobre crescimento econômico de longo prazo, reforçando a relevância de investigar os determinantes do desempenho escolar em estados de baixo IDH como o Maranhão.

O que foi observado é que análises centradas especificamente no Maranhão são escassas. O estado figurou sistematicamente entre os piores índices nacionais no IDEB das séries iniciais (INEP, 2024), com média municipal abaixo de 5,0 na última edição. A concentração de municípios em condições de alta vulnerabilidade socioeconômica torna necessária uma abordagem que controle o contexto antes de comparar desempenhos, o que a literatura geral sobre IDEB raramente faz de forma sistemática.

2.4 Nossa Proposta

O presente trabalho distingue-se da literatura existente por três características:

- a) adota uma abordagem em dois estágios que separa explicitamente a segmentação socioeconômica da análise de fatores intracontextuais;
- b) aplica essa lógica exclusivamente aos 217 municípios maranhenses com dados disponíveis no IDEB 2023, contexto sub-representado na literatura de EDM;
- c) combina importâncias do Random Forest (BREIMAN, 2001) com testes de Mann-Whitney (MANN; WHITNEY, 1947) para obter tanto uma ordenação de variáveis quanto evidência estatística de que as diferenças observadas não são atribuíveis ao acaso.

A análise intragrupo (restrita a municípios com contexto socioeconômico semelhante) responde a uma pergunta que modelos globais não conseguem: quais fatores diferem, de forma consistente e estatisticamente significativa, entre municípios que superam e que ficam abaixo do desempenho esperado dado o seu contexto? Essa pergunta tem implicação direta para políticas educacionais, pois identifica alvos de intervenção que operam mesmo sob restrições socioeconômicas.

3 Materiais e Métodos

3.1 Fontes de Dados

Este estudo integra quatro bases de dados públicas referentes aos municípios do Maranhão:

- **IDEB EFAI 2023 (INEP).** O Índice de Desenvolvimento da Educação Básica dos Anos Iniciais do Ensino Fundamental, divulgado pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP, 2024), é calculado conforme a metodologia proposta por Fernandes (2007): combina a taxa de aprovação escolar (fluxo) com a proficiência média em Língua Portuguesa e Matemática aferida pelo Saeb. Para este estudo, utilizou-se a edição 2023 da rede municipal, que cobriu os 217 (todos) municípios do estado com dados disponíveis.
- **Censo Escolar 2023 (INEP).** Os microdados do Censo Escolar fornecem informações a nível de escola sobre infraestrutura física (internet, biblioteca/sala de leitura, laboratório de informática, quadra esportiva, abastecimento de água e esgotamento sanitário) e sobre o corpo docente. Para as variáveis de formação docente nos Anos Iniciais do Ensino Fundamental, utilizou-se a Tabela 2.23 da Sinopse Estatística do Educacenso 2023, que fornece o número de docentes EFAI por nível de formação de modo consistente entre numerador e denominador, eliminando o viés de dupla contagem presente nos microdados brutos.
- **Censo Demográfico 2010 (IBGE).** A renda per capita municipal de 2010 foi extraída do Censo Demográfico (IBGE, 2010) e utilizada como proxy da capacidade econômica dos municípios. Embora defasada, essa variável é o indicador de renda municipal mais desagregado disponível com cobertura universal para os 217 municípios analisados.
- **IDHM 2010 (Atlas Brasil/PNUD).** O Índice de Desenvolvimento Humano Municipal, calculado pelo PNUD Brasil (Programa das Nações Unidas para o Desenvolvimento) com base no Censo 2010, captura três dimensões do desenvolvimento humano (longevidade, educação e renda) em um índice composto entre 0 e 1. Junto com a renda per capita, compõe o espaço de segmentação socioeconômica utilizado na clusterização.

3.2 Variáveis

As variáveis são organizadas em três grupos, descritos na Tabela 1.

Tabela 1 – Variáveis utilizadas na análise

Variável	Fonte	Definição operacional
<i>Segmentação socioeconômica</i>		
Renda per capita 2010	IBGE 2010	Renda domiciliar per capita média municipal (R\$)
IDHM 2010	PNUD/Atlas	Índice de Desenvolvimento Humano Municipal
<i>Infraestrutura escolar</i>		
% escolas com internet	Censo 2023	Proporção de escolas municipais com acesso à internet
% escolas com biblioteca/sala de leitura	Censo 2023	Proporção com biblioteca, biblioteca-sala de leitura ou sala de leitura
% escolas com laboratório de informática	Censo 2023	Proporção com laboratório de informática
% escolas com quadra esportiva	Censo 2023	Proporção com quadra de esportes
% escolas com água adequada	Censo 2023	Proporção com água potável ou rede pública
% escolas com esgoto adequado	Censo 2023	Proporção com rede pública ou fossa séptica
<i>Qualificação docente</i>		
% docentes EFAI com ensino superior	Sinopse 2023	Proporção de docentes dos Anos Iniciais com graduação
% docentes EFAI com licenciatura	Sinopse 2023	Proporção de docentes dos Anos Iniciais com licenciatura
<i>Fluxo e distorção</i>		
Média de alunos/turma (EF)	Censo 2023	Total de matrículas no EF dividido pelo total de turmas EF
Proxy distorção idade-série	Censo 2023	% matrículas com 15 anos ou mais na educação básica municipal

3.3 Metodologia

O pipeline analítico segue as etapas do processo CRISP-DM (*Cross-Industry Standard Process for Data Mining*) (SHEARER, 2000), adaptado ao contexto de análise de dados educacionais: compreensão do domínio, coleta e preparação dos dados, modelagem e avaliação dos resultados. Dentro desse processo, a análise é conduzida em dois estágios sequenciais, conforme descrito a seguir.

3.3.1 Estágio 1: Segmentação Socioeconômica por K-Means

O K-Means (MACQUEEN, 1967) agrupa os 217 municípios com base em renda per capita e IDHM. Antes da clusterização, as duas variáveis são normalizadas via `RobustScaler`, que centraliza na mediana e escala pelo intervalo interquartil, reduzindo a influência de municípios atípicos (como São Luís e Imperatriz).

O número de clusters k é selecionado pela inspeção conjunta do Método do Cotovelo, que avalia a inércia total em função de k , e do Silhouette Score médio (ROUSSEEUV, 1987), que mede a separação relativa dos grupos. O algoritmo é executado com $k \in \{2, \dots, 10\}$, inicialização `k-means++` e `n_init = 10`. A estabilidade dos clusters é avaliada por bootstrap de 25 iterações com 80% dos dados, seguindo a configuração de referência de Ben-Hur, Elisseeff e Guyon (2002), usando o Adjusted Rand Index (ARI) como métrica de concordância.

A visualização dos clusters é feita via Análise de Componentes Principais (ABDI; WILLIAMS, 2010) com duas componentes, permitindo inspeção gráfica da separação em espaço reduzido.

3.3.2 Estágio 2: Análise Intragrupo

Dentro de cada cluster com amostra suficiente, os municípios são divididos em dois grupos por desempenho: *alto IDEB*, formado pelo quartil superior ($\geq Q_{75}$), e *baixo IDEB*, formado pelo quartil inferior ($\leq Q_{25}$). Os municípios do intervalo central são excluídos da análise comparativa, o que aumenta o contraste entre os grupos e reduz o ruído.

Para identificar quais variáveis diferenciam os dois grupos, aplica-se um Random Forest Classifier (BREIMAN, 2001) com 500 árvores, `class_weight='balanced'` e `min_samples_leaf=3`. A importância de cada variável é calculada pelo critério de redução média de impureza (*Mean Decrease in Impurity*), que quantifica a contribuição de cada variável para separar os dois grupos ao longo das 500 árvores. Em paralelo, o teste de Mann-Whitney (MANN; WHITNEY, 1947) bicaudal verifica se as distribuições das variáveis diferem significativamente entre os grupos alto e baixo IDEB. São utilizados três limiares de significância: $\alpha = 0,01$ (***), $\alpha = 0,05$ (**) e $\alpha = 0,10$ (*).

A combinação de importâncias do Random Forest com os p-valores do Mann-Whitney permite distinguir variáveis com alta relevância preditiva daquelas com diferença estatisticamente sustentada: uma variável é considerada fator discriminante relevante quando apresenta alta importância e diferença significativa ao nível de $\alpha = 0,10$.

3.4 Uso de Ferramentas de Inteligência Artificial Generativa

Este trabalho utilizou ferramentas de inteligência artificial generativa em três etapas do processo de pesquisa:

- **Revisão de código.** A primeira etapa do trabalho é toda relacionada às fases de ciências de dados com Python. Foi utilizada a ferramenta Claude (Anthropic) para correção e revisão dos scripts Python do pipeline de análise (`ingest.py`, `transform.py` e os módulos de modelagem), com validação e aprovação do autor em cada alteração sugerida.
- **Revisão e edição de texto.** Na fase da produção escrita deste artigo, o Claude (Anthropic) e ChatGPT (OpenAI) foram utilizados para revisar a redação e a clareza das seções do artigo. O texto original, a estrutura argumentativa e as interpretações dos resultados são de autoria exclusiva do autor.
- **Busca e validação de referências bibliográficas.** Claude (Anthropic) e SciSpace AI Research (PubGenius Inc.) foram utilizados para identificar trabalhos potencialmente relevantes e verificar metadados de citações. Cada referência foi checada pelo autor nas fontes originais antes da inclusão.

O uso dessas ferramentas está declarado em conformidade com as diretrizes de integridade científica do CNPq, que exigem a identificação explícita das ferramentas de inteligência artificial generativa utilizadas, suas finalidades e a responsabilização integral do pesquisador pelos resultados produzidos.

4 Experimentos Computacionais

4.1 Compreensão do Domínio

O Maranhão é o segundo maior estado do Nordeste em extensão territorial e um dos mais populosos, com 217 municípios distribuídos em cinco mesorregiões. Em indicadores socioeconômicos, ocupa posições críticas: IDHM médio de 0,639 em 2010 (um dos mais baixos do país) e renda per capita municipal mediana em torno de R\$ 200 no mesmo período (IBGE, 2010). Esse contexto reflete-se diretamente nos resultados educacionais: na edição 2023 do IDEB, a média dos municípios maranhenses nos Anos Iniciais da rede municipal ficou em 5,01, com metade dos municípios abaixo de 4,90, valores que evidenciam tanto o atraso histórico quanto a dispersão expressiva do desempenho entre municípios.

A questão central desta investigação é identificar, entre municípios com contexto socioeconômico semelhante, quais fatores escolares estão associados ao desempenho superior no IDEB. Respondê-la exige, primeiro, neutralizar o efeito do contexto por meio de uma segmentação explícita e, depois, comparar, dentro de cada grupo, os municípios de alto e baixo desempenho.

4.2 Coleta de Dados

O pipeline de ingestão (`ingest.py`) automatiza a carga das quatro fontes descritas no Capítulo 3. Para o IDEB, lê a planilha oficial do INEP e filtra os municípios maranhenses da rede municipal, tratando os códigos de não divulgação (ND, ND*, (*), (**)) como valores ausentes. Para o Censo Escolar, carrega os microdados em formato CSV (*encoding* latin-1, separador ponto-e-vírgula) e seleciona as colunas de infraestrutura, docentes e matrículas, filtrando as escolas de dependência municipal no Maranhão (`TP_DEPENDENCIA = 3`). Para os docentes dos Anos Iniciais, usa exclusivamente a Tabela 2.23 da Sinopse Estatística 2023 (formato ODS), garantindo que numerador (docentes com superior) e denominador (total de docentes EFAI) venham da mesma fonte. O IBGE e o IDHM são lidos de planilhas Excel curadas previamente.

As variáveis de infraestrutura são agregadas ao nível municipal como proporção de escolas com cada atributo presente. As variáveis de docentes, como percentual sobre o total de docentes EFAI do município. As variáveis de fluxo, como médias ou proporções sobre o total de matrículas e turmas municipais.

4.3 Pré-processamento

O pipeline de transformação (`transform.py`) aplica as seguintes operações:

- **IDEB:** substituição de valores especiais por NaN, conversão de vírgula para ponto decimal, remoção de colunas redundantes (notas separadas de LP e MAT, já incorporadas na nota média).
- **Censo Escolar:** remoção de colunas completamente vazias, conversão de colunas de quantidade para inteiro, normalização do código municipal para 7 dígitos.
- **IBGE:** remoção de linhas de totalização regional, normalização de nome de colunas.
- **IDHM:** remoção de linhas de totalização, renomeação de colunas para padrão interno.
- **Merge:** integração das quatro bases pela chave NO_MUNICIPIO (normalizada), com junção à esquerda a partir do IDEB. Resultado: 217 municípios com dados completos de IDEB, Censo, IBGE e IDHM.

Após o merge, não há valores ausentes nas variáveis de cluster nem nas variáveis-alvo (IDEB), mas algumas variáveis explicativas apresentam missings pontuais decorrentes de municípios sem turmas de correção de fluxo (alunos com atraso no que se espera de idade/série).

4.4 Análise Exploratória

A distribuição do IDEB dos 217 municípios maranhenses é apresentada na Figura 1. A distribuição é aproximadamente unimodal, ligeiramente assimétrica à direita, com média de 5,01 ($dp = 0,59$), mediana de 4,90, mínimo de 4,00 e máximo de 7,30.




Figura 1 – Distribuição do IDEB 2023, municípios maranhenses, rede municipal, Anos Iniciais do EF. Linha vermelha tracejada: média (5,01); linha laranja tracejada: mediana (4,90); faixa vermelha: intervalo ± 1 desvio-padrão.

A amplitude de 3,30 pontos (4,00 a 7,30) é expressiva dado que o IDEB varia de 0 a 10. Isso indica que, mesmo dentro do Maranhão (estado homogeneamente vulnerável em termos nacionais) existe variabilidade interna substancial que justifica investigar os fatores associados aos destaques positivos.

4.5 Modelagem

A clusterização K-Means foi aplicada sobre as variáveis *renda per capita* e *IDHM* (normalizadas via RobustScaler), testando $k \in \{2, \dots, 10\}$ conforme detalhado na Seção 3.

4.5.1 Seleção do Número de Clusters

A Figura 2 apresenta as curvas de inércia (cotovelo) e Silhouette Score para $k \in \{2, \dots, 10\}$. O Silhouette Score atinge seu valor máximo em $k = 2$ (0,619), indicando dois grupos bem separados na relação *renda*/*IDHM*. O Método do Cotovelo confirma a escolha: a queda marginal de inércia entre $k = 2$ e $k = 3$ é consideravelmente menor que entre $k = 1$ e $k = 2$. A estabilidade bootstrap (ARI médio = 0,89 em 25 iterações) confirma que a partição é robusta.




Figura 2 – Curvas de inércia (esquerda) e Silhouette Score (direita) para $k \in \{2, \dots, 10\}$. A linha vertical vermelha indica o k ótimo segundo o silhouette.

4.5.2 Estrutura dos Clusters

A Figura 3 exibe os clusters projetados nas duas primeiras componentes principais (PC1 explica 88,4% da variância; PC2 explica 11,6%). A separação visual entre os dois grupos é clara, confirmando a coerência da partição.




Figura 3 – Visualização PCA dos clusters de municípios maranhenses para $k \in \{2, 3, 4\}$. A separação em dois grupos é a mais nítida.

Os dois clusters obtidos são denominados pelo critério de renda média:

- **Cluster vulnerável** ($n = 197$): renda per capita média de R\$ 210, IDHM médio de 0,737, IDEB médio de 4,96.
- **Cluster maior renda** ($n = 20$): renda per capita média de R\$ 447, IDHM médio de 0,780, IDEB médio de 5,45. Inclui municípios como Açailândia, Balsas, Bacabal e Alto Parnaíba.

O cluster de maior renda conta com apenas 20 municípios, número insuficiente para a análise intragrupo por quantis (que requereria ao menos 20 observações em cada subgrupo extremo). A análise comparativa detalhada é portanto conduzida exclusivamente no cluster vulnerável.

Os percentuais médios das variáveis de infraestrutura revelam disparidades: a *conectividade à internet* está presente em 73,7% das escolas municipais do cluster vulnerável e em 81,9% das escolas do cluster de maior renda; já o acesso a *biblioteca ou sala de leitura* é notavelmente baixo em ambos os grupos (12,5% nas escolas vulneráveis), sugerindo que esse recurso pode ser um diferencial relevante justamente por sua raridade. A proporção média de *docentes EFAI com ensino superior* é de 60,5% nos municípios mais vulneráveis e de 73,9% naqueles de maior renda, diferença que antecipa uma das hipóteses testadas no estágio intragrupo.

4.6 Resultados e Discussão

4.6.1 Fatores Discriminantes no Cluster Vulnerável

Dentro do cluster vulnerável ($n = 197$), os 57 municípios que se encontram no quartil superior de IDEB (alto, $\geq 5,20$, média 5,65) são comparados aos 50 do quartil inferior (baixo, $\leq 4,50$, média 4,35). A diferença média de 1,30 ponto de IDEB entre os grupos é substancial: equivale a mais de dois desvios-padrão da distribuição estadual.

A Figura 4 apresenta as importâncias do Random Forest Classifier para o cluster vulnerável. As oito variáveis de maior importância são, em ordem decrescente: *renda per capita* (0,121), *média de alunos por turma no EF básico* (0,098), *% escolas com biblioteca/sala de leitura* (0,096), *% docentes com ensino superior* (0,093), *proxy de distorção idade-série* (0,090), *% docentes com licenciatura* (0,087), *média de alunos por turma no EF anos finais* (0,074) e *% escolas com esgoto adequado* (0,073).




Figura 4 – Importâncias do Random Forest Classifier para diferenciar municípios de alto e baixo IDEB no cluster vulnerável.

O Teste de Mann-Whitney complementa a análise ao indicar quais variáveis apresentam diferenças estatisticamente significativas entre os grupos. A Tabela 2 resume os resultados para as variáveis com $p < 0,10$.

Tabela 2 – Variáveis com diferença significativa entre municípios de alto e baixo IDEB, Cluster vulnerável (Mann-Whitney bicaudal)

Variável	Média alto	Média baixo	Δ	p-valor
% doc. com licenciatura	68,0%	59,4%	+8,6 p.p.	0,023**
% doc. com ensino superior	66,8%	58,5%	+8,3 p.p.	0,026**
% escolas com biblioteca	13,8%	10,5%	+3,3 p.p.	0,030**
% escolas com internet	77,1%	69,5%	+7,6 p.p.	0,062*
Alunos/turma EF (média)	22,9	21,9	+1,0	0,066*

Sig.: ** $p < 0,05$; * $p < 0,10$.

A formação docente emerge como o fator intracontextual mais consistentemente associado ao desempenho superior: municípios vulneráveis de alto IDEB têm, em média, 8,5 p.p. a mais de *docentes com ensino superior* e 8,6 p.p. a mais com *licenciatura* em comparação aos de baixo IDEB. Esse achado é convergente com a literatura internacional.

Rivkin, Hanushek e Kain (2005) demonstraram que a qualidade do professor é o fator intraescolar de maior impacto sobre o aprendizado. Estudos nacionais também apontam formação docente como variável central nos resultados do IDEB (VASCONCELOS et al., 2021).

O acesso a *biblioteca ou sala de leitura*, ainda que presente em apenas 10–14% das escolas, também aparece como fator discriminante ($p = 0,030$). Sua raridade torna essa variável um alvo direto de intervenção: pequenas expansões na proporção de escolas com espaços de leitura estruturados podem fazer diferença mensurável no IDEB municipal.

A *conectividade à internet* ($p = 0,062$) e o *tamanho médio de turma* ($p = 0,066$) são significativos ao nível de 10%, sinalizando tendências relevantes para políticas, embora com menor robustez estatística dada a variabilidade intragrupo.

A *renda per capita* aparece com a maior importância no Random Forest (0,121) mesmo dentro do cluster vulnerável, onde a variação de renda é estruturalmente menor. Isso sugere que, mesmo após a segmentação socioeconômica, a heterogeneidade residual de renda dentro do grupo tem poder preditivo, o que reforça a importância de controles socioeconômicos em análises educacionais, mesmo dentro de grupos nominalmente homogêneos.

4.7 Implicações Práticas

Os resultados têm implicações diretas para gestores municipais e formuladores de políticas educacionais do Maranhão. Três direções de ação emergem dos achados:

- **Formação e habilitação docente.** A diferença de 8,5 p.p. na proporção de *docentes com ensino superior* entre municípios de alto e baixo IDEB, dentro do mesmo contexto socioeconômico, indica que programas de formação continuada e de indução à licenciatura específica têm potencial de impacto real sobre o IDEB. Políticas estaduais e federais de financiamento de graduação a distância para docentes em exercício (como o Programa Nacional de Formação de Professores da Educação Básica — Parfor) são alvos naturais de expansão nos municípios do cluster vulnerável.
- **Espaços de leitura nas escolas.** A escassez de *bibliotecas e salas de leitura* (presentes em apenas 10–14% das escolas) e sua associação significativa com desempenho superior sugerem que investimentos relativamente modestos em acervo e espaço físico podem ser custo-efetivos. Municípios com IDEB baixo dentro do cluster vulnerável têm, em média, 3,3 p.p. menos escolas com esse recurso.
- **Conectividade digital.** A diferença de 7,6 p.p. na proporção de *escolas com internet* aponta para o efeito mediado da conectividade sobre o IDEB: embora o impacto seja apenas marginalmente significativo ($p = 0,062$), a convergência com a importância no Random Forest justifica o monitoramento desse indicador como parte de estratégias de melhoria educacional.

5 Conclusões

5.1 Comparação com a Literatura sobre IDEB

Este trabalho propôs e aplicou uma abordagem em dois estágios (segmentação socioeconômica por K-Means seguida de análise intragrupo com Random Forest Classifier e teste de Mann-Whitney) aos 217 municípios maranhenses com dados no IDEB 2023 (Anos Iniciais, rede municipal). Os resultados identificaram *formação docente*, *acesso a bibliotecas* e *conectividade à internet* como os fatores intracontextuais mais consistentemente associados ao desempenho superior dentro do grupo de municípios vulneráveis.

Esses achados dialogam com a literatura de maneiras específicas. A centralidade da qualificação docente confirma o achado seminal de Rivkin, Hanushek e Kain (2005) no contexto norte-americano e é convergente com estudos brasileiros que identificaram formação superior como fator associado ao IDEB (VASCONCELOS et al., 2021). A relevância da infraestrutura de leitura reforça a tese de Coleman et al. (1966) de que recursos escolares têm efeito real, embora secundário ao contexto familiar, o que, no caso de municípios igualmente vulneráveis, pode ganhar destaque justamente porque o efeito do contexto é controlado.

Em relação à literatura de mineração de dados educacionais, o trabalho contribui com uma aplicação metodológica que supera duas limitações frequentes: o uso de modelos globais que ignoram a heterogeneidade socioeconômica entre municípios e a concentração de estudos EDM nas regiões Sul e Sudeste (BAKER; YACEF, 2009; ROMERO; VENTURA, 2020). A abordagem em dois estágios é replicável para outros estados e pode ser adaptada a outros níveis de ensino (Anos Finais, Ensino Médio) ou outras medidas de desempenho.

Quanto ao IDEB como métrica, os pressupostos estatísticos identificados por Soares e Xavier (2013) (especialmente a correlação entre fluxo e proficiência) não invalidam a análise, mas sugerem cautela na interpretação: municípios com IDEB elevado podem estar priorizando aprovação em detrimento da proficiência. A combinação de variáveis de fluxo (*distorção idade-série*, *correção de fluxo*) com os indicadores estruturais na mesma análise ajuda a mitigar parcialmente esse risco.

5.2 Limitações e Direções Futuras

Este estudo apresenta quatro limitações relevantes que devem ser consideradas na interpretação dos resultados.

- **Defasagem dos dados socioeconômicos.** A *renda per capita* e o IDHM utilizados são provenientes do Censo Demográfico de 2010, com 14 anos de defasagem em

relação ao IDEB 2023. Mudanças na estrutura econômica e social dos municípios nesse período (como a expansão de programas de transferência de renda e variações na atividade econômica regional) podem não estar refletidas na segmentação. A atualização com os dados do Censo Demográfico 2022 (IBGE) e do IDHM 2022 (PNUD), quando disponíveis, é a principal direção de melhoria metodológica.

- **Tamanho do cluster de maior renda.** O cluster composto por 20 municípios de maior renda não atingiu o número mínimo de amostras para a análise intragrupo por quartis, impedindo a identificação de fatores discriminantes nesse grupo. Uma possível solução é adotar um limiar de corte mais amplo (por exemplo, tercis em vez de quartis) ou combinar esse cluster com dados de outros estados nordestinos para ampliar a amostra.
- **Causalidade.** A análise é descritiva e associativa, não causal. Não é possível afirmar que *formação docente* ou *infraestrutura escolar* causam IDEB mais alto. Municípios com gestão mais eficaz tendem a contratar mais docentes qualificados e a obter melhores resultados ao mesmo tempo, tornando difícil separar o efeito de cada variável do efeito da qualidade de gestão municipal. Estudos de painel com variação longitudinal do IDEB (2019–2023) permitiriam estimativas mais robustas do efeito causal.
- **Variáveis de gestão escolar ausentes.** O Censo Escolar não captura variáveis de processos pedagógicos, gestão, clima escolar ou engajamento familiar, que a literatura aponta como mediadores importantes do desempenho. A inclusão de dados de avaliações de escola (como o SPAECE ou avaliações próprias do estado) em pesquisas futuras poderia complementar o diagnóstico aqui apresentado.

As direções futuras prioritárias são:

- a) replicar a análise com os dados socioeconômicos do Censo 2022 assim que disponibilizados;
- b) expandir o estudo para outros estados do Nordeste, permitindo comparações e identificação de padrões regionais;
- c) desenvolver análise longitudinal com os ciclos do IDEB de 2017 a 2023 para verificar se os fatores aqui identificados apresentam efeito consistente ao longo do tempo;
- d) integrar dados de formação continuada de professores (PARFOR ou UAB — Universidade Aberta do Brasil) ao modelo para testar se o investimento em capacitação docente precede a melhora do IDEB.

5.3 Agradecimentos

O autor agradece ao Programa de Pós-Graduação em Computação Aplicada (PPGCA) do Instituto Federal de Educação, Ciência e Tecnologia do Maranhão (IFMA) pelo suporte institucional. Os dados utilizados neste trabalho são de acesso público e foram disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP/MEC) e pelo Instituto Brasileiro de Geografia e Estatística (IBGE). Os resultados e interpretações são de responsabilidade exclusiva do autor e não representam posição oficial dessas instituições.

Declaração de uso de inteligência artificial generativa. Ferramentas de inteligência artificial generativa foram utilizadas durante a produção deste trabalho, conforme detalhado na Seção 3.4: Claude (Anthropic) e ChatGPT (OpenAI) para revisão de texto e de código; Claude (Anthropic) e SciSpace AI Research (PubGenius Inc.) para busca e validação de referências bibliográficas. O autor revisou e aprova integralmente o conteúdo final, assumindo responsabilidade por quaisquer imprecisões.

5.4 Contribuições dos Autores (CRediT)

Darlon José Coqueiro: Conceituação (*Conceptualization*); Metodologia (*Methodology*); Software (*Software*); Análise formal (*Formal analysis*); Curadoria de dados (*Data curation*); Redação: rascunho original (*Writing — original draft*); Redação: revisão e edição (*Writing — review & editing*); Visualização (*Visualization*).

Referências

- ABDI, H.; WILLIAMS, L. J. Principal component analysis. *WIREs Computational Statistics*, v. 2, n. 4, p. 433–459, 2010. Disponível em: <<https://doi.org/10.1002/wics.101>>. Acesso em: 25 maio 2026.
- ALBERNAZ, Â.; FERREIRA, F. H. G.; FRANCO, C. Qualidade e equidade no ensino fundamental brasileiro. *Pesquisa e Planejamento Econômico*, v. 32, n. 3, p. 453–476, 2002. Disponível em: <<https://ppe.ipea.gov.br/index.php/ppe/article/view/139>>. Acesso em: 23 maio 2026.
- BAKER, R. S. J. D.; YACEF, K. The state of educational data mining in 2009: A review and future visions. *Journal of Educational Data Mining*, v. 1, n. 1, p. 3–16, 2009. Disponível em: <<https://jedm.educationaldatamining.org/index.php/JEDM/article/view/8>>. Acesso em: 23 maio 2026.
- BEN-HUR, A.; ELISSEEFF, A.; GUYON, I. A stability based method for discovering structure in clustered data. In: *Pacific Symposium on Biocomputing*. [s.n.], 2002. v. 7, p. 6–17. Disponível em: <<https://psb.stanford.edu/psb-online/proceedings/psb02/benhur.pdf>>. Acesso em: 29 maio 2026.
- BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001. Disponível em: <<https://link.springer.com/article/10.1023/A:1010933404324>>. Acesso em: 25 maio 2026.
- COLEMAN, J. S. et al. *Equality of Educational Opportunity*. Washington, D.C.: U.S. Government Printing Office, 1966. Disponível em: <https://archive.org/details/equalityofeducat0000cole_a0h5>. Acesso em: 23 maio 2026.
- COLPANI, R. Mineração de dados educacionais: um estudo da evasão no ensino médio com base nos indicadores do Censo Escolar. *Informática na Educação: Teoria & Prática*, v. 21, n. 3, 2018. Disponível em: <<https://seer.ufrgs.br/InfEducTeoriaPratica/article/view/87880>>. Acesso em: 27 maio 2026.
- FACELI, K.; LORENA, A. C.; CARVALHO, A. C. P. d. L. F. d. *Inteligência Artificial: uma abordagem de aprendizado de máquina*. 2. ed. Rio de Janeiro: LTC, 2021. 424 p. ISBN 9788521637349.
- FERNANDES, R. *Índice de Desenvolvimento da Educação Básica (IDEB)*. Brasília, 2007. Disponível em: <<https://rbep.inep.gov.br/ojs3/index.php/td/article/view/3850>>. Acesso em: 23 maio 2026.
- GLEWWE, P. W. et al. School resources and educational outcomes in developing countries: A review of the literature from 1990 to 2010. *Education Policy in Developing Countries*, University of Chicago Press, p. 13–64, 2014. Disponível em: <<https://www.nber.org/papers/w17554>>. Acesso em: 23 maio 2026.
- HANUSHEK, E. A.; WOESSMANN, L. Do better schools lead to more growth? Cognitive skills, economic outcomes, and causation. *Journal of Economic Growth*, v. 17, n. 4, p. 267–321, 2012. Disponível em: <<https://link.springer.com/article/10.1007/s10887-012-9081-x>>. Acesso em: 23 maio 2026.

IBGE. *Censo Demográfico 2010*. Rio de Janeiro: IBGE, 2010. Disponível em: <<https://www.ibge.gov.br/estatisticas/sociais/saude/9662-censo-demografico-2010.html>>. Acesso em: 23 maio 2026.

INEP. *Nota Informativa: IDEB 2023*. Brasília, 2024. Disponível em: <https://download.inep.gov.br/ideb/nota_informativa_ideb_2023.pdf>. Acesso em: 23 maio 2026.

MACQUEEN, J. B. Some methods for classification and analysis of multivariate observations. In: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Berkeley, CA: University of California Press, 1967. v. 1, p. 281–297. Disponível em: <<https://projecteuclid.org/euclid.bsmmsp/1200512992>>. Acesso em: 25 maio 2026.

MANN, H. B.; WHITNEY, D. R. On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, v. 18, n. 1, p. 50–60, 1947. Disponível em: <<https://projecteuclid.org/euclid.aoms/1177730491>>. Acesso em: 25 maio 2026.

RIVKIN, S. G.; HANUSHEK, E. A.; KAIN, J. F. Teachers, schools, and academic achievement. *Econometrica*, v. 73, n. 2, p. 417–458, 2005. Disponível em: <<https://www.nber.org/papers/w6691>>. Acesso em: 23 maio 2026.

ROMERO, C.; VENTURA, S. Educational data mining and learning analytics: An updated survey. *WIREs Data Mining and Knowledge Discovery*, v. 10, n. 3, p. e1355, 2020. Disponível em: <<https://doi.org/10.1002/widm.1355>>. Acesso em: 23 maio 2026.

ROUSSEEUW, P. J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53–65, 1987. Disponível em: <<https://www.sciencedirect.com/science/article/pii/0377042787901257>>. Acesso em: 25 maio 2026.

SHEARER, C. The CRISP-DM model: The new blueprint for data mining. *Journal of Data Warehousing*, v. 5, n. 4, p. 13–22, 2000. Disponível em: <<https://mineracaodedados.wordpress.com/wp-content/uploads/2012/04/the-crisp-dm-model-the-new-blueprint-for-data-mining-shearer-colin.pdf>>. Acesso em: 29 maio 2026.

SOARES, J. F.; XAVIER, F. P. Pressupostos educacionais e estatísticos do IDEB. *Educação & Sociedade*, v. 34, n. 124, p. 903–923, 2013. Disponível em: <<https://www.scielo.br/j/es/a/JLzr4qdx89rjrNXnydNcvcy/>>. Acesso em: 25 maio 2026.

VASCONCELOS, J. C. et al. Infraestrutura escolar e investimentos públicos em Educação no Brasil: a importância para o desempenho educacional. *Ensaio: Avaliação e Políticas Públicas em Educação*, v. 29, n. 113, p. 874–898, 2021. Disponível em: <<https://www.scielo.br/j/ensaio/a/w9HwRXMQ3FVZ9fzJJKBgLLt/>>. Acesso em: 23 maio 2026.