DEBATES EM EDUCAÇÃO
ISSN: 2175-6600

Artigo | Article

Fatores intracontextuais do desempenho no IDEB: segmentação socioeconômica e análise intragrupo nos municípios do Maranhão

Intracontextual factors of IDEB performance: socioeconomic segmentation and within-group analysis in the municipalities of Maranhão

Factores intracontextuales del desempeño en el IDEB: segmentación socioeconómica y análisis intragrupo en los municipios de Maranhão

Resumo

O desempenho educacional dos municípios maranhenses permanece entre os mais baixos do país, e a desigualdade socioeconômica dificulta comparações diretas entre redes de ensino. Este artigo tem como objetivo identificar os fatores escolares que diferenciam municípios de alto e de baixo desempenho no Índice de Desenvolvimento da Educação Básica de 2025, nos anos iniciais do ensino fundamental da rede municipal, entre municípios de contexto socioeconômico semelhante. A pesquisa, de natureza quantitativa e descritiva, integra microdados do Censo Escolar de 2025, a renda *per capita* municipal do Censo Demográfico de 2022 e o Índice de Desenvolvimento Humano Municipal calculado a partir do Censo de 2010 para os 217 municípios do Maranhão. A análise ocorre em dois estágios: primeiro, o algoritmo *K-Means* agrupa os municípios segundo a renda *per capita* e o desenvolvimento humano; depois, dentro de cada grupo, um classificador *Random Forest* e o teste de Mann-Whitney comparam os municípios do quartil superior e do quartil inferior de desempenho. No grupo mais vulnerável, a formação docente em nível superior e em licenciatura é o fator mais associado ao desempenho superior. No grupo de maior renda, destacam-se o tamanho de turma, a renda *per capita* e a quadra esportiva. Conclui-se que o aprendizado de máquina aplicado a dados administrativos públicos oferece subsídios para a formulação de políticas educacionais e para a alocação de recursos nos municípios, além de constituir uma estrutura analítica replicável em outras regiões.

Palavras-chave: desempenho educacional; aprendizado de máquina; políticas educacionais.

Abstract

The educational performance of municipalities in Maranhão remains among the lowest in Brazil, and socioeconomic inequality hinders direct comparisons between school systems. This article aims to identify the school factors that distinguish high- and low-performing municipalities in the 2025 Basic Education Development Index, in the early years of elementary education in municipal schools, among municipalities with similar socioeconomic contexts. The study, quantitative and descriptive in nature, integrates

https://doi.org/10.28998/2175-6600.2025v17n39
Artigo publicado sob a Licença Creative Commons 4.0

Submetido em: dd/mm/aaaa
Aceito em: dd/mm/aaaa
Publicado: dd/mm/aaaa
e-Location: xxxxxxx

microdata from the 2025 School Census, municipal per capita income from the 2022 Demographic Census, and the Municipal Human Development Index calculated from the 2010 Census, for the 217 municipalities of Maranhão. The analysis is carried out in two stages: first, the K-Means algorithm groups municipalities according to per capita income and human development; then, within each group, a Random Forest classifier and the Mann-Whitney test compare municipalities in the upper and lower performance quartiles. In the most vulnerable group, teacher education at the higher education and teaching degree levels is the factor most associated with higher performance. In the higher-income group, class size, per capita income, and the presence of sports courts stand out. It is concluded that machine learning applied to public administrative data provides support for the design of educational policies and for resource allocation in municipalities, in addition to constituting an analytical framework replicable in other regions.

Keywords: *educational performance; machine learning; educational policies.*

Resumen

El desempeño educativo de los municipios de Maranhão sigue entre los más bajos de Brasil, y la desigualdad socioeconómica dificulta las comparaciones directas entre redes de enseñanza. Este artículo tiene como objetivo identificar los factores escolares que diferencian a los municipios de alto y de bajo desempeño en el Índice de Desarrollo de la Educación Básica de 2025, en los años iniciales de la enseñanza fundamental de la red municipal, entre municipios de contexto socioeconómico similar. La investigación, de naturaleza cuantitativa y descriptiva, integra microdatos del Censo Escolar de 2025, la renta per cápita municipal del Censo Demográfico de 2022 y el Índice de Desarrollo Humano Municipal calculado a partir del Censo de 2010, para los 217 municipios de Maranhão. El análisis se realiza en dos etapas: primero, el algoritmo K-Means agrupa los municipios según la renta per cápita y el desarrollo humano; después, dentro de cada grupo, un clasificador Random Forest y la prueba de Mann-Whitney comparan los municipios del cuartil superior y del cuartil inferior de desempeño. En el grupo más vulnerable, la formación docente superior y en licenciatura es el factor más asociado al desempeño superior. En el grupo de mayor renta, destacan el tamaño de clase, la renta per cápita y la cancha deportiva. Se concluye que el aprendizaje automático aplicado a datos administrativos públicos ofrece subsidios para la formulación de políticas educativas y para la asignación de recursos en los municipios, además de constituir un marco analítico replicable en otras regiones.

Palabras-clave: *desempeño educativo; aprendizaje automático; políticas educativas.*

INTRODUÇÃO

A qualidade da educação básica é um dos principais determinantes do desenvolvimento humano e econômico de longo prazo (Hanushek; Woessmann, 2012). No Brasil, o Índice de Desenvolvimento da Educação Básica (IDEB) monitora o ensino pú-

blico combinando fluxo escolar e proficiência em língua portuguesa e matemática numa medida comparável entre municípios, estados e redes de ensino (Fernandes, 2007). Apesar dos avanços das últimas duas décadas, as disparidades regionais persistem: estados do Norte e do Nordeste ficam sistematicamente abaixo da média nacional, reflexo de desigualdades estruturais de renda, infraestrutura e serviços públicos (INEP, 2026b).

O Maranhão está entre os casos mais críticos. Com um dos menores Índices de Desenvolvimento Humano Municipal (IDHM) do país e indicadores educacionais historicamente abaixo da média nacional, o estado concentra municípios em alta vulnerabilidade socioeconômica, onde os obstáculos para melhorar o desempenho escolar superam a capacidade de gestão local (IBGE, 2010; INEP, 2026b). Isso coloca uma pergunta direta: o que diferencia, dentro de um mesmo patamar de vulnerabilidade, os municípios que sobem no IDEB daqueles que ficam estagnados?

A literatura internacional examinou amplamente a relação entre condições socioeconômicas, infraestrutura escolar, qualificação docente e o desempenho dos estudantes (Rivkin; Hanushek; Kain, 2005; Coleman et al., 1966). No Brasil, estudos com dados do IDEB e do Censo Escolar apontaram formação dos professores, tamanho das turmas e infraestrutura como variáveis relevantes (Vasconcelos et al., 2021; Soares; Xavier, 2013). Análises voltadas especificamente para o Maranhão que isolem fatores intracontextuais (aqueles que operam mesmo quando o contexto socioeconômico é semelhante) são escassas.

Métodos de aprendizado de máquina têm sido aplicados a dados educacionais com resultados promissores, especialmente pela capacidade de lidar com bases administrativas grandes e heterogêneas (Ersozlu; Taheri; Koch, 2024; Kalita et al., 2025; Romero; Ventura, 2020). Algoritmos de agrupamento identificam estruturas nos dados sem categorias predefinidas, o que os torna úteis para segmentar contextos antes de comparações (Faceli; Lorena; Carvalho, 2021; Kalita et al., 2025). Quando combinados com medidas de importância de variáveis e testes não paramétricos, essa abordagem permite identificar os fatores que mais diferenciam grupos de desempenho.

O objetivo geral deste artigo é identificar, entre municípios maranhenses de contexto socioeconômico semelhante, os fatores escolares associados ao desempenho superior no IDEB. Para isso, a análise abrange os 217 municípios maranhenses, dos quais 216 têm dados disponíveis no IDEB 2025 (anos iniciais do ensino fundamental,

rede municipal). No primeiro estágio, os municípios são agrupados por contexto socioeconômico via *K-Means*, usando renda *per capita* e IDHM. No segundo, dentro de cada grupo, um *Random Forest Classifier* combinado com o teste de Mann-Whitney identifica quais características escolares e socioeconômicas separam municípios de alto e baixo desempenho. As variáveis analisadas vêm do Censo Escolar 2025: infraestrutura (internet, biblioteca, laboratório de informática, saneamento), qualificação docente e indicadores de fluxo escolar.

O trabalho faz três contribuições principais. Primeiro, propõe e aplica ao contexto específico do Maranhão uma abordagem em dois estágios (segmentação socioeconômica seguida de análise intragrupo). Segundo, identifica os fatores escolares associados ao desempenho superior no IDEB dentro de cada perfil socioeconômico, tanto no grupo de municípios mais vulneráveis quanto no de maior renda. Terceiro, disponibiliza um *pipeline* reprodutível para análises similares em outras unidades federativas. Os resultados têm uso direto para gestores e formuladores de políticas que precisam decidir onde concentrar recursos.

O restante do artigo está organizado da seguinte forma: a próxima seção discute a mineração de dados educacionais e os determinantes do desempenho no IDEB; em seguida, os procedimentos metodológicos descrevem as fontes de dados, as variáveis e os dois estágios da análise; a seção de resultados apresenta a segmentação dos municípios, os fatores discriminantes e a discussão desses fatores à luz da literatura; por fim, as considerações finais sintetizam os achados, as limitações e as direções futuras.

ESTADO DA ARTE: MINERAÇÃO DE DADOS EDUCACIONAIS E DETERMINANTES DO DESEMPENHO NO IDEB

Compreender os fatores associados ao desempenho escolar exige articular dois campos de conhecimento: os estudos educacionais sobre os determinantes do desempenho e os métodos computacionais capazes de extrair padrões de grandes bases administrativas. Esta seção reúne essas bases teórico-conceituais, que sustentam as escolhas metodológicas e a interpretação dos resultados do estudo. Inicialmente, discute-se o uso de aprendizado de máquina na análise educacional; em seguida, o agrupamento não supervisionado como estratégia de segmentação contextual; depois, os estudos brasileiros sobre o IDEB e os condicionantes socioeconômicos desse ín-

dice, que evidenciam a escassez de pesquisas voltadas ao Maranhão; por fim, delimita-se a contribuição deste estudo em relação a essa literatura.

Aprendizado de máquina na análise educacional

A mineração de dados educacionais (*Educational Data Mining*, EDM) consolidou-se como área de pesquisa a partir da segunda metade da década de 2000, quando Baker e Yacef (2009) mapearam o estado da arte e identificaram cinco grandes paradigmas: predição, agrupamento, mineração de regras de associação, descoberta com modelos e visualização. Em revisão atualizada, Romero e Ventura (2020) estenderam esse panorama e evidenciaram a predominância de técnicas supervisionadas para tarefas de classificação, especialmente para predizer aprovação, evasão e desempenho em avaliações padronizadas.

No Brasil, a aplicação de algoritmos de aprendizado supervisionado a dados administrativos educacionais ganhou tração com a ampla disponibilização de microdados do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP). Estudos baseados no Censo Escolar e no IDEB aplicaram técnicas de mineração de dados para identificar fatores associados a desempenho e evasão (Colpani, 2018). A capacidade dessas técnicas de lidar com bases de alta dimensionalidade e distribuições assimétricas as torna adequadas a dados como os do Censo Escolar, que apresentam essas características.

Apesar dos avanços, a literatura nacional apresenta três lacunas persistentes:

a) concentração de estudos em municípios das regiões Sul e Sudeste;
b) uso de modelos globais que ignoram a heterogeneidade socioeconômica entre municípios;
c) sub-representação de estados como o Maranhão, onde as condições de vulnerabilidade tornam inadequada a comparação direta com médias nacionais.

Aprendizado não supervisionado para segmentação contextual

O agrupamento (*clustering*) via *K-Means*, proposto por MacQueen (1967), é uma das técnicas de aprendizado não supervisionado mais amplamente utilizadas para segmentação de entidades em grupos homogêneos internamente e heterogêneos entre si. O algoritmo minimiza a inércia intragrupo por meio de iterações de atribuição e

recentramento, requerendo apenas a especificação prévia do número de grupos k.

A seleção de k é um desafio clássico. O Método do Cotovelo (*Elbow Method*) avalia a variação da inércia, mas pode ser ambíguo em dados reais. O *Silhouette Score*, introduzido por Rousseeuw (1987), oferece uma métrica mais interpretável: para cada ponto, mede a razão entre a coesão do ponto em relação ao próprio grupo e a separação dele em relação ao *cluster* mais próximo, produzindo um escore entre -1 e 1 (quanto mais alto, mais bem definido o agrupamento).

Em contextos educacionais, o *K-Means* tem sido empregado para segmentar escolas por perfil socioeconômico antes de comparações de desempenho, o que evita confusões entre o efeito do contexto e a eficácia escolar. A visualização dos *clusters* via Análise de Componentes Principais (Abdi; Williams, 2010) permite inspecionar graficamente a qualidade da separação em espaço bidimensional, mesmo quando as variáveis originais têm escalas incomparáveis.

A combinação de *K-Means* para segmentação contextual com testes intragrupo para identificação de fatores discriminantes representa uma abordagem metodológica que preserva a validade interna das comparações: ao comparar municípios dentro do mesmo *cluster* socioeconômico, reduz-se o risco de atribuir a fatores escolares diferenças que são, na verdade, determinadas pela renda ou pelo nível de desenvolvimento humano.

O IDEB e os fatores socioeconômicos do desempenho escolar no Brasil

O IDEB foi concebido por Fernandes (2007) como uma medida composta que combina taxa de aprovação (fluxo) e proficiência em Língua Portuguesa e Matemática (Saeb/Prova Brasil), resultando em um indicador comparável ao longo do tempo e entre redes de ensino. Soares e Xavier (2013) examinaram os pressupostos estatísticos do índice, alertando para o risco de interpretações simplistas que ignoram a correlação entre fluxo e proficiência.

A relação entre qualificação docente e desempenho escolar é um dos achados mais robustos da literatura internacional. Rivkin, Hanushek e Kain (2005), em análise com dados do Texas, demonstraram que a qualidade do professor é o fator intraescolar com maior impacto sobre o aprendizado dos estudantes, superando infraestrutura e tamanho de turma. O efeito-escola, por sua vez, foi documentado desde o clássico relatório de Coleman et al. (1966), que identificou nos Estados Unidos que o contexto

socioeconômico familiar explica a maior parte da variância no desempenho, enquanto fatores escolares têm efeito residual (embora real e acionável por políticas públicas).

Albernaz, Ferreira e Franco (2002) identificaram que qualidade e equidade no ensino fundamental variam sistematicamente com o nível socioeconômico das escolas, evidenciando que comparações entre municípios de contextos distintos tendem a confundir efeito-escola com efeito-contexto. No Brasil, Vasconcelos et al. (2021) analisaram a relação entre infraestrutura escolar e desempenho usando dados do Censo Escolar e do Saeb, encontrando associação positiva entre presença de laboratórios, bibliotecas e conexão à internet e os resultados dos estudantes. Em revisão da literatura sobre recursos escolares em países em desenvolvimento, Glewwe et al. (2014) confirmaram que qualidade docente e infraestrutura física têm efeitos positivos, mas heterogêneos, sobre o aprendizado, com magnitude dependente do contexto local. Hanushek e Woessmann (2012) demonstraram, em perspectiva comparada entre países, que habilidades cognitivas têm efeito causal sobre crescimento econômico de longo prazo, reforçando a relevância de investigar os determinantes do desempenho escolar em estados de baixo Índice de Desenvolvimento Humano (IDH), como o Maranhão.

O que foi observado é que análises centradas especificamente no Maranhão são escassas. O estado figurou sistematicamente entre os piores índices nacionais no IDEB das séries iniciais (INEP, 2026b), com média municipal de 5,4 nos anos iniciais na edição mais recente. A concentração de municípios em condições de alta vulnerabilidade socioeconômica torna necessária uma abordagem que controle o contexto antes de comparar desempenhos, o que a literatura geral sobre IDEB raramente faz de forma sistemática.

Contribuição deste estudo à literatura

O presente trabalho distingue-se da literatura existente por três características:

a) adota uma abordagem em dois estágios que separa explicitamente a segmentação socioeconômica da análise de fatores intracontextuais;
b) aplica essa lógica exclusivamente aos 217 municípios maranhenses, dos quais 216 têm dados disponíveis no IDEB 2025, contexto sub-representado na literatura de EDM;
c) combina importâncias do *Random Forest* (Breiman, 2001) com testes de Mann-

Whitney (Mann; Whitney, 1947) para obter tanto uma ordenação de variáveis quanto evidência estatística de que as diferenças observadas não são atribuíveis ao acaso.

A análise intragrupo (restrita a municípios com contexto socioeconômico semelhante) responde a uma pergunta que modelos globais não conseguem: quais fatores diferem, de forma consistente e estatisticamente significativa, entre municípios que superam e que ficam abaixo do desempenho esperado dado o contexto socioeconômico em que se encontram? Essa pergunta tem implicação direta para políticas educacionais, pois identifica alvos de intervenção que operam mesmo sob restrições socioeconômicas.

PROCEDIMENTOS METODOLÓGICOS

Trata-se de uma pesquisa de abordagem quantitativa, de caráter descritivo e exploratório, baseada exclusivamente em dados secundários de acesso público. O *pipeline* analítico segue as etapas do processo CRISP-DM (*Cross-Industry Standard Process for Data Mining*) (Shearer, 2000), adaptado ao contexto de análise de dados educacionais: compreensão do domínio, coleta e preparação dos dados, modelagem e avaliação dos resultados. Dentro desse processo, a análise é conduzida em dois estágios sequenciais, descritos a seguir, após a apresentação das fontes de dados, das variáveis e do tratamento dos dados.

Fontes de dados

Este estudo integra quatro bases de dados públicas referentes aos municípios do Maranhão:

- **IDEB EFAI 2025 (INEP).** O Índice de Desenvolvimento da Educação Básica dos anos iniciais do ensino fundamental (EFAI), divulgado pelo INEP (INEP, 2026b), é calculado conforme a metodologia proposta por Fernandes (2007): combina a taxa de aprovação escolar (fluxo) com a proficiência média em Língua Portuguesa e Matemática aferida pelo Sistema de Avaliação da Educação Básica (Saeb). Para este estudo, utilizou-se a edição 2025 da rede municipal, que cobriu 216 dos 217 municípios do estado; Nova Iorque não teve o indicador divulgado nesta edição.

- **Censo Escolar 2025 (INEP).** Os microdados do Censo Escolar (INEP, 2026a) fornecem informações em nível de escola sobre infraestrutura física (internet, biblioteca/sala de leitura, laboratório de informática, quadra esportiva, abastecimento de água e esgotamento sanitário) e sobre o corpo docente. Para as variáveis de formação docente nos anos iniciais do ensino fundamental (EF), utilizou-se a Tabela 2.29 da Sinopse Estatística da Educação Básica 2025 (INEP, 2026c), que fornece o número de docentes EFAI por nível de formação de modo consistente entre numerador e denominador, eliminando o viés de dupla contagem presente nos microdados brutos.
- **Censo Demográfico 2022 (IBGE).** A renda *per capita* municipal foi extraída do Censo Demográfico 2022 do Instituto Brasileiro de Geografia e Estatística (IBGE) (IBGE, 2022a), tabela ”Valor do rendimento nominal médio mensal domiciliar per capita”(Sidra, tabela 10295), e utilizada como *proxy* da capacidade econômica dos municípios. É o dado de renda mais recente disponível com cobertura universal por município.
- **IDHM 2010 (Atlas Brasil/PNUD).** O Índice de Desenvolvimento Humano Municipal, calculado pelo Programa das Nações Unidas para o Desenvolvimento (PNUD) com base no Censo 2010 (PNUD; IPEA; FJP, 2013), captura três dimensões do desenvolvimento humano (longevidade, educação e renda) em um índice composto entre 0 e 1. A atualização do Atlas Brasil para o período 2022–2024 baseia-se na Pesquisa Nacional por Amostra de Domicílios Contínua (PNAD Contínua), cuja desagregação geográfica cobre apenas 146 estratos de municípios para todo o Brasil (IBGE, 2022b), não municípios individuais. Como a análise depende de diferenciar cada um dos 217 municípios maranhenses, manteve-se o IDHM calculado a partir do Censo Demográfico de 2010, a edição mais recente com desagregação municipal individual disponível. Junto com a renda *per capita*, compõe o espaço de segmentação socioeconômica utilizado na clusterização.

Variáveis

As variáveis são organizadas em quatro grupos, descritos no quadro 1.

Quadro 1 – Variáveis utilizadas na análise

Variável	Fonte	Definição operacional
Segmentação socioeconômica		
Renda *per capita* 2022	IBGE/Censo 2022	Rendimento domiciliar *per capita* médio mensal municipal (R$)
IDHM 2010	PNUD/Atlas	Índice de Desenvolvimento Humano Municipal
Infraestrutura escolar		
% escolas com internet	Censo 2025	Proporção de escolas municipais com acesso à internet
% escolas com biblioteca/sala de leitura	Censo 2025	Proporção com biblioteca, biblioteca-sala de leitura ou sala de leitura
% escolas com laboratório de informática	Censo 2025	Proporção com laboratório de informática
% escolas com quadra esportiva	Censo 2025	Proporção com quadra de esportes
% escolas com água adequada	Censo 2025	Proporção com água potável ou rede pública
% escolas com esgoto adequado	Censo 2025	Proporção com rede pública ou fossa séptica
Qualificação docente		
% docentes EFAI com ensino superior	Sinopse 2025	Proporção de docentes dos anos iniciais com graduação
% docentes EFAI com licenciatura	Sinopse 2025	Proporção de docentes dos anos iniciais com licenciatura
Fluxo e distorção		
Média de alunos/turma (EF)	Censo 2025	Total de matrículas no EF dividido pelo total de turmas do EF
Proxy distorção idade-série	Censo 2025	% matrículas com 15 anos ou mais na educação básica municipal
% turmas com correção de fluxo (EF anos finais)	Censo 2025	Proporção de turmas de correção de fluxo entre as turmas do EF anos finais

Fonte: elaboração própria (2026).

Coleta e pré-processamento dos dados

O *pipeline* de ingestão (`ingest.py`) automatiza a carga das quatro fontes descritas anteriormente. Para o IDEB, lê a planilha oficial do INEP e filtra os municípios maranhenses da rede municipal, tratando os códigos de não divulgação (ND, ND*, (*), (**)) como valores ausentes. Para o Censo Escolar 2025, o Inep passou a distribuir os microdados em quatro tabelas relacionais por domínio (escola, docente, matrícula e turma), cada uma agregada por escola; o *pipeline* lê as quatro em formato CSV (*en-*

coding latin-1, separador ponto-e-vírgula), filtra as escolas de dependência municipal no Maranhão (TP_DEPENDENCIA = 3) e as combina pela chave de identificação da escola (CO_ENTIDADE). Para os docentes dos anos iniciais, usa exclusivamente a Tabela 2.29 da Sinopse Estatística 2025 (planilha em formato XLSX), garantindo que numerador (docentes com superior) e denominador (total de docentes EFAI) venham da mesma fonte. Os dados de renda *per capita* vêm de uma cópia local da resposta da API pública do Sidra/IBGE (tabela 10295), salva no repositório para garantir a reprodutibilidade; os dados do IDHM são lidos de planilha Excel curada previamente.

As variáveis de infraestrutura são agregadas ao nível municipal como proporção de escolas com cada atributo presente. As variáveis de docentes, como percentual sobre o total de docentes EFAI do município. As variáveis de fluxo, como médias ou proporções sobre o total de matrículas e turmas municipais.

O *pipeline* de transformação (`transform.py`) aplica as seguintes operações:

- **IDEB:** substituição de valores especiais por `NaN`, conversão de vírgula para ponto decimal, remoção de colunas redundantes (notas separadas de língua portuguesa e matemática, já incorporadas na nota média).
- **Censo Escolar:** remoção de colunas completamente vazias, conversão de colunas de quantidade para inteiro, normalização do código municipal para 7 dígitos.
- **IBGE:** conversão do valor de renda *per capita* para numérico; a fonte já chega limpa, sem linhas de totalização.
- **IDHM:** remoção de linhas de totalização, renomeação de colunas para padrão interno.
- **Integração:** junção das quatro bases pela chave `NO_MUNICIPIO` (normalizada), com junção à esquerda a partir do IDEB. Resultado: 217 municípios com renda *per capita*, IDHM e Censo Escolar completos; 216 com o indicador do IDEB (ver seção anterior).

Após a integração, não há valores ausentes nas variáveis de *cluster* (renda *per capita* e IDHM), o que preserva os 217 municípios no Estágio 1. A variável-alvo (IDEB) tem um valor ausente (Nova Iorque), tratado por exclusão pontual nas etapas que dependem diretamente do IDEB (Estágio 2). As variáveis explicativas não têm valores ausentes; municípios sem turmas de correção de fluxo aparecem com proporção zero nessa variável.

Estágio 1: segmentação socioeconômica por *K-Means*

O *K-Means* (MacQueen, 1967) agrupa os 217 municípios com base em renda *per capita* e IDHM. Antes da clusterização, as duas variáveis são normalizadas via `RobustScaler`, que centraliza na mediana e escala pelo intervalo interquartil, reduzindo a influência de municípios atípicos, isto é, com renda *per capita* e IDHM muito acima dos demais municípios do estado, como São Luís e Imperatriz, que, por esses valores extremos, poderiam distorcer a formação dos grupos.

O número de *clusters* k é selecionado pela inspeção conjunta do Método do Cotovelo, que avalia a inércia total em função de k, e do *Silhouette Score* médio (Rousseeuw, 1987), que mede a separação relativa dos grupos. O algoritmo é executado com $k \in \{2, \ldots, 10\}$, inicialização `k-means++` e `n_init = 10`. A estabilidade dos *clusters* é avaliada por *bootstrap* de 25 iterações com 80% dos dados, seguindo a configuração de referência de Ben-Hur, Elisseeff e Guyon (2002), usando o *Adjusted Rand Index* (ARI) como métrica de concordância.

A visualização dos *clusters* é feita via Análise de Componentes Principais (PCA) (Abdi; Williams, 2010) com duas componentes, permitindo inspeção gráfica da separação em espaço reduzido.

Estágio 2: análise intragrupo

Dentro de cada *cluster* com amostra suficiente, os municípios são divididos em dois grupos por desempenho: *alto IDEB*, formado pelo quartil superior ($\geq Q_{75}$), e *baixo IDEB*, formado pelo quartil inferior ($\leq Q_{25}$). Os municípios do intervalo central são excluídos da análise comparativa, o que aumenta o contraste entre os grupos e reduz o ruído.

Para identificar quais variáveis diferenciam os dois grupos, aplica-se um *Random Forest Classifier* (Breiman, 2001) com 500 árvores, `class_weight='balanced'` e `min_samples_leaf=3`. A importância de cada variável é calculada pelo critério de redução média de impureza (*Mean Decrease in Impurity*), que quantifica a contribuição de cada variável para separar os dois grupos ao longo das 500 árvores. Em paralelo, o teste de Mann-Whitney (Mann; Whitney, 1947) bicaudal verifica se as distribuições das variáveis diferem significativamente entre os grupos alto e baixo IDEB. São utilizados três limiares de significância: $\alpha = 0{,}01$ (***), $\alpha = 0{,}05$ (**) e $\alpha = 0{,}10$ (*).

A combinação de importâncias do *Random Forest* com os p-valores do Mann-Whitney permite distinguir variáveis com alta relevância preditiva daquelas com diferença estatisticamente sustentada: uma variável é considerada fator discriminante relevante quando apresenta alta importância *e* diferença significativa ao nível de $\alpha = 0{,}10$.

Uso de ferramentas de inteligência artificial generativa

Este trabalho utilizou ferramentas de inteligência artificial generativa em três etapas do processo de pesquisa:

- **Revisão de código.** A primeira etapa do trabalho corresponde às fases de ciência de dados com Python. A ferramenta Claude (Anthropic) foi utilizada para correção e revisão dos *scripts* Python do *pipeline* de análise (`ingest.py`, `transform.py` e os módulos de modelagem), com validação e aprovação da autoria em cada alteração sugerida.
- **Revisão e edição de texto.** Na fase de produção escrita deste artigo, o Claude (Anthropic) e o ChatGPT (OpenAI) foram utilizados para revisar a redação e a clareza das seções. O texto original, a estrutura argumentativa e as interpretações dos resultados são de responsabilidade exclusiva da autoria.
- **Busca e validação de referências bibliográficas.** Claude (Anthropic) e SciSpace AI Research (PubGenius Inc.) foram utilizados para identificar trabalhos potencialmente relevantes e verificar metadados de citações. Cada referência foi conferida nas fontes originais antes da inclusão.

O uso dessas ferramentas está declarado em conformidade com as diretrizes de integridade científica do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), que exigem a identificação explícita das ferramentas de inteligência artificial generativa utilizadas, as finalidades de cada uma e a responsabilização integral do pesquisador pelos resultados produzidos.

RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados obtidos com a aplicação dos dois estágios descritos nos procedimentos metodológicos e os discute à luz da literatura. Inicialmente, caracterizam-se o contexto socioeconômico e educacional do Maranhão e a

distribuição do IDEB entre os municípios, o que evidencia a variabilidade de desempenho que motiva a investigação. Em seguida, apresentam-se a segmentação socioeconômica obtida com o *K-Means* e, dentro de cada um dos dois grupos resultantes, os fatores que diferenciam os municípios de alto e de baixo desempenho. Por fim, esses achados são confrontados com os estudos sobre o IDEB e traduzidos em implicações para as políticas educacionais.

Contexto socioeconômico e educacional do Maranhão

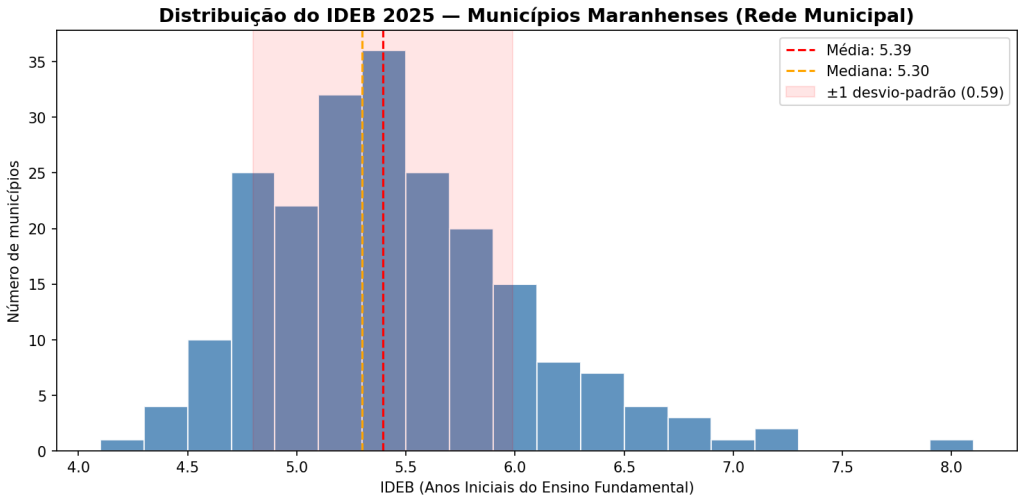
O Maranhão é o segundo maior estado do Nordeste em extensão territorial e um dos mais populosos, com 217 municípios distribuídos em cinco mesorregiões. Em indicadores socioeconômicos, ocupa posições críticas: IDHM médio de 0,639 em 2010 (um dos mais baixos do país) (IBGE, 2010) e renda *per capita* municipal mediana de R$ 667 no Censo Demográfico de 2022 (IBGE, 2022a). Esse contexto reflete-se diretamente nos resultados educacionais: na edição 2025 do IDEB, a média dos 216 municípios maranhenses com indicador divulgado nos anos iniciais da rede municipal ficou em 5,39 (desvio-padrão de 0,59), com metade dos municípios abaixo de 5,30, valores que evidenciam tanto o atraso histórico quanto a dispersão expressiva do desempenho entre municípios.

A questão central desta investigação é identificar, entre municípios com contexto socioeconômico semelhante, quais fatores escolares estão associados ao desempenho superior no IDEB. Respondê-la exige, primeiro, neutralizar o efeito do contexto por meio de uma segmentação explícita e, depois, comparar, dentro de cada grupo, os municípios de alto e baixo desempenho.

Distribuição do IDEB entre os municípios

A distribuição do IDEB dos 216 municípios maranhenses com indicador divulgado é apresentada no gráfico 1. A distribuição é aproximadamente unimodal, ligeiramente assimétrica à direita, com média de 5,39 (desvio-padrão de 0,59), mediana de 5,30, mínimo de 4,10 e máximo de 8,10.

Gráfico 1 – Distribuição do IDEB 2025 dos municípios maranhenses – rede municipal, anos iniciais do ensino fundamental



Nota: linha vermelha tracejada: média (5,39); linha laranja tracejada: mediana (5,30); faixa vermelha: intervalo de ± 1 desvio-padrão.

Fonte: elaboração própria com base em INEP (2026b).

A amplitude de 4,00 pontos (4,10 a 8,10) é expressiva dado que o IDEB varia de 0 a 10. Isso indica que, mesmo dentro do Maranhão (estado homogeneamente vulnerável em termos nacionais), existe variabilidade interna substancial que justifica investigar os fatores associados aos destaques positivos.

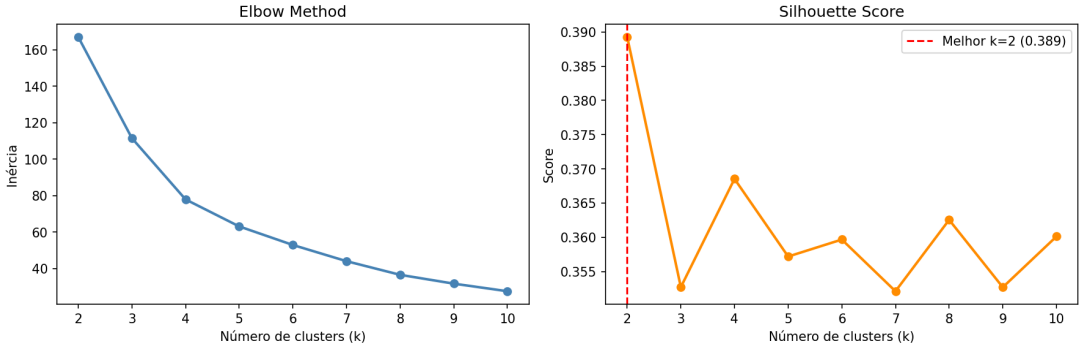
Segmentação socioeconômica dos municípios

A clusterização *K-Means* foi aplicada sobre as variáveis *renda per capita* e *IDHM* (normalizadas via RobustScaler), testando $k \in \{2, \ldots, 10\}$, conforme descrito nos procedimentos metodológicos.

No gráfico 2, são apresentadas as curvas de inércia (cotovelo) e de *Silhouette Score* para $k \in \{2, \ldots, 10\}$. O *Silhouette Score* atinge o valor máximo em $k = 2$ (0,389), indicando que dois grupos é a partição com melhor separação relativa entre as testadas, ainda que o valor moderado indique sobreposição relevante entre os grupos. A curva de inércia decresce de forma gradual, sem um cotovelo nítido, e por isso não oferece um critério adicional forte para a escolha de k. A estabilidade *bootstrap* (ARI) foi calculada para $k \in \{2, 3, 4, 5\}$ e não favorece $k = 2$: o ARI médio é 0,485 em $k = 2$, subindo para 0,579 em $k = 3$ e 0,651 em $k = 4$, ou seja, partições com mais grupos são mais estáveis sob reamostragem. A escolha de $k = 2$ neste estudo apoia-se,

portanto, no *Silhouette Score* e na interpretabilidade substantiva da distinção vulnerável/maior renda, não na estabilidade *bootstrap*, o que é discutido como limitação nas considerações finais.

Gráfico 2 – Curvas de inércia e de *Silhouette Score* para $k \in \{2, \ldots, 10\}$

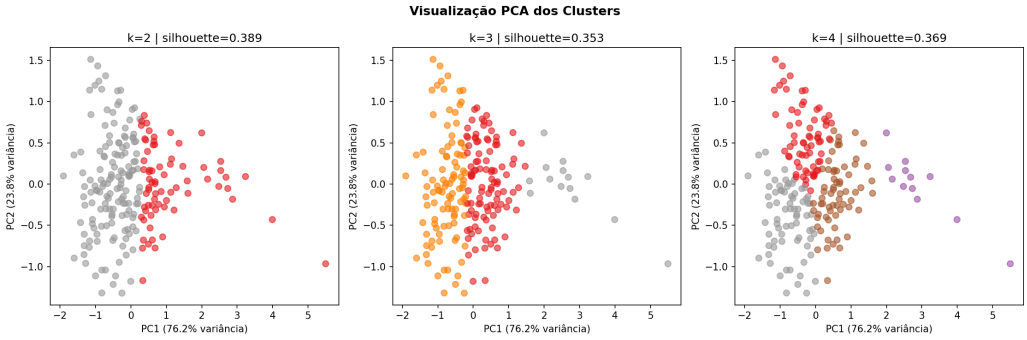


Nota: à esquerda, inércia; à direita, *Silhouette Score*. A linha vertical vermelha indica o k ótimo segundo o *Silhouette Score*.

Fonte: dados da pesquisa (2026).

No gráfico 3, são exibidos os *clusters* projetados nas duas primeiras componentes principais (a primeira componente, PC1, explica 76,2% da variância; a segunda, PC2, explica 23,8%). A separação visual entre os dois grupos é perceptível, mas com sobreposição relevante nas bordas, consistente com o *Silhouette Score* moderado; entre as alternativas testadas ($k \in \{2, 3, 4\}$), a separação em dois grupos ainda é a mais nítida disponível.

Gráfico 3 – Projeção dos *clusters* de municípios maranhenses nas duas primeiras componentes principais para $k \in \{2, 3, 4\}$



Fonte: dados da pesquisa (2026).

Os dois *clusters* obtidos são denominados pelo critério de renda média:

- ***Cluster* vulnerável** (n = 147): renda *per capita* média de R$ 607,77, IDHM

médio de 0,73, IDEB médio de 5,31.

- ***Cluster* maior renda** (n = 70): renda *per capita* média de R$ 846,55, IDHM médio de 0,76, IDEB médio de 5,56. Inclui municípios como Timon, Porto Franco, Paço do Lumiar e Zé Doca.

Como teste de sensibilidade (não reportado em detalhe), uma reclusterização com a renda *per capita* de 2010 no lugar da de 2022 resulta em um *cluster* de maior renda com apenas 20 municípios. A atualização para a renda de 2022 desloca a fronteira entre os grupos: o *cluster* de maior renda passa a ter 70 municípios, amostra agora suficiente para a análise intragrupo por quantis. As duas subseções seguintes apresentam os fatores discriminantes em cada grupo.

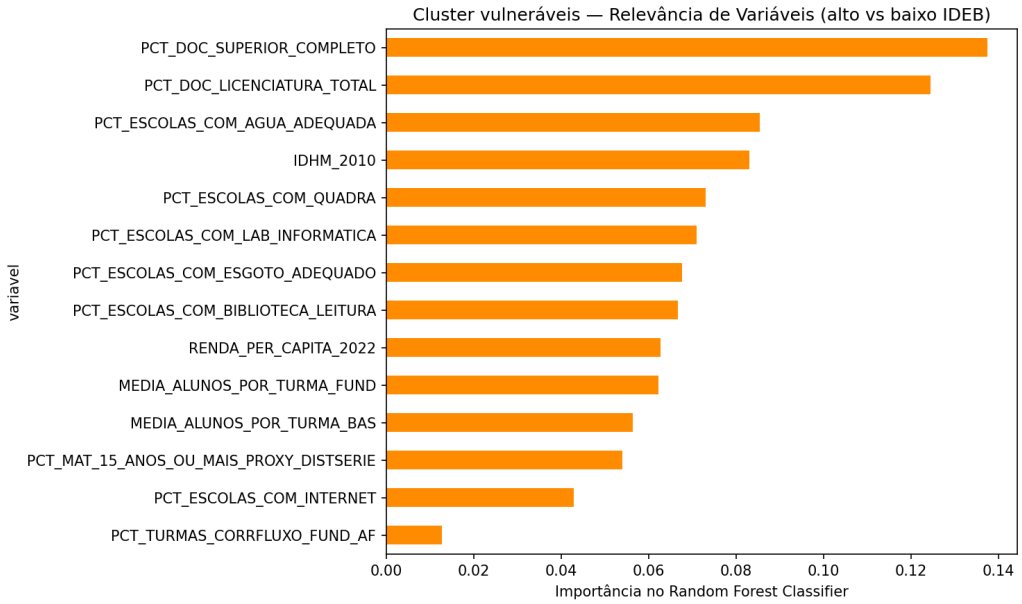
Os percentuais médios das variáveis de infraestrutura revelam disparidades: a *conectividade à internet* está presente em 85,8% das escolas municipais do *cluster* vulnerável e em 90,3% das escolas do *cluster* de maior renda; já o acesso a *biblioteca ou sala de leitura* é relativamente baixo em ambos os grupos (16,9% nas escolas vulneráveis e 24,1% nas de maior renda). A proporção média de *docentes EFAI com ensino superior* é de 57,5% nos municípios mais vulneráveis e de 70,7% naqueles de maior renda, diferença que antecipa uma das hipóteses testadas no estágio intragrupo.

Fatores discriminantes no *cluster* vulnerável

Dentro do *cluster* vulnerável (n = 147), os 41 municípios que se encontram no quartil superior de IDEB (alto, $\geq 5{,}60$, média 6,00) são comparados aos 43 do quartil inferior (baixo, $\leq 4{,}90$, média 4,71). A diferença média de 1,29 ponto de IDEB entre os grupos é substancial: equivale a mais de dois desvios-padrão da distribuição estadual.

No gráfico 4, apresentam-se as importâncias do *Random Forest Classifier* para o *cluster* vulnerável. As oito variáveis de maior importância são, em ordem decrescente: *% docentes com ensino superior* (0,137), *% docentes com licenciatura* (0,124), *% escolas com água adequada* (0,086), *IDHM* (0,083), *% escolas com quadra esportiva* (0,073), *% escolas com laboratório de informática* (0,071), *% escolas com esgoto adequado* (0,068) e *% escolas com biblioteca/sala de leitura* (0,067).

Gráfico 4 – Importância das variáveis no *Random Forest Classifier* para diferenciar municípios de alto e baixo IDEB no *cluster* vulnerável



Fonte: dados da pesquisa (2026).

O teste de Mann-Whitney complementa a análise ao indicar quais variáveis apresentam diferenças estatisticamente significativas entre os grupos. Na tabela 1, resumem-se os resultados para as variáveis com $p < 0{,}10$; as diferenças entre proporções são expressas em pontos percentuais (p.p.).

Tabela 1 – Variáveis com diferença significativa entre municípios de alto e baixo IDEB no *cluster* vulnerável (Mann-Whitney bicaudal)

Variável	Média alto	Média baixo	Δ	p-valor
% doc. com ensino superior	63,5%	48,6%	+15,0 p.p.	0,001***
% doc. com licenciatura	62,2%	47,6%	+14,6 p.p.	0,001***
% escolas com quadra esportiva	8,8%	5,5%	+3,2 p.p.	0,077*
% escolas com laboratório de informática	6,8%	3,7%	+3,1 p.p.	0,058*

Nota: *** $p < 0{,}01$; * $p < 0{,}10$.

Fonte: dados da pesquisa (2026).

A formação docente emerge como o fator intracontextual mais consistentemente associado ao desempenho superior, com significância estatística elevada: municípios vulneráveis de alto IDEB têm, em média, 15,0 p.p. a mais de *docentes com ensino superior* e 14,6 p.p. a mais com *licenciatura* em comparação aos de baixo IDEB, ambos com $p < 0{,}01$. Esse achado é convergente com a literatura internacional. Rivkin, Hanushek e Kain (2005) demonstraram que a qualidade do professor é o fator intra-

escolar de maior impacto sobre o aprendizado. Estudos nacionais também apontam formação docente como variável central nos resultados do IDEB (Vasconcelos et al., 2021).

A *quadra esportiva* ($p = 0{,}077$) e o *laboratório de informática* ($p = 0{,}058$) aparecem como fatores discriminantes ao nível de 10%. No teste de sensibilidade com dados de uma edição anterior do Ideb e do Censo Escolar (não reportado em detalhe), biblioteca/sala de leitura e conectividade à internet ocupavam esse lugar; a composição exata de quais variáveis secundárias atingem significância é, portanto, sensível à edição de dados utilizada, o que é consistente com a separação moderada entre os *clusters* relatada na segmentação (*Silhouette Score* de 0,389).

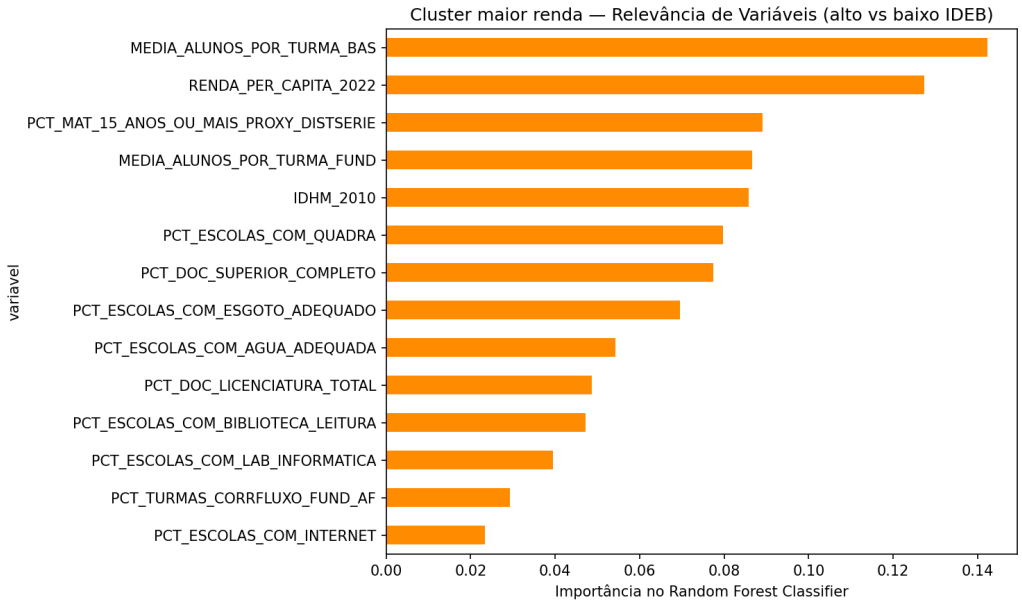
O *IDHM* aparece entre as variáveis de maior importância no *Random Forest* (0,083) mesmo dentro do *cluster* vulnerável, onde sua variação é estruturalmente menor, ainda que sem diferença estatisticamente significativa entre os grupos de alto e baixo IDEB ($p = 0{,}661$). Como a importância no *Random Forest* tende a favorecer variáveis contínuas, essa importância isolada não deve ser lida como evidência de associação; sem significância no teste de Mann-Whitney, o achado é, na melhor das hipóteses, sugestivo.

Fatores discriminantes no *cluster* de maior renda

Com a atualização da renda *per capita* para o Censo Demográfico de 2022, o *cluster* de maior renda passou a reunir 70 municípios, amostra suficiente para repetir a mesma análise intragrupo aplicada ao *cluster* vulnerável. Os 21 municípios do quartil superior de IDEB (alto, $\geq 6{,}00$) são comparados aos 19 do quartil inferior (baixo, $\leq 5{,}10$).

No gráfico 5, apresentam-se as importâncias do *Random Forest Classifier* para o *cluster* de maior renda. As oito variáveis de maior importância são, em ordem decrescente: *média de alunos por turma na educação básica* (0,142), *renda per capita* (0,127), *proxy de distorção idade-série* (0,089), *média de alunos por turma no ensino fundamental* (0,087), *IDHM* (0,086), *% escolas com quadra esportiva* (0,080), *% docentes com ensino superior* (0,077) e *% escolas com esgoto adequado* (0,070).

Gráfico 5 – Importância das variáveis no *Random Forest Classifier* para diferenciar municípios de alto e baixo IDEB no *cluster* de maior renda



Fonte: dados da pesquisa (2026).

A tabela 2 resume as variáveis com diferença estatisticamente significativa ($p < 0{,}10$) entre os municípios de alto e baixo IDEB nesse *cluster*.

Tabela 2 – Variáveis com diferença significativa entre municípios de alto e baixo IDEB no *cluster* de maior renda (Mann-Whitney bicaudal)

Variável	**Média alto**	**Média baixo**	**Δ**	**p-va**
Alunos/turma, educação básica (média)	19,4	17,4	+2,0	0,02
Renda *per capita* (R$)	876,7	770,4	+106,3	0,04
% escolas com quadra esportiva	11,7%	6,8%	+4,9 p.p.	0,03
Alunos/turma, ensino fundamental (média)	20,6	18,8	+1,8	0,07
% turmas com correção de fluxo (EF anos finais)	0,98%	0,30%	+0,7 p.p.	0,08
% doc. com ensino superior	75,7%	66,1%	+9,5 p.p.	0,09

Nota: ** $p < 0{,}05$; * $p < 0{,}10$.

Fonte: dados da pesquisa (2026).

O achado mais chamativo desse *cluster* é a direção do *tamanho de turma*: municípios de maior renda com IDEB alto têm, em média, turmas *maiores* (2,0 alunos a mais na educação básica como um todo, 1,8 a mais no ensino fundamental como um todo) do que os de IDEB baixo, o inverso do que a literatura sobre tamanho de turma costuma reportar (Rivkin; Hanushek; Kain, 2005). Uma leitura cautelosa é que essa variável funcione aqui como *proxy* de urbanização ou de escala administrativa (esco-

las maiores, mais estruturadas, atraem mais matrículas por turma) em vez de captar um efeito pedagógico direto do tamanho de turma sobre a aprendizagem; a análise não permite distinguir entre essas explicações. A *renda per capita* e a % *de escolas com quadra esportiva* também diferenciam os grupos. A % *de turmas com correção de fluxo no ensino fundamental anos finais* é maior entre os municípios de IDEB alto (0,98% contra 0,30%, $p = 0{,}088$), resultado que, isoladamente, não permite inferir se a oferta de correção de fluxo é causa ou consequência do desempenho. A % *de docentes com ensino superior* repete, nesse *cluster*, o padrão observado entre os municípios vulneráveis, embora com significância mais marginal ($p = 0{,}090$).

Diálogo com a literatura sobre o IDEB

Os achados dialogam com a literatura de maneiras específicas. A centralidade da qualificação docente é convergente com o achado seminal de Rivkin, Hanushek e Kain (2005) no contexto norte-americano e com estudos brasileiros que identificaram formação superior como fator associado ao IDEB (Vasconcelos et al., 2021); no *cluster* vulnerável essa associação é forte ($p < 0{,}01$ para ensino superior e licenciatura), enquanto no *cluster* de maior renda ela aparece apenas para ensino superior e de forma mais marginal ($p = 0{,}090$). Já a direção contraintuitiva do *tamanho de turma* no *cluster* de maior renda ilustra o limite desse tipo de análise associativa: a tese de Coleman et al. (1966) de que recursos escolares têm efeito real, embora secundário ao contexto, não prevê sinal invertido para essa variável, o que reforça a leitura de que ela pode estar capturando um efeito de escala ou urbanização, não um efeito pedagógico direto do tamanho da turma.

Em relação à literatura de mineração de dados educacionais, o trabalho contribui com uma aplicação metodológica que supera duas limitações frequentes: o uso de modelos globais que ignoram a heterogeneidade socioeconômica entre municípios e a concentração de estudos EDM nas regiões Sul e Sudeste (Baker; Yacef, 2009; Romero; Ventura, 2020). A abordagem em dois estágios é replicável para outros estados e pode ser adaptada a outros níveis de ensino (anos finais do ensino fundamental, ensino médio) ou outras medidas de desempenho.

Quanto ao IDEB como métrica, os pressupostos estatísticos identificados por Soares e Xavier (2013) (especialmente a correlação entre fluxo e proficiência) não invalidam a análise, mas sugerem cautela na interpretação: municípios com IDEB ele-

vado podem estar priorizando aprovação em detrimento da proficiência. A combinação de variáveis de fluxo (*distorção idade-série*, *correção de fluxo*) com os indicadores estruturais na mesma análise ajuda a mitigar parcialmente esse risco.

Implicações para as políticas educacionais

Os resultados têm implicações diretas para gestores municipais e formuladores de políticas educacionais do Maranhão, com direções distintas para cada perfil socioeconômico:

- **Formação e habilitação docente (ambos os *clusters*).** A diferença de 15,0 p.p. na proporção de *docentes com ensino superior* entre municípios de alto e baixo IDEB no *cluster* vulnerável ($p < 0{,}01$), repetida de forma mais marginal no *cluster* de maior renda (+9,5 p.p., $p = 0{,}090$), torna programas de formação continuada e de indução à licenciatura específica candidatos plausíveis de política pública em todo o estado, não apenas nos municípios mais vulneráveis; a análise associativa não permite, porém, quantificar o impacto esperado. Políticas estaduais e federais de financiamento de graduação a distância para docentes em exercício (como o Programa Nacional de Formação de Professores da Educação Básica — Parfor) são alvos naturais de expansão.
- **Infraestrutura esportiva e de informática (*cluster* vulnerável).** A quadra esportiva ($p = 0{,}077$) e o laboratório de informática ($p = 0{,}058$) emergem como fatores discriminantes específicos dos municípios mais vulneráveis, sugerindo que, nesse grupo, esses recursos são candidatos a priorização no monitoramento e na alocação orçamentária, ainda que a análise não permita estimar o retorno esperado desses investimentos.
- **Renda e escala (*cluster* de maior renda).** A renda *per capita* municipal ($p = 0{,}048$) e o tamanho de turma ($p = 0{,}025$) diferenciam os municípios de alto e baixo IDEB nesse grupo. Como o sinal do tamanho de turma é contraintuitivo (turmas maiores associadas a IDEB mais alto), essa variável deve ser interpretada como sinalizador de contexto administrativo e urbano, não como recomendação de política para aumentar o número de alunos por turma.

CONSIDERAÇÕES FINAIS

Este trabalho propôs e aplicou uma abordagem em dois estágios (segmentação socioeconômica por *K-Means* seguida de análise intragrupo com *Random Forest Classifier* e teste de Mann-Whitney) aos 217 municípios maranhenses, dos quais 216 têm dados no IDEB 2025 (anos iniciais do ensino fundamental, rede municipal). Os resultados identificaram a *formação docente* como o fator intracontextual mais consistentemente associado ao desempenho superior: no grupo de municípios vulneráveis, tanto a formação em nível superior quanto a licenciatura diferenciam fortemente os grupos ($p < 0{,}01$); no de maior renda, apenas a formação em nível superior aparece, e de forma marginal ($p = 0{,}090$). Isso atende ao objetivo de isolar fatores escolares que operam mesmo sob contexto socioeconômico semelhante. Dentro do *cluster* vulnerável, quadra esportiva e laboratório de informática também se destacam; dentro do *cluster* de maior renda, renda *per capita* e tamanho de turma diferenciam os grupos de alto e baixo desempenho.

Este estudo apresenta cinco limitações relevantes que devem ser consideradas na interpretação dos resultados.

- **Descompasso de anos entre as variáveis de segmentação.** A renda *per capita* utilizada é do Censo Demográfico de 2022, mas o IDHM permanece o de 2010: a extensão do Atlas Brasil para o período 2022–2024 baseia-se na PNAD Contínua, cuja desagregação geográfica cobre apenas 146 estratos de municípios para todo o Brasil, não municípios individuais, o que a torna inadequada para diferenciar os 217 municípios maranhenses individualmente. Enquanto o IBGE ou o Atlas Brasil não publicarem um IDHM municipal individual mais recente, esse descompasso de doze anos entre as duas variáveis de segmentação permanece uma limitação estrutural do desenho.
- **Separação moderada e estabilidade limitada dos *clusters*.** O *Silhouette Score* da partição em dois grupos é 0,389, o maior entre os k testados, mas indicativo de sobreposição relevante. A estabilidade *bootstrap* não favorece $k = 2$: o ARI médio é 0,485, abaixo do obtido com três (0,579) ou quatro grupos (0,651). A escolha de dois grupos apoia-se no *Silhouette Score* e na interpretabilidade substantiva, e municípios próximos ao limiar podem trocar de grupo em reamostragens. Isso recomenda cautela ao tratar a fronteira entre *clusters* como uma divisão rígida e explica, em parte, por que as variáveis secundárias que atingem

significância mudam conforme a edição dos dados.

- **Causalidade.** A análise é descritiva e associativa, não causal. Não é possível afirmar que *formação docente* ou *infraestrutura escolar* causam IDEB mais alto. Municípios com gestão mais eficaz tendem a contratar mais docentes qualificados e a obter melhores resultados ao mesmo tempo, tornando difícil separar o efeito de cada variável do efeito da qualidade de gestão municipal. O sinal contraintuitivo do tamanho de turma no *cluster* de maior renda (turmas maiores associadas a IDEB mais alto) ilustra esse risco: é mais plausível que essa variável capture escala administrativa ou urbanização do que um efeito pedagógico direto. Estudos de painel com variação longitudinal do IDEB (2019–2025) permitiriam estimativas mais robustas do efeito causal.
- **Comparações múltiplas.** Em cada *cluster* foram realizados catorze testes de Mann-Whitney sem correção para comparações múltiplas. Os achados com $p < 0{,}01$ (formação docente no *cluster* vulnerável) são robustos a essa questão; os achados entre 0,05 e 0,10 devem ser lidos como indicativos, não conclusivos.
- **Variáveis de gestão escolar ausentes.** O Censo Escolar não captura variáveis de processos pedagógicos, gestão, clima escolar ou engajamento familiar, que são mediadores importantes do desempenho. A inclusão de dados de avaliações de escola (como avaliações próprias do estado) em pesquisas futuras poderia complementar o diagnóstico aqui apresentado.

Apesar dessas limitações, a abordagem em dois estágios mostrou-se útil para orientar a alocação de recursos educacionais em diferentes perfis socioeconômicos, ao apontar fatores escolares passíveis de intervenção tanto em municípios vulneráveis quanto em municípios de maior renda.

REFERÊNCIAS

ABDI, Hervé; WILLIAMS, Lynne J. Principal Component Analysis. **WIREs Computational Statistics**, v. 2, n. 4, p. 433–459, 2010. DOI: 10.1002/wics.101. Disponível em: <https://doi.org/10.1002/wics.101>. Acesso em: 25 mai. 2026.

ALBERNAZ, Ângela; FERREIRA, Francisco H. G.; FRANCO, Creso. Qualidade e Eqüidade no Ensino Fundamental Brasileiro. **Pesquisa e Planejamento Econômico**, v. 32, n. 3, p. 453–476, 2002. Disponível em: <https://ppe.ipea.gov.br/index.php/ppe/article/view/139>. Acesso em: 23 mai. 2026.

BAKER, Ryan S. J. D.; YACEF, Kalina. The State of Educational Data Mining in 2009: A Review and Future Visions. **Journal of Educational Data Mining**, v. 1, n. 1, p. 3–16,

2009. DOI: 10.5281/zenodo.3554658. Disponível em: <https://jedm.educationaldatamining.org/index.php/JEDM/article/view/8>. Acesso em: 23 mai. 2026.

BEN-HUR, Asa; ELISSEEFF, André; GUYON, Isabelle. A Stability Based Method for Discovering Structure in Clustered Data. In: PACIFIC Symposium on Biocomputing. [S.l.: s.n.], 2002. v. 7, p. 6–17. Disponível em: <https://psb.stanford.edu/psb-online/proceedings/psb02/benhur.pdf>. Acesso em: 29 mai. 2026.

BREIMAN, Leo. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: 10.1023/A:1010933404324. Disponível em: <https://link.springer.com/article/10.1023/A:1010933404324>. Acesso em: 25 mai. 2026.

COLEMAN, James S. et al. **Equality of Educational Opportunity**. Washington, D.C.: U.S. Government Printing Office, 1966. Disponível em: <https://archive.org/details/equalityofeducat0000cole_a0h5>. Acesso em: 23 mai. 2026.

COLPANI, Rogério. Mineração de Dados Educacionais: um estudo da evasão no ensino médio com base nos indicadores do Censo Escolar. **Informática na Educação: Teoria & Prática**, v. 21, n. 3, 2018. DOI: 10.22456/1982-1654.87880. Disponível em: <https://seer.ufrgs.br/InfEducTeoriaPratica/article/view/87880>. Acesso em: 27 mai. 2026.

ERSOZLU, Zara; TAHERI, Sona; KOCH, Inge. A Review of Machine Learning Methods Used for Educational Data. **Education and Information Technologies**, v. 29, n. 16, p. 22125–22145, 2024. DOI: 10.1007/s10639-024-12704-0. Disponível em: <https://doi.org/10.1007/s10639-024-12704-0>. Acesso em: 27 set. 2026.

FACELI, Katti; LORENA, Ana Carolina; CARVALHO, André Carlos Paulo de Leon Ferreira de. **Inteligência Artificial: uma abordagem de aprendizado de máquina**. 2. ed. Rio de Janeiro: LTC, 2021. 424 p. ISBN 9788521637349.

FERNANDES, Reynaldo. **Índice de Desenvolvimento da Educação Básica (IDEB)**. Brasília, 2007. Disponível em: <https://rbep.inep.gov.br/ojs3/index.php/td/article/view/3850>. Acesso em: 23 mai. 2026.

GLEWWE, Paul W. et al. School Resources and Educational Outcomes in Developing Countries: A Review of the Literature from 1990 to 2010. In: GLEWWE, Paul (Ed.). **Education Policy in Developing Countries**. Chicago: University of Chicago Press, 2014. P. 13–64. Disponível em: <https://www.nber.org/papers/w17554>. Acesso em: 23 mai. 2026.

HANUSHEK, Eric A.; WOESSMANN, Ludger. Do Better Schools Lead to More Growth? Cognitive Skills, Economic Outcomes, and Causation. **Journal of Economic Growth**, v. 17, n. 4, p. 267–321, 2012. DOI: 10.1007/s10887-012-9081-x. Disponível em: <https://link.springer.com/article/10.1007/s10887-012-9081-x>. Acesso em: 23 mai. 2026.

IBGE. **Censo Demográfico 2010**. Rio de Janeiro: IBGE, 2010. Disponível em: <https://www.ibge.gov.br/estatisticas/sociais/saude/9662-censo-demografico-2010.html>. Acesso em: 23 mai. 2026.

IBGE. **Censo Demográfico 2022: rendimento nominal médio mensal domiciliar per capita, por município**. Rio de Janeiro: IBGE, 2022a. Sidra, tabela 10295. Disponível em: <https://sidra.ibge.gov.br/tabela/10295>. Acesso em: 27 set. 2026.

_____. **Nota técnica 01/2022: estimativas para estratos de municípios na PNAD Contínua**. Rio de Janeiro: IBGE, 2022b. Disponível em: <https://www.ibge.gov.br/novo-portal-destaques/33562-nota-tecnica-estimativas-para-estratos-de-municipios-na-pnad-continua.html>. Acesso em: 27 set. 2026.

INEP. **Microdados do Censo Escolar da Educação Básica 2025**. Brasília: INEP, 2026a. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/censo-escolar>. Acesso em: 27 set. 2026.

_____. **Nota Informativa: IDEB 2025**. Brasília, 2026b. Disponível em: <https://download.inep.gov.br/ideb/resultados/nota_informativa_ideb_2025.pdf>. Acesso em: 27 set. 2026.

_____. **Sinopse Estatística da Educação Básica 2025**. Brasília: INEP, 2026c. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/sinopses-estatisticas/educacao-basica>. Acesso em: 27 set. 2026.

KALITA, Emi et al. Educational Data Mining: A 10-Year Review. **Discover Computing**, v. 28, n. 1, 2025. DOI: 10.1007/s10791-025-09589-z. Disponível em: <https://doi.org/10.1007/s10791-025-09589-z>. Acesso em: 27 set. 2026.

MACQUEEN, James B. Some Methods for Classification and Analysis of Multivariate Observations. In: PROCEEDINGS of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. Berkeley, CA: University of California Press, 1967. v. 1, p. 281–297. Disponível em: <https://projecteuclid.org/euclid.bsmsp/1200512992>. Acesso em: 25 mai. 2026.

MANN, Henry B.; WHITNEY, Donald R. On a Test of Whether One of Two Random Variables Is Stochastically Larger than the Other. **The Annals of Mathematical Statistics**, v. 18, n. 1, p. 50–60, 1947. DOI: 10.1214/aoms/1177730491. Disponível em: <https://projecteuclid.org/euclid.aoms/1177730491>. Acesso em: 25 mai. 2026.

PNUD; IPEA; FJP. **Atlas do Desenvolvimento Humano no Brasil**. Brasília: PNUD; IPEA; FJP, 2013. Disponível em: <http://www.atlasbrasil.org.br>. Acesso em: 26 set. 2026.

RIVKIN, Steven G.; HANUSHEK, Eric A.; KAIN, John F. Teachers, Schools, and Academic Achievement. **Econometrica**, v. 73, n. 2, p. 417–458, 2005. DOI: 10.1111/j.1468-0262.2005.00584.x. Disponível em: <https://www.nber.org/papers/w6691>. Acesso em: 23 mai. 2026.

ROMERO, Cristóbal; VENTURA, Sebastián. Educational Data Mining and Learning Analytics: An Updated Survey. **WIREs Data Mining and Knowledge Discovery**, v. 10, n. 3, e1355, 2020. DOI: 10.1002/widm.1355. Disponível em: <https://doi.org/10.1002/widm.1355>. Acesso em: 23 mai. 2026.

ROUSSEEUW, Peter J. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987. DOI: 10.1016/0377-0427(87)90125-7. Disponível em: <https://www.sciencedirect.com/science/article/pii/0377042787901257>. Acesso em: 25 mai. 2026.

SHEARER, Colin. The CRISP-DM Model: The New Blueprint for Data Mining. **Journal of Data Warehousing**, v. 5, n. 4, p. 13–22, 2000. Disponível em: <https://mineracaodedados.wordpress.com/wp-content/uploads/2012/04/the-crisp-dm-model-the-new-blueprint-for-data-mining-shearer-colin.pdf>. Acesso em: 29 mai. 2026.

SOARES, José Francisco; XAVIER, Flávia Pereira. Pressupostos educacionais e estatísticos do IDEB. **Educação & Sociedade**, v. 34, n. 124, p. 903–923, 2013. DOI: 10.1590/S0101-73302013000300013. Disponível em: <https://www.scielo.br/j/es/a/JLzr4qdx89rjrNXnydNcvcy/>. Acesso em: 25 mai. 2026.

VASCONCELOS, Joyciane Coelho et al. Infraestrutura escolar e investimentos públicos em Educação no Brasil: a importância para o desempenho educacional. **Ensaio: Avaliação e Políticas Públicas em Educação**, v. 29, n. 113, p. 874–898, 2021. DOI: 10.1590/S0104-40362020002802245. Disponível em: <https://www.scielo.br/j/ensaio/a/w9HwRXMQ3FVZ9fzJJKBgLLt/>. Acesso em: 23 mai. 2026.

INFORMAÇÕES COMPLEMENTARES

Disponibilidade de dados

Os dados utilizados neste trabalho são de acesso público e foram disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), vinculado ao Ministério da Educação, pelo Instituto Brasileiro de Geografia e Estatística (IBGE) e pelo Programa das Nações Unidas para o Desenvolvimento (PNUD). Os resultados e interpretações são de responsabilidade exclusiva da autoria e não representam posição oficial dessas instituições.