DEBATES EM EDUCAÇÃO
ISSN: 2175-6600

Artigo | Article

Fatores intracontextuais do desempenho no IDEB: segmentação socioeconômica e análise intragrupo nos municípios do Maranhão

Intracontextual factors of IDEB performance: socioeconomic segmentation and within-group analysis in the municipalities of Maranhão

Factores intracontextuales del desempeño en el IDEB: segmentación socioeconómica y análisis intragrupo en los municipios de Maranhão

Resumo

O desempenho educacional dos municípios maranhenses permanece entre os mais baixos do país, e a desigualdade socioeconômica dificulta comparações diretas entre redes de ensino. Este artigo tem como objetivo identificar os fatores escolares que diferenciam municípios de alto e de baixo desempenho no Índice de Desenvolvimento da Educação Básica de 2025, nos anos iniciais do ensino fundamental da rede municipal, entre municípios de contexto socioeconômico semelhante. A pesquisa, de natureza quantitativa e descritiva, integra microdados do Censo Escolar de 2025 e dados de renda do Censo Demográfico de 2022 para os 216 municípios do Maranhão com o índice divulgado. A análise ocorre em dois estágios: primeiro, o algoritmo *K-Means* agrupa os municípios segundo a renda *per capita* e a proporção de moradores em pobreza extrema, resultando em três grupos; depois, dentro dos grupos com amostra suficiente, um classificador *Random Forest* e o teste de Mann-Whitney comparam os municípios do quartil superior e do quartil inferior de desempenho. Nos grupos de renda baixa e intermediária, a proporção de docentes com ensino superior e com licenciatura diferencia os municípios de alto e de baixo desempenho. No grupo intermediário, destaca-se também a presença de quadra esportiva nas escolas. Conclui-se que o aprendizado de máquina aplicado a dados administrativos públicos oferece subsídios para a formulação de políticas educacionais e para a alocação de recursos nos municípios, além de constituir uma estrutura analítica replicável em outras regiões.

Palavras-chave: desempenho educacional; aprendizado de máquina; políticas educacionais.

Abstract

The educational performance of municipalities in Maranhão remains among the lowest in Brazil, and socioeconomic inequality hinders direct comparisons between school systems. This article aims to identify the school factors that distinguish high- and low-performing municipalities in the 2025 Basic Education Development Index, in the early years of elementary education in municipal schools, among municipalities with similar socioeconomic contexts. The study, quantitative and descriptive in nature, integrates

https://doi.org/10.28998/2175-6600.2025v17n39
Artigo publicado sob a Licença Creative Commons 4.0
Submetido em: dd/mm/aaaa
Aceito em: dd/mm/aaaa
Publicado: dd/mm/aaaa
e-Location: xxxxxxx

microdata from the 2025 School Census and income data from the 2022 Demographic Census for the 216 municipalities of Maranhão for which the index was released. The analysis is carried out in two stages: first, the K-Means algorithm groups municipalities according to per capita income and the share of residents in extreme poverty, resulting in three groups; then, within the groups with sufficient sample size, a Random Forest classifier and the Mann-Whitney test compare municipalities in the upper and lower performance quartiles. In the low- and middle-income groups, the share of teachers with higher education and with a teaching degree distinguishes high- from low-performing municipalities. In the middle-income group, the presence of sports courts in schools also stands out. It is concluded that machine learning applied to public administrative data provides support for the design of educational policies and for resource allocation in municipalities, in addition to constituting an analytical framework replicable in other regions.

Keywords: *educational performance; machine learning; educational policies.*

Resumen

El desempeño educativo de los municipios de Maranhão sigue entre los más bajos de Brasil, y la desigualdad socioeconómica dificulta las comparaciones directas entre redes de enseñanza. Este artículo tiene como objetivo identificar los factores escolares que diferencian a los municipios de alto y de bajo desempeño en el Índice de Desarrollo de la Educación Básica de 2025, en los años iniciales de la enseñanza fundamental de la red municipal, entre municipios de contexto socioeconómico similar. La investigación, de naturaleza cuantitativa y descriptiva, integra microdatos del Censo Escolar de 2025 y datos de renta del Censo Demográfico de 2022 para los 216 municipios de Maranhão con el índice divulgado. El análisis se realiza en dos etapas: primero, el algoritmo K-Means agrupa los municipios según la renta per cápita y la proporción de residentes en pobreza extrema, lo que resulta en tres grupos; después, dentro de los grupos con muestra suficiente, un clasificador Random Forest y la prueba de Mann-Whitney comparan los municipios del cuartil superior y del cuartil inferior de desempeño. En los grupos de renta baja e intermedia, la proporción de docentes con educación superior y con licenciatura diferencia los municipios de alto y de bajo desempeño. En el grupo intermedio, destaca también la presencia de canchas deportivas en las escuelas. Se concluye que el aprendizaje automático aplicado a datos administrativos públicos ofrece subsidios para la formulación de políticas educativas y para la asignación de recursos en los municipios, además de constituir un marco analítico replicable en otras regiones.

Palabras-clave: *desempeño educativo; aprendizaje automático; políticas educativas.*

INTRODUÇÃO

A qualidade da educação básica é um dos principais determinantes do desenvolvimento humano e econômico de longo prazo (Hanushek; Woessmann, 2012). No

Brasil, o Índice de Desenvolvimento da Educação Básica (IDEB) monitora o ensino público combinando fluxo escolar e proficiência em língua portuguesa e matemática numa medida comparável entre municípios, estados e redes de ensino (Fernandes, 2007). Apesar dos avanços das últimas duas décadas, as disparidades regionais persistem: estados do Norte e do Nordeste ficam sistematicamente abaixo da média nacional, reflexo de desigualdades estruturais de renda, infraestrutura e serviços públicos (INEP, 2026b).

O Maranhão está entre os casos mais críticos. Com a menor renda domiciliar *per capita* do país no Censo Demográfico 2022 e indicadores educacionais historicamente abaixo da média nacional, o estado concentra municípios em alta vulnerabilidade socioeconômica, onde os obstáculos para melhorar o desempenho escolar superam a capacidade de gestão local (IBGE, 2022b; INEP, 2026b). Isso coloca uma pergunta direta: o que diferencia, dentro de um mesmo patamar de vulnerabilidade, os municípios que sobem no IDEB daqueles que ficam estagnados?

A literatura internacional examinou amplamente a relação entre condições socioeconômicas, infraestrutura escolar, qualificação docente e o desempenho dos estudantes (Rivkin; Hanushek; Kain, 2005; Coleman et al., 1966). No Brasil, estudos com dados do IDEB e do Censo Escolar apontaram formação dos professores, tamanho das turmas e infraestrutura como variáveis relevantes (Vasconcelos et al., 2021; Soares; Xavier, 2013). Análises voltadas especificamente para o Maranhão que isolem fatores intracontextuais (aqueles que operam mesmo quando o contexto socioeconômico é semelhante) são escassas.

Métodos de aprendizado de máquina têm sido aplicados a dados educacionais com resultados promissores, especialmente pela capacidade de lidar com bases administrativas grandes e heterogêneas (Ersozlu; Taheri; Koch, 2024; Kalita et al., 2025; Romero; Ventura, 2020). Algoritmos de agrupamento identificam estruturas nos dados sem categorias predefinidas, o que os torna úteis para segmentar contextos antes de comparações (Faceli; Lorena; Carvalho, 2021; Kalita et al., 2025). Quando combinados com medidas de importância de variáveis e testes não paramétricos, essa abordagem permite identificar os fatores que mais diferenciam grupos de desempenho.

O objetivo geral deste artigo é identificar, entre municípios maranhenses de contexto socioeconômico semelhante, os fatores escolares associados ao desempenho superior no IDEB. Para isso, a análise abrange os 216 municípios maranhenses com

IDEB 2025 divulgado (anos iniciais do ensino fundamental, rede municipal), de um total de 217. No primeiro estágio, os municípios são agrupados por contexto socioeconômico via *K-Means*, usando a renda *per capita* e a proporção de moradores em pobreza extrema, ambas do Censo Demográfico 2022. No segundo, dentro de cada grupo, um *Random Forest Classifier* combinado com o teste de Mann-Whitney identifica quais características escolares e socioeconômicas separam municípios de alto e baixo desempenho. As variáveis analisadas vêm do Censo Escolar 2025: infraestrutura (internet, biblioteca, laboratório de informática, saneamento), qualificação docente e indicadores de fluxo escolar.

O trabalho faz três contribuições principais. Primeiro, propõe e aplica ao contexto específico do Maranhão uma abordagem em dois estágios (segmentação socioeconômica seguida de análise intragrupo). Segundo, identifica os fatores escolares associados ao desempenho superior no IDEB dentro de cada perfil socioeconômico, tanto no grupo de municípios mais vulneráveis quanto no de renda intermediária. Terceiro, disponibiliza um *pipeline* reprodutível para análises similares em outras unidades federativas. Os resultados têm uso direto para gestores e formuladores de políticas que precisam decidir onde concentrar recursos.

O restante do artigo está organizado da seguinte forma: a próxima seção discute a mineração de dados educacionais e os determinantes do desempenho no IDEB; em seguida, os procedimentos metodológicos descrevem as fontes de dados, as variáveis e os dois estágios da análise; a seção de resultados apresenta a segmentação dos municípios, os fatores discriminantes e a discussão desses fatores à luz da literatura; por fim, as considerações finais sintetizam os achados, as limitações e as direções futuras.

ESTADO DA ARTE: MINERAÇÃO DE DADOS EDUCACIONAIS E DETERMINANTES DO DESEMPENHO NO IDEB

Compreender os fatores associados ao desempenho escolar exige articular dois campos de conhecimento: os estudos educacionais sobre os determinantes do desempenho e os métodos computacionais capazes de extrair padrões de grandes bases administrativas. Esta seção reúne essas bases teórico-conceituais, que sustentam as escolhas metodológicas e a interpretação dos resultados do estudo. Inicialmente, discute-se o uso de aprendizado de máquina na análise educacional; em seguida, o

agrupamento não supervisionado como estratégia de segmentação contextual; depois, os estudos brasileiros sobre o IDEB e os condicionantes socioeconômicos desse índice, que evidenciam a escassez de pesquisas voltadas ao Maranhão; por fim, delimita-se a contribuição deste estudo em relação a essa literatura.

Aprendizado de máquina na análise educacional

A mineração de dados educacionais (*Educational Data Mining*, EDM) consolidou-se como área de pesquisa a partir da segunda metade da década de 2000, quando Baker e Yacef (2009) mapearam o estado da arte e identificaram cinco grandes paradigmas: predição, agrupamento, mineração de regras de associação, descoberta com modelos e visualização. Em revisão atualizada, Romero e Ventura (2020) estenderam esse panorama e evidenciaram a predominância de técnicas supervisionadas para tarefas de classificação, especialmente para predizer aprovação, evasão e desempenho em avaliações padronizadas.

No Brasil, a aplicação de algoritmos de aprendizado supervisionado a dados administrativos educacionais ganhou tração com a ampla disponibilização de microdados do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP). Estudos baseados no Censo Escolar e no IDEB aplicaram técnicas de mineração de dados para identificar fatores associados a desempenho e evasão (Colpani, 2018). A capacidade dessas técnicas de lidar com bases de alta dimensionalidade e distribuições assimétricas as torna adequadas a dados como os do Censo Escolar, que apresentam essas características.

Apesar dos avanços, a literatura nacional apresenta três lacunas persistentes:

a) concentração de estudos em municípios das regiões Sul e Sudeste;
b) uso de modelos globais que ignoram a heterogeneidade socioeconômica entre municípios;
c) sub-representação de estados como o Maranhão, onde as condições de vulnerabilidade tornam inadequada a comparação direta com médias nacionais.

Aprendizado não supervisionado para segmentação contextual

O agrupamento (*clustering*) via *K-Means*, proposto por MacQueen (1967), é uma das técnicas de aprendizado não supervisionado mais amplamente utilizadas para seg-

mentação de entidades em grupos homogêneos internamente e heterogêneos entre si. O algoritmo minimiza a inércia intragrupo por meio de iterações de atribuição e recentramento, requerendo apenas a especificação prévia do número de grupos k.

A seleção de k é um desafio clássico. O Método do Cotovelo (*Elbow Method*) avalia a variação da inércia, mas pode ser ambíguo em dados reais. O *Silhouette Score*, introduzido por Rousseeuw (1987), oferece uma métrica mais interpretável: para cada ponto, mede a razão entre a coesão do ponto em relação ao próprio grupo e a separação dele em relação ao *cluster* mais próximo, produzindo um escore entre -1 e 1 (quanto mais alto, mais bem definido o agrupamento).

Em contextos educacionais, o *K-Means* tem sido empregado para segmentar escolas por perfil socioeconômico antes de comparações de desempenho, o que evita confusões entre o efeito do contexto e a eficácia escolar. A visualização dos *clusters* via Análise de Componentes Principais (Abdi; Williams, 2010) permite inspecionar graficamente a qualidade da separação em espaço bidimensional, mesmo quando as variáveis originais têm escalas incomparáveis.

A combinação de *K-Means* para segmentação contextual com testes intragrupo para identificação de fatores discriminantes representa uma abordagem metodológica que preserva a validade interna das comparações: ao comparar municípios dentro do mesmo *cluster* socioeconômico, reduz-se o risco de atribuir a fatores escolares diferenças que são, na verdade, determinadas pela renda ou pela concentração de pobreza.

O IDEB e os fatores socioeconômicos do desempenho escolar no Brasil

O IDEB foi concebido por Fernandes (2007) como uma medida composta que combina taxa de aprovação (fluxo) e proficiência em Língua Portuguesa e Matemática (Saeb/Prova Brasil), resultando em um indicador comparável ao longo do tempo e entre redes de ensino. Soares e Xavier (2013) examinaram os pressupostos estatísticos do índice, alertando para o risco de interpretações simplistas que ignoram a correlação entre fluxo e proficiência.

A relação entre qualificação docente e desempenho escolar é um dos achados mais robustos da literatura internacional. Rivkin, Hanushek e Kain (2005), em análise com dados do Texas, demonstraram que a qualidade do professor é o fator intraescolar com maior impacto sobre o aprendizado dos estudantes, superando infraestrutura e

tamanho de turma. O efeito-escola, por sua vez, foi documentado desde o clássico relatório de Coleman et al. (1966), que identificou nos Estados Unidos que o contexto socioeconômico familiar explica a maior parte da variância no desempenho, enquanto fatores escolares têm efeito residual (embora real e acionável por políticas públicas).

Albernaz, Ferreira e Franco (2002) identificaram que qualidade e equidade no ensino fundamental variam sistematicamente com o nível socioeconômico das escolas, evidenciando que comparações entre municípios de contextos distintos tendem a confundir efeito-escola com efeito-contexto. No Brasil, Vasconcelos et al. (2021) analisaram a relação entre infraestrutura escolar e desempenho usando dados do Censo Escolar e do Saeb, encontrando associação positiva entre presença de laboratórios, bibliotecas e conexão à internet e os resultados dos estudantes. Em revisão da literatura sobre recursos escolares em países em desenvolvimento, Glewwe et al. (2014) confirmaram que qualidade docente e infraestrutura física têm efeitos positivos, mas heterogêneos, sobre o aprendizado, com magnitude dependente do contexto local. Hanushek e Woessmann (2012) demonstraram, em perspectiva comparada entre países, que habilidades cognitivas têm efeito causal sobre crescimento econômico de longo prazo, reforçando a relevância de investigar os determinantes do desempenho escolar em estados de baixa renda, como o Maranhão.

O que foi observado é que análises centradas especificamente no Maranhão são escassas. O estado figurou sistematicamente entre os piores índices nacionais no IDEB das séries iniciais (INEP, 2026b), com média municipal de 5,4 nos anos iniciais na edição mais recente. A concentração de municípios em condições de alta vulnerabilidade socioeconômica torna necessária uma abordagem que controle o contexto antes de comparar desempenhos, o que a literatura geral sobre IDEB raramente faz de forma sistemática.

Contribuição deste estudo à literatura

O presente trabalho distingue-se da literatura existente por três características:

a) adota uma abordagem em dois estágios que separa explicitamente a segmentação socioeconômica da análise de fatores intracontextuais;
b) aplica essa lógica exclusivamente aos municípios maranhenses (216 dos 217, os que têm IDEB 2025 divulgado), contexto sub-representado na literatura de EDM;

c) combina importâncias do *Random Forest* (Breiman, 2001) com testes de Mann-Whitney (Mann; Whitney, 1947) para obter tanto uma ordenação de variáveis quanto evidência estatística de que as diferenças observadas não são atribuíveis ao acaso.

A análise intragrupo (restrita a municípios com contexto socioeconômico semelhante) responde a uma pergunta que modelos globais não conseguem: quais fatores diferem, de forma consistente e estatisticamente significativa, entre municípios que superam e que ficam abaixo do desempenho esperado dado o contexto socioeconômico em que se encontram? Essa pergunta tem implicação direta para políticas educacionais, pois identifica alvos de intervenção que operam mesmo sob restrições socioeconômicas.

PROCEDIMENTOS METODOLÓGICOS

Trata-se de uma pesquisa de abordagem quantitativa, de caráter descritivo e exploratório, baseada exclusivamente em dados secundários de acesso público. O *pipeline* analítico segue as etapas do processo CRISP-DM (*Cross-Industry Standard Process for Data Mining*) (Shearer, 2000), adaptado ao contexto de análise de dados educacionais: compreensão do domínio, coleta e preparação dos dados, modelagem e avaliação dos resultados. Dentro desse processo, a análise é conduzida em dois estágios sequenciais, descritos a seguir, após a apresentação das fontes de dados, das variáveis e do tratamento dos dados.

Fontes de dados

Este estudo integra três bases de dados públicas referentes aos municípios do Maranhão:

- **IDEB EFAI 2025 (INEP).** O Índice de Desenvolvimento da Educação Básica dos anos iniciais do ensino fundamental (EFAI), divulgado pelo INEP (INEP, 2026b), é calculado conforme a metodologia proposta por Fernandes (2007): combina a taxa de aprovação escolar (fluxo) com a proficiência média em Língua Portuguesa e Matemática aferida pelo Sistema de Avaliação da Educação Básica (Saeb). Para este estudo, utilizou-se a edição 2025 da rede municipal, que cobriu 216 dos 217 municípios do estado; Nova Iorque não teve o indicador di-

vulgado nesta edição, porque o INEP não divulgou as notas do município no Saeb.

- **Censo Escolar 2025 (INEP).** Os microdados do Censo Escolar (INEP, 2026a) fornecem informações em nível de escola sobre infraestrutura física (internet, biblioteca/sala de leitura, laboratório de informática, quadra esportiva, abastecimento de água e esgotamento sanitário) e sobre o corpo docente. Para as variáveis de formação docente nos anos iniciais do ensino fundamental (EF), utilizou-se a Tabela 2.29 da Sinopse Estatística da Educação Básica 2025 (INEP, 2026c), que fornece o número de docentes EFAI por nível de formação de modo consistente entre numerador e denominador, eliminando o viés de dupla contagem presente nos microdados brutos.
- **Censo Demográfico 2022 (IBGE).** Do Censo Demográfico 2022 do Instituto Brasileiro de Geografia e Estatística (IBGE) foram extraídas, por município, duas medidas de renda domiciliar *per capita*: o valor do rendimento nominal médio mensal domiciliar *per capita* (Sidra, tabela 10295) (IBGE, 2022b) e a distribuição dos moradores por classes de rendimento domiciliar *per capita* em salários mínimos (Sidra, tabela 10296) (IBGE, 2022a). Por ser um recenseamento, e não uma pesquisa amostral, o Censo Demográfico é a única fonte de renda com cobertura individual para todos os 217 municípios do estado.

Variáveis de segmentação socioeconômica

A segmentação dos municípios utiliza duas variáveis, ambas do Censo Demográfico 2022:

- **Renda *per capita***: rendimento nominal médio mensal domiciliar *per capita*, em reais. Mede o *nível* de recursos econômicos disponíveis no município.
- **Pobreza extrema**: percentual de moradores em domicílios com rendimento *per capita* de até 1/4 do salário mínimo ou sem rendimento. Mede a *concentração* de famílias em privação severa. O corte de 1/4 do salário mínimo é o critério de miserabilidade adotado pela Lei Orgânica da Assistência Social para o Benefício de Prestação Continuada (BRASIL, 1993), o que o torna uma linha de referência institucional reconhecida no Brasil.

A escolha dessas duas variáveis apoia-se em três argumentos. O primeiro é teórico: o nível socioeconômico é o preditor mais consistente do desempenho escolar

desde Coleman et al. (1966), e a meta-análise de Sirin (2005) mostra que essa associação é mais forte quando medida em unidades agregadas, como escolas e distritos, do que no nível individual. Controlar o contexto socioeconômico dos municípios antes de comparar seu desempenho é, portanto, condição para não atribuir a fatores escolares diferenças que decorrem da renda (Albernaz; Ferreira; Franco, 2002). O segundo argumento é que as duas medidas captam aspectos complementares da renda: a média é sensível a rendas altas concentradas em poucos domicílios, enquanto a proporção de moradores em pobreza extrema descreve a base da distribuição. Dois municípios com renda média semelhante podem ter proporções bastante diferentes de famílias em privação severa. O terceiro argumento é de consistência temporal: ambas vêm do mesmo recenseamento, de 2022, o mais recente com desagregação municipal completa.

As duas variáveis são correlacionadas (coeficiente de Pearson de $-0{,}87$ entre os 216 municípios analisados), o que é esperado, dado que ambas derivam da distribuição de renda. A contribuição de cada uma para a partição é avaliada no Estágio 1 por meio de um teste de ablação, que refaz a clusterização sem cada variável e mede o quanto a partição se altera.

Variáveis

O conjunto completo de variáveis é organizado em quatro grupos, descritos no quadro 1.

Quadro 1 – Variáveis utilizadas na análise

Variável	Fonte	Definição operacional
Segmentação socioeconômica		
Renda *per capita*	Censo 2022	Rendimento domiciliar *per capita* médio mensal municipal (R$)
Pobreza extrema	Censo 2022	% de moradores com rendimento domiciliar *per capita* de até 1/4 do salário mínimo ou sem rendimento
Infraestrutura escolar		
% escolas com internet	Censo 2025	Proporção de escolas municipais com acesso à internet
% escolas com biblioteca/sala de leitura	Censo 2025	Proporção com biblioteca, biblioteca-sala de leitura ou sala de leitura
% escolas com laboratório de informática	Censo 2025	Proporção com laboratório de informática
% escolas com quadra esportiva	Censo 2025	Proporção com quadra de esportes
% escolas com água adequada	Censo 2025	Proporção com água potável ou rede pública
% escolas com esgoto adequado	Censo 2025	Proporção com rede pública ou fossa séptica
Qualificação docente		
% docentes EFAI com ensino superior	Sinopse 2025	Proporção de docentes dos anos iniciais com graduação
% docentes EFAI com licenciatura	Sinopse 2025	Proporção de docentes dos anos iniciais com licenciatura
Fluxo e distorção		
Média de alunos/turma (educação básica)	Censo 2025	Total de matrículas da educação básica dividido pelo total de turmas da educação básica
Média de alunos/turma (EF)	Censo 2025	Total de matrículas no EF dividido pelo total de turmas do EF
Proxy distorção idade-série	Censo 2025	% matrículas com 15 anos ou mais na educação básica municipal
% turmas com correção de fluxo (EF anos finais)	Censo 2025	Proporção de turmas de correção de fluxo entre as turmas do EF anos finais

Fonte: elaboração própria (2026).

Coleta e pré-processamento dos dados

O *pipeline* de ingestão (`ingest.py`) automatiza a carga das três fontes descritas anteriormente. Para o IDEB, lê a planilha oficial do INEP e filtra os municípios maranhenses da rede municipal, tratando os códigos de não divulgação (ND, ND*, (*),

(**)) como valores ausentes. Para o Censo Escolar 2025, o Inep passou a distribuir os microdados em quatro tabelas relacionais por domínio (escola, docente, matrícula e turma), cada uma agregada por escola; o *pipeline* lê as quatro em formato CSV (*encoding* latin-1, separador ponto-e-vírgula), filtra as escolas de dependência municipal no Maranhão (TP_DEPENDENCIA = 3) e as combina pela chave de identificação da escola (CO_ENTIDADE). Para os docentes dos anos iniciais, usa exclusivamente a Tabela 2.29 da Sinopse Estatística 2025 (planilha em formato XLSX), garantindo que numerador (docentes com superior) e denominador (total de docentes EFAI) venham da mesma fonte. Os dados de renda e de pobreza extrema vêm de cópias locais das respostas da API pública do Sidra/IBGE (tabelas 10295 e 10296), salvas no repositório para garantir a reprodutibilidade.

As variáveis de infraestrutura são agregadas ao nível municipal como proporção de escolas com cada atributo presente. As variáveis de docentes, como percentual sobre o total de docentes EFAI do município. As variáveis de fluxo, como médias ou proporções sobre o total de matrículas e turmas municipais.

O *pipeline* de transformação (`transform.py`) aplica as seguintes operações:

- **IDEB:** substituição de valores especiais por `NaN`, conversão de vírgula para ponto decimal, remoção de colunas redundantes (notas separadas de língua portuguesa e matemática, já incorporadas na nota média).
- **Censo Escolar:** remoção de colunas completamente vazias, conversão de colunas de quantidade para inteiro, normalização do código municipal para 7 dígitos.
- **IBGE:** conversão da renda *per capita* e da pobreza extrema para numérico; a fonte já chega limpa, sem linhas de totalização.
- **Integração:** junção das três bases pela chave `NO_MUNICIPIO` (normalizada), com junção à esquerda a partir do IDEB. Resultado: 217 municípios com renda, pobreza extrema e Censo Escolar completos; 216 com o indicador do IDEB.

Após a integração, não há valores ausentes nas variáveis de *cluster* (renda *per capita* e pobreza extrema). A variável-alvo (IDEB) tem um valor ausente (Nova Iorque). Como o município não pode ser classificado por desempenho, ele é excluído dos dois estágios, e a análise segue com 216 municípios. As variáveis explicativas não têm valores ausentes; municípios sem turmas de correção de fluxo aparecem com proporção zero nessa variável.

Estágio 1: segmentação socioeconômica por *K-Means*

O *K-Means* (MacQueen, 1967) agrupa os 216 municípios com base na renda *per capita* e na pobreza extrema. Antes da clusterização, as duas variáveis são normalizadas via `RobustScaler`, que centraliza na mediana e escala pelo intervalo interquartil, reduzindo a influência de municípios atípicos, isto é, com renda *per capita* muito acima e pobreza extrema muito abaixo dos demais municípios do estado, como São Luís e Imperatriz, que, por esses valores extremos, poderiam distorcer a formação dos grupos.

O algoritmo é executado com $k \in \{2, \ldots, 10\}$, inicialização `k-means++` e `n_init = 10`. O número de *clusters* é escolhido pelo *Silhouette Score* médio (Rousseeuw, 1987), que mede a separação relativa dos grupos, e confirmado pela estabilidade da partição, avaliada por *bootstrap* de 25 iterações com 80% dos dados, seguindo a configuração de referência de Ben-Hur, Elisseeff e Guyon (2002), com o *Adjusted Rand Index* (ARI) como métrica de concordância. A curva de inércia (Método do Cotovelo) é apresentada como apoio visual. A contribuição de cada variável é medida por ablação: a clusterização é refeita sem a variável, e o ARI entre a nova partição e a original indica o quanto a partição depende dela.

A visualização dos *clusters* é feita via Análise de Componentes Principais (PCA) (Abdi; Williams, 2010) com duas componentes, permitindo inspeção gráfica da separação em espaço reduzido.

Estágio 2: análise intragrupo

Dentro de cada *cluster* com amostra suficiente, os municípios são divididos em dois grupos por desempenho: *alto IDEB*, formado pelo quartil superior ($\geq Q_{75}$), e *baixo IDEB*, formado pelo quartil inferior ($\leq Q_{25}$). Os municípios do intervalo central são excluídos da análise comparativa, o que aumenta o contraste entre os grupos e reduz o ruído.

Para identificar quais variáveis diferenciam os dois grupos, aplica-se um *Random Forest Classifier* (Breiman, 2001) com 500 árvores, `class_weight='balanced'` e `min_samples_leaf=3`. A importância de cada variável é calculada pelo critério de redução média de impureza (*Mean Decrease in Impurity*), que quantifica a contribuição de cada variável para separar os dois grupos ao longo das 500 árvores. Em paralelo, o

teste de Mann-Whitney (Mann; Whitney, 1947) bicaudal verifica se as distribuições das variáveis diferem significativamente entre os grupos alto e baixo IDEB. São utilizados três limiares de significância: $\alpha = 0{,}01$ (***), $\alpha = 0{,}05$ (**) e $\alpha = 0{,}10$ (*).

A combinação de importâncias do *Random Forest* com os p-valores do Mann-Whitney permite distinguir variáveis com alta relevância preditiva daquelas com diferença estatisticamente sustentada: uma variável é considerada fator discriminante relevante quando apresenta alta importância *e* diferença significativa ao nível de $\alpha = 0{,}10$.

Uso de ferramentas de inteligência artificial generativa

Este trabalho utilizou ferramentas de inteligência artificial generativa em três etapas do processo de pesquisa:

- **Revisão de código.** A primeira etapa do trabalho corresponde às fases de ciência de dados com Python. A ferramenta Claude (Anthropic) foi utilizada para correção e revisão dos *scripts* Python do *pipeline* de análise (`ingest.py`, `transform.py` e os módulos de modelagem), com validação e aprovação da autoria em cada alteração sugerida.
- **Revisão e edição de texto.** Na fase de produção escrita deste artigo, o Claude (Anthropic) e o ChatGPT (OpenAI) foram utilizados para revisar a redação e a clareza das seções. O texto original, a estrutura argumentativa e as interpretações dos resultados são de responsabilidade exclusiva da autoria.
- **Busca e validação de referências bibliográficas.** Claude (Anthropic) e SciSpace AI Research (PubGenius Inc.) foram utilizados para identificar trabalhos potencialmente relevantes e verificar metadados de citações. Cada referência foi conferida nas fontes originais antes da inclusão.

O uso dessas ferramentas está declarado em conformidade com as diretrizes de integridade científica do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), que exigem a identificação explícita das ferramentas de inteligência artificial generativa utilizadas, as finalidades de cada uma e a responsabilização integral do pesquisador pelos resultados produzidos.

RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados obtidos com a aplicação dos dois estágios descritos nos procedimentos metodológicos e os discute à luz da literatura. Inicialmente, caracterizam-se o contexto socioeconômico e educacional do Maranhão e a distribuição do IDEB entre os municípios, o que evidencia a variabilidade de desempenho que motiva a investigação. Em seguida, apresentam-se a segmentação socioeconômica obtida com o *K-Means* e, dentro de cada grupo com amostra suficiente, os fatores que diferenciam os municípios de alto e de baixo desempenho. Por fim, esses achados são confrontados com os estudos sobre o IDEB e traduzidos em implicações para as políticas educacionais.

Contexto socioeconômico e educacional do Maranhão

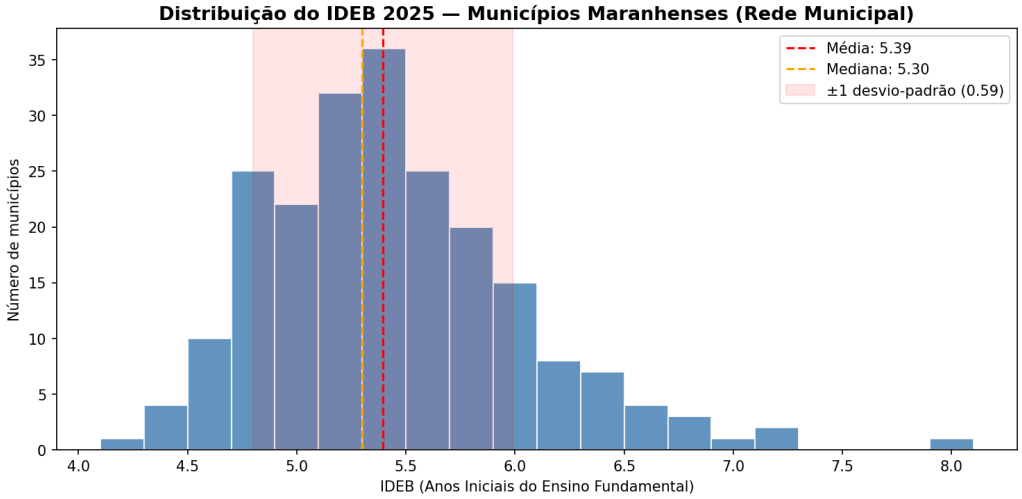
O Maranhão é o segundo maior estado do Nordeste em extensão territorial e um dos mais populosos, com 217 municípios distribuídos em cinco mesorregiões. No Censo Demográfico 2022, o estado tem a menor renda domiciliar *per capita* entre as 27 unidades da federação (R$ 899,87, contra R$ 1.638,06 no Brasil) e a segunda maior proporção de moradores em pobreza extrema, com rendimento *per capita* de até 1/4 do salário mínimo ou sem rendimento (26,6%, contra 13,3% no Brasil) (IBGE, 2022b,a). Entre os municípios, a desigualdade também é expressiva: a renda *per capita* mediana é de R$ 667, e a proporção de moradores em pobreza extrema varia de 11,2% a 60,3%. Esse contexto reflete-se nos resultados educacionais: na edição 2025 do IDEB, a média dos 216 municípios maranhenses com indicador divulgado nos anos iniciais da rede municipal ficou em 5,39 (desvio-padrão de 0,59), com metade dos municípios abaixo de 5,30.

A questão central desta investigação é identificar, entre municípios com contexto socioeconômico semelhante, quais fatores escolares estão associados ao desempenho superior no IDEB. Respondê-la exige, primeiro, neutralizar o efeito do contexto por meio de uma segmentação explícita e, depois, comparar, dentro de cada grupo, os municípios de alto e baixo desempenho.

Distribuição do IDEB entre os municípios

A distribuição do IDEB dos 216 municípios maranhenses com indicador divulgado é apresentada no gráfico 1. A distribuição é aproximadamente unimodal, ligeiramente assimétrica à direita, com média de 5,39 (desvio-padrão de 0,59), mediana de 5,30, mínimo de 4,10 e máximo de 8,10.

Gráfico 1 – Distribuição do IDEB 2025 dos municípios maranhenses – rede municipal, anos iniciais do ensino fundamental



Nota: linha vermelha tracejada: média (5,39); linha laranja tracejada: mediana (5,30); faixa vermelha: intervalo de ± 1 desvio-padrão.

Fonte: elaboração própria com base em INEP (2026b).

A amplitude de 4,00 pontos (4,10 a 8,10) é expressiva dado que o IDEB varia de 0 a 10. Isso indica que, mesmo dentro do Maranhão (estado homogeneamente vulnerável em termos nacionais), existe variabilidade interna substancial que justifica investigar os fatores associados aos destaques positivos.

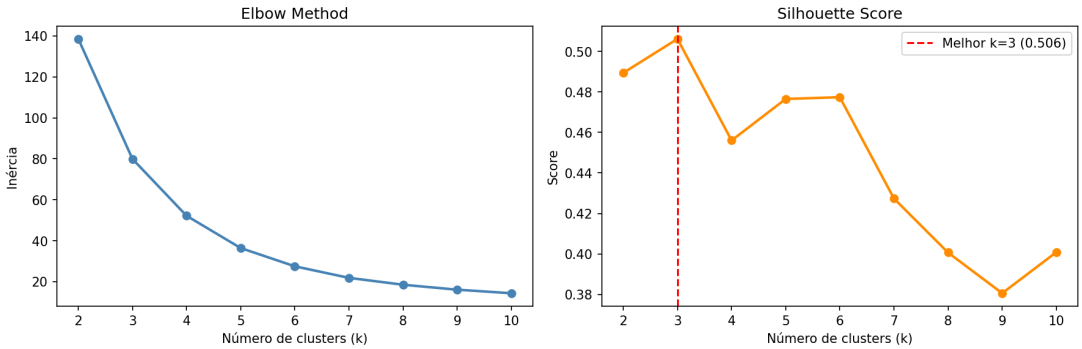
Segmentação socioeconômica dos municípios

A clusterização *K-Means* foi aplicada sobre a *renda per capita* e a *pobreza extrema* (normalizadas via RobustScaler), testando $k \in \{2, \ldots, 10\}$, conforme descrito nos procedimentos metodológicos.

No gráfico 2, são apresentadas as curvas de inércia (cotovelo) e de *Silhouette Score*. O *Silhouette Score* atinge o valor máximo em $k = 3$ (0,506), acima de $k = 2$

(0,489) e de $k = 4$ (0,456). A estabilidade *bootstrap* confirma a escolha: o ARI médio é 0,812 em $k = 3$, contra 0,744 em $k = 2$ e 0,704 em $k = 4$. Os dois critérios apontam, portanto, para a mesma partição, que é ao mesmo tempo a mais bem separada e a mais estável sob reamostragem entre as testadas. A curva de inércia decresce de forma gradual e não oferece, por si só, um critério adicional.

Gráfico 2 – Curvas de inércia e de *Silhouette Score* para $k \in \{2, \ldots, 10\}$

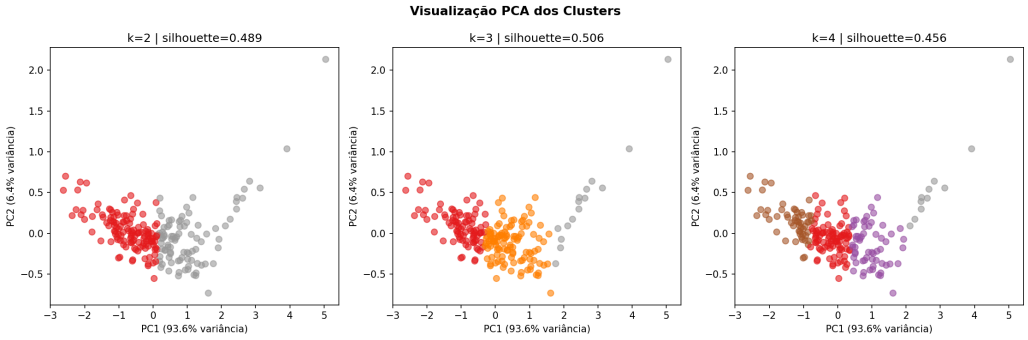


Nota: à esquerda, inércia; à direita, *Silhouette Score*. A linha vertical vermelha indica o k ótimo segundo o *Silhouette Score*.

Fonte: dados da pesquisa (2026).

No gráfico 3, são exibidos os *clusters* projetados nas duas primeiras componentes principais (a primeira componente, PC1, explica 93,6% da variância; a segunda, PC2, explica 6,4%). A predominância da primeira componente reflete a correlação entre as duas variáveis de segmentação: os municípios se distribuem essencialmente ao longo de um eixo de renda, no qual renda média alta e pobreza extrema baixa caminham juntas.

Gráfico 3 – Projeção dos *clusters* de municípios maranhenses nas duas primeiras componentes principais para $k \in \{2, 3, 4\}$



Fonte: dados da pesquisa (2026).

O teste de ablação indica que as duas variáveis contribuem para a partição, com peso maior para a renda média. Refazendo a clusterização sem a renda *per capita*, a concordância com a partição original cai para um ARI de 0,379; sem a pobreza extrema, o ARI é de 0,688. A pobreza extrema, portanto, não é redundante: sua retirada reclassifica parte relevante dos municípios, o que confirma que ela acrescenta à renda média a informação sobre a base da distribuição de renda.

Os três *clusters* obtidos são denominados pelo critério de renda média:

- ***Cluster* vulnerável** (n = 88): renda *per capita* média de R$ 555,84, 41,8% dos moradores em pobreza extrema, IDEB médio de 5,29.
- ***Cluster* intermediário** (n = 113): renda *per capita* média de R$ 732,06, 27,5% dos moradores em pobreza extrema, IDEB médio de 5,42.
- ***Cluster* de alta renda** (n = 15): renda *per capita* média de R$ 1.082,44, 15,3% dos moradores em pobreza extrema, IDEB médio de 5,78. Reúne a capital e os principais polos regionais do estado: São Luís, São José de Ribamar, Paço do Lumiar, Imperatriz, Timon, Açailândia, Balsas, Santa Inês, Pedreiras, Presidente Dutra, Porto Franco, Estreito, Carolina, Fortaleza dos Nogueiras e Itinga do Maranhão.

O *cluster* de alta renda, com 15 municípios, não tem amostra suficiente para a análise intragrupo por quartis, que resultaria em quatro ou cinco municípios em cada extremo. A análise comparativa é, portanto, conduzida nos *clusters* vulnerável e intermediário, que juntos reúnem 201 dos 216 municípios analisados.

Os percentuais médios das variáveis de infraestrutura e de formação docente acompanham o gradiente de renda. A *conectividade à internet* está presente em 83,8% das escolas municipais do *cluster* vulnerável, em 89,0% das do intermediário e em 94,3% das de alta renda. O acesso a *biblioteca ou sala de leitura* é baixo nos dois primeiros grupos (15,8% e 19,3%) e mais que dobra no de alta renda (38,7%). A proporção média de *docentes EFAI com ensino superior* é de 55,9%, 64,0% e 79,1%, respectivamente, diferença que antecipa uma das hipóteses testadas no estágio intragrupo.

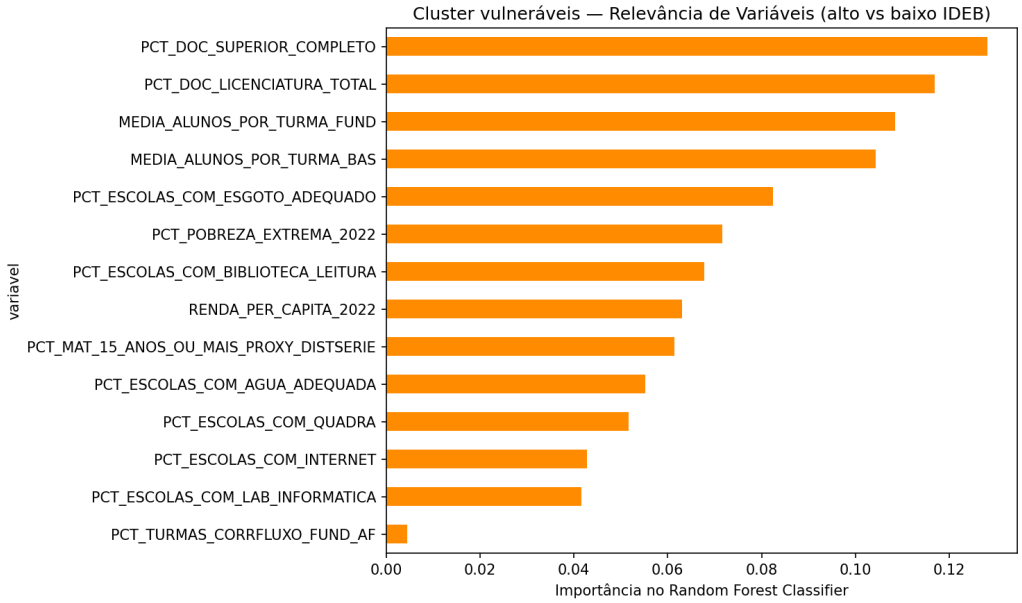
Fatores discriminantes no *cluster* vulnerável

Dentro do *cluster* vulnerável (n = 88), os 24 municípios que se encontram no quartil superior de IDEB (alto, $\geq 5{,}60$, média 6,08) são comparados aos 23 do quartil

inferior (baixo, $\leq 4{,}80$, média 4,61). A diferença média de 1,47 ponto de IDEB entre os grupos é substancial: equivale a quase dois desvios-padrão e meio da distribuição estadual.

No gráfico 4, apresentam-se as importâncias do *Random Forest Classifier* para o *cluster* vulnerável. As oito variáveis de maior importância são, em ordem decrescente: *% docentes com ensino superior* (0,128), *% docentes com licenciatura* (0,117), *média de alunos por turma no ensino fundamental* (0,108), *média de alunos por turma na educação básica* (0,104), *% escolas com esgoto adequado* (0,082), *pobreza extrema* (0,072), *% escolas com biblioteca/sala de leitura* (0,068) e *renda per capita* (0,063).

Gráfico 4 – Importância das variáveis no *Random Forest Classifier* para diferenciar municípios de alto e baixo IDEB no *cluster* vulnerável



Fonte: dados da pesquisa (2026).

O teste de Mann-Whitney complementa a análise ao indicar quais variáveis apresentam diferenças estatisticamente significativas entre os grupos. Na tabela 1, resumem-se os resultados para as variáveis com $p < 0{,}10$; as diferenças entre proporções são expressas em pontos percentuais (p.p.).

Tabela 1 – Variáveis com diferença significativa entre municípios de alto e baixo IDEB no *cluster* vulnerável (Mann-Whitney bicaudal)

Variável	Média alto	Média baixo	Δ	p-valor
% doc. com ensino superior	60,6%	49,0%	+11,6 p.p.	0,039**
% doc. com licenciatura	59,1%	47,8%	+11,4 p.p.	0,049**

Nota: ** $p < 0{,}05$.

Fonte: dados da pesquisa (2026).

A formação docente é o único fator que diferencia de forma estatisticamente significativa os municípios de alto e baixo IDEB no *cluster* vulnerável, e as duas variáveis que a medem também lideram a importância no *Random Forest*. Os municípios vulneráveis de alto IDEB têm, em média, 11,6 p.p. a mais de *docentes com ensino superior* e 11,4 p.p. a mais com *licenciatura* do que os de baixo IDEB. Esse achado é convergente com a literatura internacional: Rivkin, Hanushek e Kain (2005) demonstraram que a qualidade do professor é o fator intraescolar de maior impacto sobre o aprendizado, e estudos nacionais também apontam a formação docente como variável central nos resultados do IDEB (Vasconcelos et al., 2021).

A renda *per capita* e a pobreza extrema não diferenciam os grupos de alto e baixo IDEB dentro desse *cluster* ($p = 0{,}322$ e $p = 0{,}463$). Esse resultado indica que a segmentação cumpriu seu papel: dentro do grupo, o contexto socioeconômico é homogêneo o bastante para que as diferenças de desempenho não sejam atribuíveis à renda. As variáveis de tamanho de turma aparecem entre as mais importantes no *Random Forest*, mas sem diferença significativa no teste de Mann-Whitney; como a importância no *Random Forest* tende a favorecer variáveis contínuas, essa importância isolada não deve ser lida como evidência de associação.

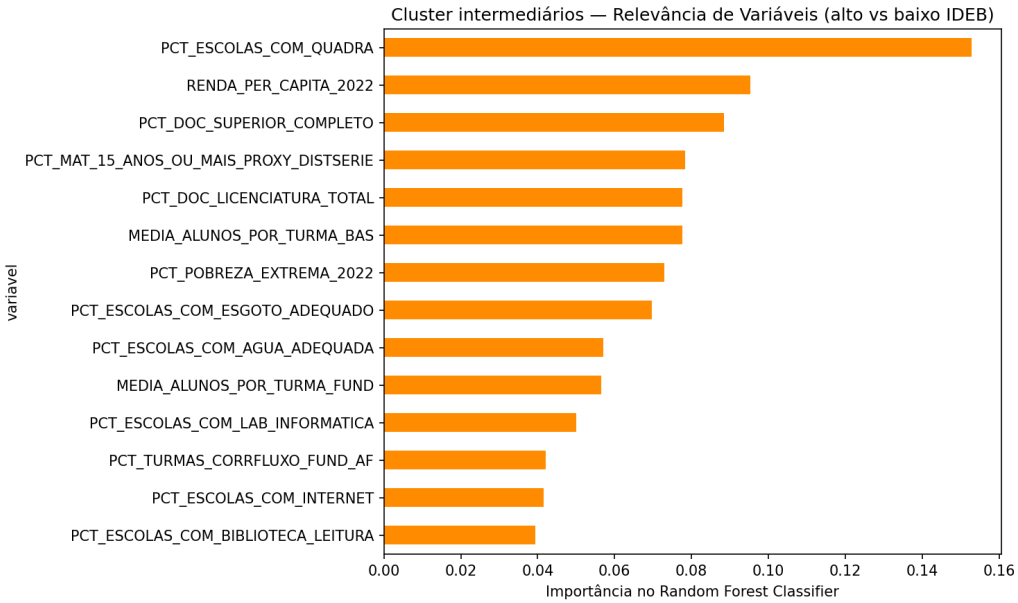
Fatores discriminantes no *cluster* intermediário

Dentro do *cluster* intermediário (n = 113), os 34 municípios do quartil superior de IDEB (alto, $\geq 5{,}70$, média 6,07) são comparados aos 29 do quartil inferior (baixo, $\leq 5{,}00$, média 4,81).

No gráfico 5, apresentam-se as importâncias do *Random Forest Classifier* para esse *cluster*. As oito variáveis de maior importância são, em ordem decrescente: *% escolas com quadra esportiva* (0,153), *renda per capita* (0,095), *% docentes com ensino superior* (0,089), *proxy de distorção idade-série* (0,078), *% docentes com licencia-*

tura (0,078), *média de alunos por turma na educação básica* (0,078), *pobreza extrema* (0,073) e *% escolas com esgoto adequado* (0,070).

Gráfico 5 – Importância das variáveis no *Random Forest Classifier* para diferenciar municípios de alto e baixo IDEB no *cluster* intermediário



Fonte: dados da pesquisa (2026).

A tabela 2 resume as variáveis com diferença estatisticamente significativa ($p < 0{,}10$) entre os municípios de alto e baixo IDEB nesse *cluster*.

Tabela 2 – Variáveis com diferença significativa entre municípios de alto e baixo IDEB no *cluster* intermediário (Mann-Whitney bicaudal)

Variável	Média alto	Média baixo	Δ	p-valor
% escolas com quadra	12,9%	5,4%	+7,5 p.p.	0,004***
% turmas corr. de fluxo (EF-AF)	0,90%	0,07%	+0,8 p.p.	0,007***
% doc. com ensino superior	69,2%	58,1%	+11,1 p.p.	0,047**
% doc. com licenciatura	67,4%	57,4%	+10,1 p.p.	0,051*
Renda *per capita* (R$)	753,15	719,13	+34,02	0,081*

Nota: *** $p < 0{,}01$; ** $p < 0{,}05$; * $p < 0{,}10$.

Fonte: dados da pesquisa (2026).

A formação docente reaparece no *cluster* intermediário com magnitude semelhante à observada entre os municípios vulneráveis: 11,1 p.p. a mais de *docentes com ensino superior* ($p = 0{,}047$) e 10,1 p.p. a mais com *licenciatura* ($p = 0{,}051$) nos municípios de IDEB alto. A repetição do achado em dois grupos socioeconômicos distintos

reforça que a associação entre formação docente e desempenho não é um artefato de um contexto específico.

A *quadra esportiva* é a variável de maior importância no *Random Forest* e a de diferença mais significativa no teste de Mann-Whitney ($p = 0{,}004$): as escolas com quadra são mais que o dobro nos municípios de IDEB alto (12,9% contra 5,4%). A presença de quadra pode sinalizar, mais do que um efeito direto da atividade esportiva, um padrão mais amplo de investimento em infraestrutura escolar, e a análise não permite distinguir entre essas leituras. A proporção de turmas de correção de fluxo nos anos finais também é maior nos municípios de IDEB alto ($p = 0{,}007$), mas os valores são pequenos (menos de 1% das turmas), e o resultado, isoladamente, não permite inferir se a oferta de correção de fluxo é causa ou consequência do desempenho.

Diferentemente do *cluster* vulnerável, a renda *per capita* ainda apresenta diferença marginal entre os grupos ($p = 0{,}081$), de R$ 34 em média, o que indica alguma heterogeneidade residual de renda no *cluster* intermediário, o maior dos três.

Diálogo com a literatura sobre o IDEB

Os achados dialogam com a literatura de maneiras específicas. A centralidade da qualificação docente, observada nos dois *clusters* analisados com diferenças de 10 a 12 p.p. entre municípios de alto e baixo IDEB, é convergente com o achado seminal de Rivkin, Hanushek e Kain (2005) no contexto norte-americano e com estudos brasileiros que identificaram formação superior como fator associado ao IDEB (Vasconcelos et al., 2021). A ausência de diferença significativa de renda e de pobreza extrema dentro do *cluster* vulnerável é consistente com a tese de Coleman et al. (1966) de que o contexto socioeconômico explica a maior parte da variação do desempenho: uma vez neutralizado esse contexto, emergem os fatores escolares, que têm efeito real, embora secundário.

Em relação à literatura de mineração de dados educacionais, o trabalho contribui com uma aplicação metodológica que supera duas limitações frequentes: o uso de modelos globais que ignoram a heterogeneidade socioeconômica entre municípios e a concentração de estudos EDM nas regiões Sul e Sudeste (Baker; Yacef, 2009; Romero; Ventura, 2020). A abordagem em dois estágios é replicável para outros estados e pode ser adaptada a outros níveis de ensino (anos finais do ensino fundamental, ensino médio) ou outras medidas de desempenho.

Quanto ao IDEB como métrica, os pressupostos estatísticos identificados por Soares e Xavier (2013) (especialmente a correlação entre fluxo e proficiência) não invalidam a análise, mas sugerem cautela na interpretação: municípios com IDEB elevado podem estar priorizando aprovação em detrimento da proficiência. A combinação de variáveis de fluxo (*distorção idade-série*, *correção de fluxo*) com os indicadores estruturais na mesma análise ajuda a mitigar parcialmente esse risco.

Implicações para as políticas educacionais

Os resultados têm implicações para gestores municipais e formuladores de políticas educacionais do Maranhão:

- **Formação e habilitação docente (*clusters* vulnerável e intermediário).** A diferença de 11 a 12 p.p. na proporção de *docentes com ensino superior* entre municípios de alto e baixo IDEB, repetida nos dois grupos analisados, torna programas de formação continuada e de indução à licenciatura específica candidatos plausíveis de política pública em todo o estado, e não apenas nos municípios mais pobres. A análise associativa não permite, porém, quantificar o impacto esperado. Políticas estaduais e federais de financiamento de graduação a distância para docentes em exercício, como o Programa Nacional de Formação de Professores da Educação Básica (Parfor), são alvos naturais de expansão.
- **Infraestrutura escolar (*cluster* intermediário).** A quadra esportiva ($p = 0{,}004$) destaca-se como fator discriminante nos municípios de renda intermediária, sugerindo que, nesse grupo, o investimento em infraestrutura física complementar é candidato a priorização no monitoramento e na alocação orçamentária, ainda que a análise não permita estimar o retorno esperado desse investimento.

CONSIDERAÇÕES FINAIS

Este trabalho propôs e aplicou uma abordagem em dois estágios (segmentação socioeconômica por *K-Means* seguida de análise intragrupo com *Random Forest Classifier* e teste de Mann-Whitney) aos 216 municípios maranhenses com dados no IDEB 2025 (anos iniciais do ensino fundamental, rede municipal). A segmentação, feita com a renda *per capita* e a proporção de moradores em pobreza extrema do Censo Demo-

gráfico 2022, produziu três grupos (vulnerável, intermediário e de alta renda), partição escolhida tanto pelo *Silhouette Score* quanto pela estabilidade *bootstrap*. Nos dois grupos com amostra suficiente para a análise intragrupo, a *formação docente* (proporção de professores com ensino superior e com licenciatura) diferencia os municípios de alto e baixo desempenho, com diferenças de 10 a 12 pontos percentuais. No grupo intermediário, a presença de quadra esportiva também se destaca. Isso atende ao objetivo de isolar fatores escolares que operam mesmo sob contexto socioeconômico semelhante.

Este estudo apresenta cinco limitações relevantes que devem ser consideradas na interpretação dos resultados.

- **Segmentação restrita à dimensão de renda.** As duas variáveis de segmentação descrevem a distribuição de renda, e são correlacionadas entre si ($-0{,}87$). Dimensões socioeconômicas não monetárias, como escolaridade dos adultos e condições de saúde, não entram na segmentação. A ablação mostra que a pobreza extrema acrescenta informação à renda média, mas a partição ainda é essencialmente ordenada ao longo de um eixo de renda.
- ***Cluster* de alta renda fora da análise intragrupo.** Os 15 municípios de alta renda, que reúnem a capital e os principais polos regionais, não têm amostra suficiente para a comparação por quartis. Os fatores associados ao desempenho nesse grupo permanecem sem investigação; análises em nível de escola, e não de município, permitiriam estudá-lo.
- **Causalidade.** A análise é descritiva e associativa, não causal. Não é possível afirmar que *formação docente* ou *infraestrutura escolar* causam IDEB mais alto. Municípios com gestão mais eficaz tendem a contratar mais docentes qualificados e a obter melhores resultados ao mesmo tempo, tornando difícil separar o efeito de cada variável do efeito da qualidade de gestão municipal. Estudos de painel com variação longitudinal do IDEB permitiriam estimativas mais robustas do efeito causal.
- **Comparações múltiplas e tamanho das amostras.** Em cada *cluster* foram realizados catorze testes de Mann-Whitney sem correção para comparações múltiplas, sobre grupos de 23 a 34 municípios. Os achados com $p < 0{,}01$ (quadra esportiva e correção de fluxo no *cluster* intermediário) são os mais robustos a essa questão; os demais, inclusive os de formação docente, devem ser lidos à luz da consistência entre os dois *clusters*, que é o que os sustenta.

- **Variáveis de gestão escolar ausentes.** O Censo Escolar não captura variáveis de processos pedagógicos, gestão, clima escolar ou engajamento familiar, que são mediadores importantes do desempenho. A inclusão de dados de avaliações de escola (como avaliações próprias do estado) em pesquisas futuras poderia complementar o diagnóstico aqui apresentado.

Apesar dessas limitações, a abordagem em dois estágios mostrou-se útil para orientar a alocação de recursos educacionais em diferentes perfis socioeconômicos, ao apontar a formação docente como fator passível de intervenção que se repete em municípios de renda baixa e intermediária.

REFERÊNCIAS

ABDI, Hervé; WILLIAMS, Lynne J. Principal Component Analysis. **WIREs Computational Statistics**, v. 2, n. 4, p. 433–459, 2010. DOI: 10.1002/wics.101. Disponível em: <https://doi.org/10.1002/wics.101>. Acesso em: 25 mai. 2026.

ALBERNAZ, Ângela; FERREIRA, Francisco H. G.; FRANCO, Creso. Qualidade e Eqüidade no Ensino Fundamental Brasileiro. **Pesquisa e Planejamento Econômico**, v. 32, n. 3, p. 453–476, 2002. Disponível em: <https://ppe.ipea.gov.br/index.php/ppe/article/view/139>. Acesso em: 23 mai. 2026.

BAKER, Ryan S. J. D.; YACEF, Kalina. The State of Educational Data Mining in 2009: A Review and Future Visions. **Journal of Educational Data Mining**, v. 1, n. 1, p. 3–16, 2009. DOI: 10.5281/zenodo.3554658. Disponível em: <https://jedm.educationaldatamining.org/index.php/JEDM/article/view/8>. Acesso em: 23 mai. 2026.

BEN-HUR, Asa; ELISSEEFF, André; GUYON, Isabelle. A Stability Based Method for Discovering Structure in Clustered Data. In: PACIFIC Symposium on Biocomputing. [S.l.: s.n.], 2002. v. 7, p. 6–17. Disponível em: <https://psb.stanford.edu/psb-online/proceedings/psb02/benhur.pdf>. Acesso em: 29 mai. 2026.

BRASIL. **Lei n.º 8.742, de 7 de dezembro de 1993: dispõe sobre a organização da Assistência Social e dá outras providências**. Brasília: Diário Oficial da União, 1993. Disponível em: <https://www2.camara.leg.br/legin/fed/lei/1993/lei-8742-7-dezembro-1993-363163-publicacaooriginal-1-pl.html>. Acesso em: 27 set. 2026.

BREIMAN, Leo. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: 10.1023/A:1010933404324. Disponível em: <https://link.springer.com/article/10.1023/A:1010933404324>. Acesso em: 25 mai. 2026.

COLEMAN, James S. et al. **Equality of Educational Opportunity**. Washington, D.C.: U.S. Government Printing Office, 1966. Disponível em: <https://archive.org/details/equalityofeducat0000cole_a0h5>. Acesso em: 23 mai. 2026.

COLPANI, Rogério. Mineração de Dados Educacionais: um estudo da evasão no ensino médio com base nos indicadores do Censo Escolar. **Informática na Educação: Teoria & Prática**, v. 21, n. 3, 2018. DOI: 10.22456/1982-1654.87880. Disponível em: <https://seer.ufrgs.br/InfEducTeoriaPratica/article/view/87880>. Acesso em: 27 mai. 2026.

ERSOZLU, Zara; TAHERI, Sona; KOCH, Inge. A Review of Machine Learning Methods Used for Educational Data. **Education and Information Technologies**, v. 29, n. 16, p. 22125–22145, 2024. DOI: 10.1007/s10639-024-12704-0. Disponível em: <https://doi.org/10.1007/s10639-024-12704-0>. Acesso em: 27 set. 2026.

FACELI, Katti; LORENA, Ana Carolina; CARVALHO, André Carlos Paulo de Leon Ferreira de. **Inteligência Artificial: uma abordagem de aprendizado de máquina**. 2. ed. Rio de Janeiro: LTC, 2021. 424 p. ISBN 9788521637349.

FERNANDES, Reynaldo. **Índice de Desenvolvimento da Educação Básica (IDEB)**. Brasília, 2007. Disponível em: <https://rbep.inep.gov.br/ojs3/index.php/td/article/view/3850>. Acesso em: 23 mai. 2026.

GLEWWE, Paul W. et al. School Resources and Educational Outcomes in Developing Countries: A Review of the Literature from 1990 to 2010. In: GLEWWE, Paul (Ed.). **Education Policy in Developing Countries**. Chicago: University of Chicago Press, 2014. P. 13–64. Disponível em: <https://www.nber.org/papers/w17554>. Acesso em: 23 mai. 2026.

HANUSHEK, Eric A.; WOESSMANN, Ludger. Do Better Schools Lead to More Growth? Cognitive Skills, Economic Outcomes, and Causation. **Journal of Economic Growth**, v. 17, n. 4, p. 267–321, 2012. DOI: 10.1007/s10887-012-9081-x. Disponível em: <https://link.springer.com/article/10.1007/s10887-012-9081-x>. Acesso em: 23 mai. 2026.

IBGE. **Censo Demográfico 2022: moradores por classes de rendimento nominal mensal domiciliar per capita, por município**. Rio de Janeiro: IBGE, 2022a. Sidra, tabela 10296. Disponível em: <https://sidra.ibge.gov.br/tabela/10296>. Acesso em: 27 set. 2026.

_____. **Censo Demográfico 2022: rendimento nominal médio mensal domiciliar per capita, por município**. Rio de Janeiro: IBGE, 2022b. Sidra, tabela 10295. Disponível em: <https://sidra.ibge.gov.br/tabela/10295>. Acesso em: 27 set. 2026.

INEP. **Microdados do Censo Escolar da Educação Básica 2025**. Brasília: INEP, 2026a. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/censo-escolar>. Acesso em: 27 set. 2026.

_____. **Nota Informativa: IDEB 2025**. Brasília, 2026b. Disponível em: <https://download.inep.gov.br/ideb/resultados/nota_informativa_ideb_2025.pdf>. Acesso em: 27 set. 2026.

_____. **Sinopse Estatística da Educação Básica 2025**. Brasília: INEP, 2026c. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/sinopses-estatisticas/educacao-basica>. Acesso em: 27 set. 2026.

KALITA, Emi et al. Educational Data Mining: A 10-Year Review. **Discover Computing**, v. 28, n. 1, 2025. DOI: 10.1007/s10791-025-09589-z. Disponível em: <https://doi.org/10.1007/s10791-025-09589-z>. Acesso em: 27 set. 2026.

MACQUEEN, James B. Some Methods for Classification and Analysis of Multivariate Observations. In: PROCEEDINGS of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. Berkeley, CA: University of California Press, 1967. v. 1, p. 281–297. Disponível em: <https://projecteuclid.org/euclid.bsmsp/1200512992>. Acesso em: 25 mai. 2026.

MANN, Henry B.; WHITNEY, Donald R. On a Test of Whether One of Two Random Variables Is Stochastically Larger than the Other. **The Annals of Mathematical Statistics**, v. 18, n. 1, p. 50–60, 1947. DOI: 10.1214/aoms/1177730491. Disponível em: <https://projecteuclid.org/euclid.aoms/1177730491>. Acesso em: 25 mai. 2026.

RIVKIN, Steven G.; HANUSHEK, Eric A.; KAIN, John F. Teachers, Schools, and Academic Achievement. **Econometrica**, v. 73, n. 2, p. 417–458, 2005. DOI: 10.1111/j.1468-0262.2005.00584.x. Disponível em: <https://www.nber.org/papers/w6691>. Acesso em: 23 mai. 2026.

ROMERO, Cristóbal; VENTURA, Sebastián. Educational Data Mining and Learning Analytics: An Updated Survey. **WIREs Data Mining and Knowledge Discovery**, v. 10, n. 3, e1355, 2020. DOI: 10.1002/widm.1355. Disponível em: <https://doi.org/10.1002/widm.1355>. Acesso em: 23 mai. 2026.

ROUSSEEUW, Peter J. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987. DOI: 10.1016/0377-0427(87)90125-7. Disponível em: <https://www.sciencedirect.com/science/article/pii/0377042787901257>. Acesso em: 25 mai. 2026.

SHEARER, Colin. The CRISP-DM Model: The New Blueprint for Data Mining. **Journal of Data Warehousing**, v. 5, n. 4, p. 13–22, 2000. Disponível em: <https://mineracaodedados.wordpress.com/wp-content/uploads/2012/04/the-crisp-dm-model-the-new-blueprint-for-data-mining-shearer-colin.pdf>. Acesso em: 29 mai. 2026.

SIRIN, Selcuk R. Socioeconomic Status and Academic Achievement: A Meta-Analytic Review of Research. **Review of Educational Research**, v. 75, n. 3, p. 417–453, 2005. DOI: 10.3102/00346543075003417. Disponível em: <https://doi.org/10.3102/00346543075003417>. Acesso em: 27 set. 2026.

SOARES, José Francisco; XAVIER, Flávia Pereira. Pressupostos educacionais e estatísticos do IDEB. **Educação & Sociedade**, v. 34, n. 124, p. 903–923, 2013. DOI: 10.1590/S0101-73302013000300013. Disponível em: <https://www.scielo.br/j/es/a/JLzr4qdx89rjrNXnydNcvcy/>. Acesso em: 25 mai. 2026.

VASCONCELOS, Joyciane Coelho et al. Infraestrutura escolar e investimentos públicos em Educação no Brasil: a importância para o desempenho educacional. **Ensaio: Avaliação e Políticas Públicas em Educação**, v. 29, n. 113, p. 874–898, 2021. DOI: 10.1590/S0104-40362020002802245. Disponível em: <https://www.scielo.br/j/ensaio/a/w9HwRXMQ3FVZ9fzJJKBgLLt/>. Acesso em: 23 mai. 2026.

INFORMAÇÕES COMPLEMENTARES

Disponibilidade de dados

Os dados utilizados neste trabalho são de acesso público e foram disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), vinculado ao Ministério da Educação e pelo Instituto Brasileiro de Geografia e Estatística (IBGE). Os resultados e interpretações são de responsabilidade exclusiva da autoria e não representam posição oficial dessas instituições.