



Desempenho Educacional nos Municípios Maranhenses: Uma Análise Comparativa entre as Regiões do Estado

Darlon José Coqueiro

23 de maio de 2026

Resumo

Esta investigação analisa o desempenho educacional no IDEB EFAI 2023 (Índice de Desenvolvimento da Educação Básica, Anos Iniciais do Ensino Fundamental) das escolas da rede municipal, utilizando aprendizado de máquina não supervisionado para identificar padrões associados ao desempenho escolar em contextos de vulnerabilidade socioeconômica. Integrando microdados do Censo Escolar 2023 e indicadores socioeconômicos do IBGE para os 217 municípios do estado com dados disponíveis, adotamos uma abordagem em dois estágios: segmentação municipal via *K-Means* sobre renda *per capita* e IDHM (Índice de Desenvolvimento Humano Municipal), seguida de *Random Forest Classifier* e testes de Mann-Whitney para identificar, dentro de cada grupo, os fatores que diferenciam municípios de alto e baixo desempenho no IDEB. Os resultados identificaram os fatores mais fortemente associados ao desempenho superior. Essas descobertas evidenciam a utilidade do aprendizado não supervisionado para análises educacionais descritivas e oferecem subsídios concretos para políticas educacionais e de alocação de recursos nos municípios. Esta pesquisa contribui para suprir a sub-representação do Maranhão na literatura de mineração de dados educacionais e propõe uma estrutura analítica replicável para outras regiões em desenvolvimento que busquem orientar estratégias de educação pública a partir de dados administrativos.

Palavras-chave: desempenho educacional; IDEB; IDHM; municípios maranhenses; clusterização; *K-Means*; *Random Forest*; políticas educacionais.

1 Introdução

A qualidade da educação básica é um dos principais determinantes do desenvolvimento humano e econômico de longo prazo (HANUSHEK; WOESSMANN, 2012). No Brasil, o Índice de Desenvolvimento da Educação Básica (IDEB) monitora o ensino público combinando fluxo escolar e proficiência em língua portuguesa e matemática numa medida comparável entre municípios, estados e redes de ensino (FERNANDES, 2007). Apesar dos avanços das últimas duas décadas, as disparidades regionais persistem: estados do Norte e do Nordeste ficam sistematicamente abaixo da média nacional, reflexo de desigualdades estruturais de renda, infraestrutura e serviços públicos (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024).

O Maranhão está entre os casos mais críticos. Com um dos menores IDHMs do país e indicadores educacionais historicamente abaixo da média nacional, o estado concentra municípios em alta vulnerabilidade socioeconômica, onde os obstáculos para melhorar o desempenho escolar superam a capacidade de gestão local (Instituto Brasileiro de Geografia e Estatística, 2010; Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024). Isso coloca uma pergunta direta: o que diferencia, dentro de um mesmo patamar de vulnerabilidade, os municípios que sobem no IDEB daqueles que ficam estagnados?

A literatura internacional examinou amplamente a relação entre condições socioeconômicas, infraestrutura escolar e qualificação docente e o desempenho dos estudantes (RIVKIN; HANUSHEK; KAIN, 2005; COLEMAN et al., 1966). No Brasil, estudos com dados do IDEB e do Censo Escolar apontaram formação dos professores, tamanho das turmas e infraestrutura como variáveis relevantes (VASCONCELOS et al., 2021; SOARES; XAVIER, 2013). Análises voltadas especificamente para o Maranhão que isolem fatores intracontextuais (aqueles que operam mesmo quando o contexto socioeconômico é semelhante) são escassas.

Métodos de aprendizado de máquina têm sido aplicados a dados educacionais com resultados promissores, especialmente por sua capacidade de lidar com bases administrativas grandes e heterogêneas (BAKER; YACEF, 2009; ROMERO; VENTURA, 2010). Algoritmos de agrupamento identificam estruturas nos dados sem categorias predefinidas, o que os torna úteis para segmentar contextos antes de comparações (WITTEN et al., 2016). Quando combinados com medidas de importância de variáveis e testes não paramétricos, essa abordagem permite identificar os fatores que mais diferenciam grupos de desempenho.

Este trabalho aplica essa lógica aos 217 municípios maranhenses com dados disponíveis no IDEB 2023 (Anos Iniciais do Ensino Fundamental, rede municipal). No primeiro estágio, os municípios são agrupados por contexto socioeconômico via *K-Means*, usando renda per capita e IDHM. No segundo, dentro de cada grupo, um *Random Forest Clas-*

sifier combinado com o teste de Mann-Whitney identifica quais características escolares e socioeconômicas separam municípios de alto e baixo desempenho. As variáveis analisadas — infraestrutura (internet, biblioteca, laboratório de informática, saneamento), qualificação docente e indicadores de fluxo escolar — vêm do Censo Escolar 2023.

O trabalho faz três contribuições principais. Primeiro, propõe e aplica uma abordagem em dois estágios — segmentação socioeconômica seguida de análise intragrupo — ao contexto específico do Maranhão. Segundo, identifica os fatores escolares associados ao desempenho superior no IDEB entre municípios vulneráveis. Terceiro, disponibiliza um pipeline reprodutível para análises similares em outras unidades federativas. Os resultados têm uso direto para gestores e formuladores de políticas que precisam decidir onde concentrar recursos.

O restante do artigo está organizado da seguinte forma: o Capítulo 2 apresenta os trabalhos relacionados; o Capítulo 3 descreve os materiais e métodos; o Capítulo 4 apresenta os experimentos e resultados; o Capítulo 5 discute conclusões, limitações e direções futuras.

2 Related Works

2.1 Supervised Machine Learning in Educational Analytics

2.2 Unsupervised Learning for Pattern Discovery

2.3 IDEB-Based Studies and Socioeconomic Factors

2.4 Our Proposal

3 Material and Methods

3.1 Machine Learning

3.2 Association Rules

3.3 Methodology

4 Computational Experiments

4.1 Domain Understanding

4.2 Data Gathering

4.3 Data Pre-processing

4.4 Exploratory Analysis

4.5 Modeling

4.6 Results and Discussion

4.7 Practical Implications

5 Conclusions

5.1 Comparison with IDEB Works

5.2 Limitations and Future Direction

5.3 Acknowledgments

5.4 Authors' CRediT

Referências

- BAKER, R. S. J. D.; YACEF, K. The state of educational data mining in 2009: A review and future visions. *Journal of Educational Data Mining*, v. 1, n. 1, p. 3–16, 2009. Disponível em: <<https://jedm.educationaldatamining.org/index.php/JEDM/article/view/8>>.
- COLEMAN, J. S. et al. *Equality of Educational Opportunity*. Washington, D.C.: U.S. Government Printing Office, 1966. Disponível em: <<https://eric.ed.gov/?id=ED012275>>.
- FERNANDES, R. *Índice de Desenvolvimento da Educação Básica (IDEB)*. Brasília, 2007. Disponível em: <<https://rbep.inep.gov.br/ojs3/index.php/td/article/view/3850>>.
- HANUSHEK, E. A.; WOESSMANN, L. Do better schools lead to more growth? Cognitive skills, economic outcomes, and causation. *Journal of Economic Growth*, v. 17, n. 4, p. 267–321, 2012. Disponível em: <<https://link.springer.com/article/10.1007/s10887-012-9081-x>>.
- Instituto Brasileiro de Geografia e Estatística. *Censo Demográfico 2010*. Rio de Janeiro: IBGE, 2010. Disponível em: <<https://www.ibge.gov.br/estatisticas/sociais/saude/9662-censo-demografico-2010.html>>.
- Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. *Nota Informativa: IDEB 2023*. Brasília, 2024. Disponível em: <https://download.inep.gov.br/ideb/nota_informativa_ideb_2023.pdf>.
- RIVKIN, S. G.; HANUSHEK, E. A.; KAIN, J. F. Teachers, schools, and academic achievement. *Econometrica*, v. 73, n. 2, p. 417–458, 2005. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1468-0262.2005.00584.x>>.
- ROMERO, C.; VENTURA, S. Educational data mining: A review of the state of the art. *IEEE Transactions on Systems, Man, and Cybernetics, Part C: Applications and Reviews*, v. 40, n. 6, p. 601–618, 2010. Disponível em: <<https://dl.acm.org/doi/10.1109/TSMCC.2010.2053532>>.
- SOARES, J. F.; XAVIER, F. P. Pressupostos educacionais e estatísticos do IDEB. *Educação & Sociedade*, v. 34, n. 124, p. 903–923, 2013. Disponível em: <<https://www.scielo.br/j/es/a/JLzr4qdx89rjrNXnydNcvcy/>>.
- VASCONCELOS, J. C. et al. Infraestrutura escolar e investimentos públicos em Educação no Brasil: a importância para o desempenho educacional. *Ensaio: Avaliação e Políticas Públicas em Educação*, v. 29, n. 113, p. 874–898, 2021. Disponível em: <<https://www.scielo.br/j/ensaio/a/w9HwRXMQ3FVZ9fzJJKBgLLt/>>.
- WITTEN, I. H. et al. *Data Mining: Practical Machine Learning Tools and Techniques*. 4. ed. Cambridge, MA: Morgan Kaufmann, 2016. ISBN 9780128042915. Disponível em: <<https://shop.elsevier.com/books/data-mining/witten/978-0-12-804291-5>>.