DEBATES EM EDUCAÇÃO
ISSN: 2175-6600

Artigo | Article

Fatores intracontextuais do desempenho no IDEB: segmentação socioeconômica e análise intragrupo nos municípios do Maranhão

Intracontextual factors of IDEB performance: socioeconomic segmentation and within-group analysis in the municipalities of Maranhão

Factores intracontextuales del desempeño en el IDEB: segmentación socioeconómica y análisis intragrupo en los municipios de Maranhão

Resumo

O desempenho educacional dos municípios maranhenses está entre os mais baixos do país, e a desigualdade socioeconômica dificulta comparações diretas entre redes de ensino. Este artigo tem como objetivo identificar os fatores escolares que diferenciam municípios de alto e de baixo desempenho no Índice de Desenvolvimento da Educação Básica de 2025, nos anos iniciais do ensino fundamental da rede municipal, entre municípios de contexto socioeconômico semelhante. A pesquisa, quantitativa e descritiva, integra dados do Censo Escolar de 2025 e do Censo Demográfico de 2022 para os 216 municípios do Maranhão com o índice divulgado. Primeiro, o algoritmo *K-Means* agrupa os municípios segundo a renda *per capita* e a proporção de moradores em pobreza extrema, resultando em três grupos; depois, nos grupos com amostra suficiente, o teste de Mann-Whitney, com tamanho de efeito e correção para comparações múltiplas, compara os municípios dos quartis superior e inferior de desempenho. Nos grupos de renda baixa e intermediária, a proporção de docentes com ensino superior e com licenciatura está associada ao desempenho, com efeito médio; no intermediário, destaca-se também a presença de quadra esportiva. Conclui-se que a formação docente é o fator escolar mais consistentemente associado ao desempenho, embora o desenho associativo do estudo não permita estimar seu efeito causal.

Palavras-chave: desempenho educacional; formação docente; eficácia escolar.

Abstract

The educational performance of municipalities in Maranhão is among the lowest in Brazil, and socioeconomic inequality hinders direct comparisons between school systems. This article aims to identify the school factors that distinguish high- and low-performing municipalities in the 2025 Basic Education Development Index, in the early years of elementary education in municipal schools, among municipalities with similar socioeconomic contexts. The study, quantitative and descriptive, integrates data from the 2025 School Census and the 2022 Demographic Census for the 216 municipalities of Maranhão for which the index was released. First, the K-Means algorithm groups municipalities according to per capita income and the share of residents in ex-

https://doi.org/10.28998/2175-6600.2025v17n39
Artigo publicado sob a Licença Creative Commons 4.0
Submetido em: dd/mm/aaaa
Aceito em: dd/mm/aaaa
Publicado: dd/mm/aaaa
e-Location: xxxxxxx

treme poverty, resulting in three groups; then, within the groups with sufficient sample size, the Mann-Whitney test, with effect sizes and correction for multiple comparisons, compares municipalities in the upper and lower performance quartiles. In the low- and middle-income groups, the share of teachers with higher education and with a teaching degree is associated with performance, with a medium effect size; in the middle-income group, the presence of sports courts also stands out. It is concluded that teacher education is the school factor most consistently associated with performance, although the associative design of the study does not allow its causal effect to be estimated.

Keywords: *educational performance; teacher education; school effectiveness.*

Resumen

El desempeño educativo de los municipios de Maranhão está entre los más bajos de Brasil, y la desigualdad socioeconómica dificulta las comparaciones directas entre redes de enseñanza. Este artículo tiene como objetivo identificar los factores escolares que diferencian a los municipios de alto y de bajo desempeño en el Índice de Desarrollo de la Educación Básica de 2025, en los años iniciales de la enseñanza fundamental de la red municipal, entre municipios de contexto socioeconómico similar. La investigación, cuantitativa y descriptiva, integra datos del Censo Escolar de 2025 y del Censo Demográfico de 2022 para los 216 municipios de Maranhão con el índice divulgado. Primero, el algoritmo K-Means agrupa los municipios según la renta per cápita y la proporción de residentes en pobreza extrema, en tres grupos; después, en los grupos con muestra suficiente, la prueba de Mann-Whitney, con tamaño del efecto y corrección por comparaciones múltiples, compara los cuartiles superior e inferior de desempeño. En los grupos de renta baja e intermedia, la proporción de docentes con educación superior y con licenciatura se asocia al desempeño, con efecto medio; en el grupo intermedio, destaca también la presencia de canchas deportivas. Se concluye que la formación docente es el factor escolar asociado de forma más consistente al desempeño, aunque el diseño asociativo del estudio no permite estimar su efecto causal.

Palabras-clave: *desempeño educativo; formación docente; eficacia escolar.*

INTRODUÇÃO

A qualidade da educação básica é um dos principais determinantes do desenvolvimento econômico de longo prazo, já que as habilidades cognitivas da população afetam o crescimento (Hanushek; Woessmann, 2012). No Brasil, o Índice de Desenvolvimento da Educação Básica (IDEB) monitora o ensino público combinando fluxo escolar e proficiência em língua portuguesa e matemática numa medida comparável entre municípios, estados e redes de ensino (Fernandes, 2007). Apesar dos avanços das últimas duas décadas, estados do Norte e do Nordeste ficam sistematicamente abaixo da média nacional, reflexo de desigualdades estruturais de renda, infraestru-

tura e serviços públicos (INEP, 2026b).

O Maranhão está entre os casos mais críticos. Com a menor renda domiciliar *per capita* do país no Censo Demográfico 2022 e indicadores educacionais historicamente abaixo da média nacional, o estado concentra municípios em alta vulnerabilidade socioeconômica (IBGE, 2022b; INEP, 2026b). Ainda assim, o desempenho varia entre municípios de condições semelhantes, o que coloca uma pergunta direta: o que diferencia, dentro de um mesmo patamar de vulnerabilidade, os municípios de maior IDEB daqueles de menor IDEB?

A literatura mostra que o nível socioeconômico é o fator mais associado ao desempenho, mas que as escolas também fazem diferença (Coleman *et al.*, 1966; Brooke; Soares, 2008), por meio da qualificação docente (Rivkin; Hanushek; Kain, 2005) e da infraestrutura (Alves; Soares, 2013; Vasconcelos *et al.*, 2021). Análises do Maranhão que isolem fatores intracontextuais, isto é, aqueles que se mantêm associados ao desempenho mesmo entre municípios de contexto socioeconômico semelhante, são escassas. Algoritmos de agrupamento, aplicados a bases educacionais grandes e heterogêneas (Romero; Ventura, 2020; Kalita *et al.*, 2025), permitem segmentar contextos antes das comparações, sem confundir fatores escolares com diferenças de contexto.

O objetivo geral deste artigo é identificar, entre municípios maranhenses de contexto socioeconômico semelhante, os fatores escolares associados ao desempenho superior no IDEB, considerando os 216 dos 217 municípios com IDEB 2025 divulgado (anos iniciais do ensino fundamental, rede municipal). Os objetivos específicos são: agrupar os municípios por contexto socioeconômico, com o algoritmo *K-Means* aplicado à renda *per capita* e à proporção de moradores em pobreza extrema do Censo Demográfico 2022; comparar, dentro de cada grupo, os municípios de alto e de baixo desempenho quanto à infraestrutura, à qualificação docente e ao fluxo escolar registrados no Censo Escolar 2025, com o teste de Mann-Whitney, tamanho de efeito e correção para comparações múltiplas; e discutir as implicações dos achados para as políticas educacionais municipais.

Diferentemente dos modelos globais, que comparam municípios de contextos muito distintos, o estudo compara municípios dentro de grupos socioeconômicos semelhantes, oferece evidência sobre um estado pouco estudado e propõe uma abordagem replicável em outras unidades federativas. O artigo organiza-se em quatro seções além desta: o referencial teórico, sobre os fatores associados ao IDEB e a mineração

de dados educacionais; os procedimentos metodológicos, com as fontes, as variáveis e os dois estágios da análise; os resultados e a discussão; e as considerações finais, com a síntese dos achados e as limitações.

REFERENCIAL TEÓRICO

Compreender os fatores associados ao desempenho escolar exige articular os estudos educacionais sobre esses fatores e os métodos computacionais capazes de extrair padrões de grandes bases administrativas. Esta seção apresenta, primeiro, os estudos sobre o IDEB e os fatores associados ao desempenho no Brasil e, em seguida, a mineração de dados educacionais e o agrupamento não supervisionado como estratégia de segmentação contextual.

O IDEB e os fatores associados ao desempenho escolar no Brasil

O IDEB combina a taxa de aprovação (fluxo) e a proficiência em Língua Portuguesa e Matemática aferida pelo Sistema de Avaliação da Educação Básica (Saeb) (Fernandes, 2007). Soares e Xavier (2013) examinaram os pressupostos estatísticos do índice e alertaram para o risco de interpretações que ignoram a correlação entre fluxo e proficiência.

O debate sobre o efeito-escola remonta ao relatório de Coleman *et al.* (1966), segundo o qual o contexto familiar explica a maior parte da variância no desempenho, e os fatores escolares têm efeito residual, mas acionável por políticas públicas. No Brasil, a pesquisa em eficácia escolar, sistematizada por Brooke e Soares (2008), mostrou que, controlado o nível socioeconômico dos alunos, as escolas ainda diferem no quanto seus estudantes aprendem. Como qualidade e equidade variam com o nível socioeconômico das escolas, comparações entre contextos distintos tendem a confundir efeito-escola com efeito-contexto (Albernaz; Ferreira; Franco, 2002).

Entre os fatores escolares, Rivkin, Hanushek e Kain (2005) demonstraram que a qualidade do professor é o fator intraescolar de maior impacto sobre o aprendizado, mas que a titulação explica pouco dessa variação. A Meta 15 do Plano Nacional de Educação estabelece que todos os professores da educação básica tenham formação específica de nível superior, em licenciatura na área em que atuam (BRASIL, 2014), e Gatti *et al.* (2019) descrevem um cenário de expansão das licenciaturas, sobretudo

a distância, com persistência de docentes em exercício sem a formação exigida. Por isso, interessa verificar se a titulação se associa ao desempenho em redes nas quais parte expressiva dos docentes ainda não tem formação superior.

Quanto à infraestrutura, Alves e Soares (2013) mostraram que o IDEB das escolas varia com o nível socioeconômico dos alunos, a infraestrutura e a complexidade da escola, com associação mais forte nos anos iniciais. Vasconcelos *et al.* (2021) encontraram, para os municípios brasileiros, que a infraestrutura pesa mais sobre o IDEB do que o volume de investimento em educação. Em revisão sobre países em desenvolvimento, Glewwe *et al.* (2013) verificaram que, nos estudos de maior rigor, poucas características de escolas e professores afetam o aprendizado, e a escolaridade docente não mostrou efeito consistente.

Análises centradas no Maranhão são escassas na literatura consultada, embora o estado figure entre os piores resultados nacionais no IDEB dos anos iniciais (INEP, 2026b) e a concentração de municípios vulneráveis exija controlar o contexto antes de comparar desempenhos.

Mineração de dados e segmentação contextual

A mineração de dados educacionais (*Educational Data Mining*) consolidou-se como área na segunda metade da década de 2000, com paradigmas que vão da predição ao agrupamento (Baker; Yacef, 2009), e é dominada por técnicas supervisionadas para predizer aprovação, evasão e desempenho (Romero; Ventura, 2020). No Brasil, os microdados do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) impulsionaram estudos que aplicam essas técnicas ao Censo Escolar e ao IDEB (Colpani, 2018). Na literatura consultada, porém, predominam modelos globais, que tratam como comparáveis municípios de contextos socioeconômicos muito distintos, e são menos frequentes os estudos sobre o Norte e o Nordeste.

O *K-Means* (MacQueen, 1967) agrupa entidades em grupos internamente homogêneos e exige definir previamente o número de grupos k, que pode ser escolhido pelo *Silhouette Score* (Rousseeuw, 1987): para cada ponto, ele compara a coesão com o próprio grupo e a separação em relação ao grupo mais próximo, num escore entre -1 e 1. No contexto brasileiro, Alves, Soares e Xavier (2014) usaram o *K-Means* para agrupar as escolas de educação básica em sete níveis segundo o índice socioeconômico, o que mostra o potencial da técnica para caracterizar contextos antes de

comparar os grupos em outros indicadores.

Combinar essa segmentação com testes aplicados dentro de cada grupo reduz, sem eliminar, o risco de atribuir a fatores escolares diferenças determinadas pela renda. É essa a lógica em dois estágios adotada neste estudo.

PROCEDIMENTOS METODOLÓGICOS

Trata-se de uma pesquisa de abordagem quantitativa e, quanto aos objetivos, descritiva, na acepção de Gil (2017): busca descrever as características de uma população (os municípios maranhenses) e estabelecer relações entre variáveis, sem manipulá-las. Quanto aos procedimentos técnicos, classifica-se como pesquisa documental (Gil, 2017), pois utiliza exclusivamente dados secundários de acesso público, produzidos pelo INEP e pelo Instituto Brasileiro de Geografia e Estatística (IBGE) com outras finalidades e aqui reanalisados. Esta seção apresenta as fontes, as variáveis e o tratamento dos dados e, em seguida, os dois estágios da análise.

Fontes de dados e variáveis

O estudo integra três bases públicas. A primeira é o IDEB 2025 dos anos iniciais do ensino fundamental (EFAI) da rede municipal (INEP, 2026b), calculado conforme Fernandes (2007). A edição cobriu 216 dos 217 municípios do estado; Nova Iorque não teve o indicador divulgado porque o INEP não divulgou as notas do município no Saeb. A segunda são os microdados do Censo Escolar 2025 (INEP, 2026a), com a infraestrutura, as matrículas e as turmas de cada escola, complementados pela Tabela 2.29 da Sinopse Estatística da Educação Básica 2025 (INEP, 2026c), que traz a formação dos docentes dos anos iniciais sem a dupla contagem presente nos microdados brutos. A terceira é o Censo Demográfico 2022, do qual foram extraídos, no Sistema IBGE de Recuperação Automática (Sidra), o rendimento médio domiciliar *per capita* (tabela 10295) (IBGE, 2022b) e a distribuição dos moradores por classes de rendimento (tabela 10296) (IBGE, 2022a). Por ser um recenseamento, é a única fonte de renda com cobertura de todos os municípios.

A segmentação usa duas variáveis do Censo 2022: a *renda per capita*, que mede o nível de recursos do município, e a *pobreza extrema*, percentual de moradores com rendimento domiciliar *per capita* de até 1/4 do salário mínimo ou sem rendimento,

critério de miserabilidade da Lei Orgânica da Assistência Social (BRASIL, 1993). A escolha tem base teórica: o nível socioeconômico é o preditor mais consistente do desempenho desde Coleman *et al.* (1966), e a associação é mais forte em unidades agregadas, como escolas e distritos, do que no nível individual (Sirin, 2005). Controlar o contexto é, portanto, condição para não atribuir a fatores escolares diferenças que decorrem da renda (Albernaz; Ferreira; Franco, 2002). As duas medidas se complementam, pois a média é sensível a rendas altas concentradas em poucos domicílios, e a pobreza extrema descreve a base da distribuição. Elas são correlacionadas (Pearson de $-0{,}87$), e a contribuição de cada uma é avaliada por ablação no Estágio 1.

As variáveis explicativas, organizadas em três grupos, são descritas no quadro 1.

Quadro 1 – Variáveis explicativas utilizadas na análise intragrupo

Variável	**Definição operacional**
Infraestrutura escolar (Censo Escolar 2025): proporção de escolas com o atributo	
% escolas com água adequada	Água potável ou rede pública
% escolas com biblioteca/sala de leitura	Biblioteca, biblioteca-sala de leitura ou sala de leitura
% escolas com esgoto adequado	Rede pública ou fossa séptica
% escolas com internet	Acesso à internet
% escolas com laboratório de informática	Laboratório de informática
% escolas com quadra esportiva	Quadra de esportes
Qualificação docente (Sinopse Estatística 2025)	
% docentes EFAI com ensino superior	Proporção de docentes dos anos iniciais com graduação
% docentes EFAI com licenciatura	Proporção de docentes dos anos iniciais com licenciatura
Fluxo e distorção (Censo Escolar 2025)	
Média de alunos/turma (educação básica)	Matrículas divididas pelo total de turmas da educação básica
Média de alunos/turma (ensino fundamental)	Matrículas divididas pelo total de turmas do ensino fundamental
Proxy distorção idade-série	% matrículas com 15 anos ou mais na educação básica municipal
% turmas com correção de fluxo (anos finais)	Proporção de turmas de correção de fluxo entre as turmas dos anos finais do ensino fundamental

Fonte: elaboração própria (2026).

Coleta e pré-processamento dos dados

A coleta e o tratamento foram automatizados em *scripts* Python, o que permite reproduzir a análise. As variáveis escolares da rede municipal foram agregadas por município como proporções de escolas, de docentes ou de turmas, ou como médias sobre as matrículas. A unidade de análise é, portanto, o município: as associações encontradas referem-se às redes municipais e não podem ser transpostas para escolas, professores ou alunos (Robinson, 1950).

A Sinopse conta os docentes dos anos iniciais de todas as redes, enquanto o IDEB analisado é o da rede municipal, que reúne, em média, 93% (*cluster* intermediário) e 95% (vulnerável) desses docentes. Para verificar se o descompasso afeta os resultados, a formação docente também foi calculada apenas na rede municipal, a partir dos microdados, abrangendo toda a educação básica, porque os microdados não separam a formação por etapa. Integradas as bases, não há valores ausentes além do IDEB de Nova Iorque, que, sem poder ser classificado por desempenho, fica fora dos dois estágios.

Estágio 1: segmentação socioeconômica por *K-Means*

O *K-Means* (MacQueen, 1967) agrupa os 216 municípios pela renda *per capita* e pela pobreza extrema, padronizadas pela mediana e pelo intervalo interquartil para reduzir a influência de municípios atípicos, como São Luís e Imperatriz, cuja renda *per capita* muito acima e pobreza extrema muito abaixo dos demais poderiam distorcer a formação dos grupos.

O algoritmo é executado para um número de grupos k entre 2 e 10, e k é escolhido pelo *Silhouette Score* médio (Rousseeuw, 1987). A escolha é confirmada pela estabilidade da partição, avaliada por *bootstrap* de 25 iterações com 80% dos dados, na configuração de referência de Ben-Hur, Elisseeff e Guyon (2002), com o *Adjusted Rand Index* (ARI) como métrica de concordância. Na ablação, a clusterização é refeita sem cada variável, e o ARI entre a nova partição e a original indica o quanto a partição depende dela. Os *clusters* são visualizados por Análise de Componentes Principais (*Principal Component Analysis*, PCA) (Abdi; Williams, 2010) com duas componentes.

Estágio 2: análise intragrupo

Em cada *cluster* com amostra suficiente, comparam-se os municípios de *alto IDEB* (quartil superior, $\geq Q_{75}$) e de *baixo IDEB* (quartil inferior, $\leq Q_{25}$); o intervalo central é excluído, o que aumenta o contraste e reduz o ruído.

Para cada variável, o teste de Mann-Whitney (Mann; Whitney, 1947) bicaudal verifica se as distribuições diferem entre os grupos, e o δ de Cliff (Cliff, 1993), de -1 a 1, mede a magnitude da diferença. Seguindo Vargha e Delaney (2000), valores absolutos a partir de 0,12, 0,28 e 0,42 são lidos como efeitos pequeno, médio e grande. Como são testadas catorze variáveis em cada *cluster* (as doze do quadro 1 e as duas de segmentação), os p-valores são acompanhados do valor q de Benjamini e Hochberg (1995), que controla a taxa de falsas descobertas. São reportadas as variáveis com $p < 0{,}10$, interpretadas à luz do valor q, do efeito e da consistência entre *clusters*, o que, com o tamanho das amostras, dá ao estágio 2 caráter exploratório.

Duas verificações complementam a comparação: a correlação de Spearman entre cada variável e o IDEB com todos os municípios do *cluster*, sem descartar o intervalo central; e o poder preditivo conjunto das variáveis, em validação cruzada em cinco partes repetida vinte vezes, de um classificador *Random Forest* (Breiman, 2001), medido pela área sob a curva ROC (*Receiver Operating Characteristic*), a AUC, em que 0,5 equivale ao acaso, e de uma regressão *ridge* (Hoerl; Kennard, 1970) para o IDEB contínuo, medida pelo R^2 fora da amostra.

Uso de ferramentas de inteligência artificial generativa

Foram utilizadas ferramentas de inteligência artificial generativa em três etapas: o Claude (Anthropic), na correção e revisão dos *scripts* Python da análise, com cada alteração validada pela autoria; o Claude e o ChatGPT (OpenAI), na revisão da redação e da clareza do texto; e o Claude e o SciSpace AI Research (PubGenius Inc.), na busca de trabalhos relevantes e na verificação de metadados de citações, com cada referência conferida na fonte original. O texto, a argumentação e a interpretação dos resultados são de responsabilidade exclusiva da autoria, conforme as diretrizes de integridade científica do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq).

RESULTADOS E DISCUSSÃO

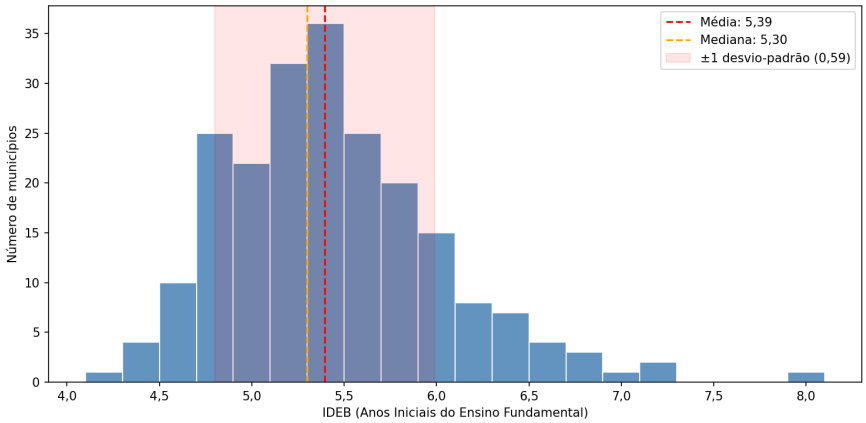
Esta seção apresenta e discute os resultados dos dois estágios: o contexto do estado e a distribuição do IDEB, a segmentação socioeconômica, os fatores que diferenciam os municípios de alto e de baixo desempenho em cada grupo e, por fim, o diálogo com a literatura e as implicações para as políticas educacionais.

Contexto socioeconômico e distribuição do IDEB

No Censo Demográfico 2022, o Maranhão tem a menor renda domiciliar *per capita* entre as 27 unidades da federação (R$ 899,87, contra R$ 1.638,06 no Brasil) (IBGE, 2022b) e a segunda maior proporção de moradores em pobreza extrema (26,6%, contra 13,3% no Brasil) (IBGE, 2022a). A desigualdade entre os municípios também é expressiva: a renda *per capita* mediana é de R$ 667, e a proporção de moradores em pobreza extrema varia de 11,2% a 60,3%.

A distribuição do IDEB dos 216 municípios com indicador divulgado é apresentada no gráfico 1. Ela é aproximadamente unimodal, ligeiramente assimétrica à direita, com média de 5,39 (desvio-padrão de 0,59), mediana de 5,30, mínimo de 4,10 e máximo de 8,10.

Gráfico 1 – Distribuição do IDEB 2025 dos municípios maranhenses – rede municipal, anos iniciais do ensino fundamental



Nota: média: 5,39; mediana: 5,30; desvio-padrão: 0,59.

Fonte: elaboração própria com base em INEP (2026b).

A amplitude de 4,00 pontos, numa escala de 0 a 10, mostra que mesmo um estado vulnerável em termos nacionais tem variabilidade interna suficiente para justificar

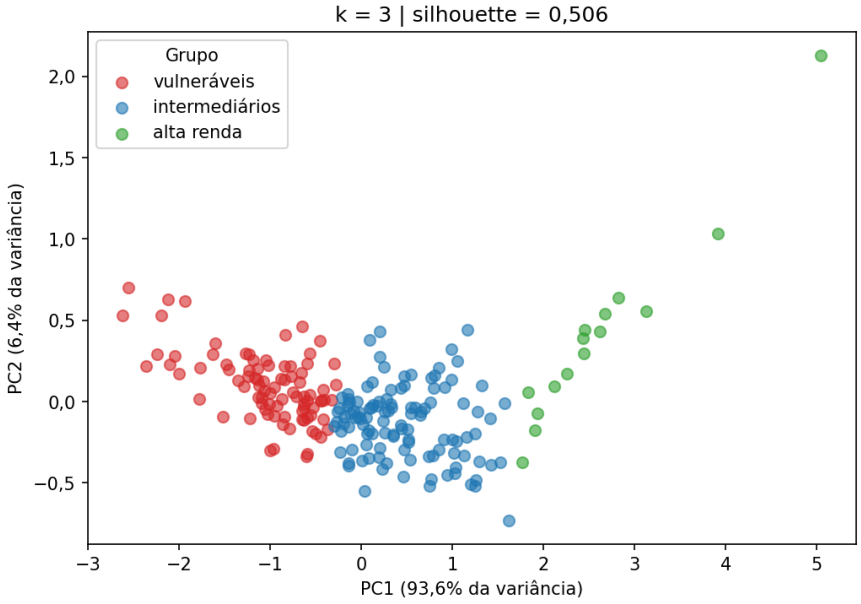
a investigação.

Segmentação socioeconômica dos municípios

Entre as partições testadas, de 2 a 10 grupos, o *Silhouette Score* atinge o valor máximo em $k = 3$ (0,506), acima de $k = 2$ (0,489) e de $k = 4$ (0,456). A estabilidade *bootstrap* confirma a escolha: o ARI médio é 0,812 em $k = 3$, contra 0,744 em $k = 2$ e 0,704 em $k = 4$. A partição com três grupos é, portanto, a mais bem separada e a mais estável sob reamostragem entre as testadas.

No gráfico 2, os *clusters* são projetados nas duas primeiras componentes principais. A primeira (PC1) explica 93,6% da variância, reflexo da correlação entre as variáveis de segmentação: os municípios se distribuem ao longo de um eixo de renda, no qual renda média alta e pobreza extrema baixa caminham juntas.

Gráfico 2 – Projeção dos *clusters* de municípios maranhenses nas duas primeiras componentes principais para $k = 3$



Fonte: elaboração própria com base em IBGE (2022a,b).

Na ablação, a concordância com a partição original cai para um ARI de 0,379 sem a renda *per capita* e para 0,688 sem a pobreza extrema. As duas variáveis contribuem, portanto, com peso maior para a renda média, e a pobreza extrema acrescenta a informação sobre a base da distribuição.

O *cluster* vulnerável (n = 88) tem renda *per capita* média de R$ 555,84, 41,8% dos moradores em pobreza extrema e IDEB médio de 5,29; o intermediário (n = 113),

R$ 732,06, 27,5% e 5,42; e o de alta renda (n = 15), R$ 1.082,44, 15,3% e 5,78. Este último reúne a capital e os polos regionais, como Imperatriz, Timon e Balsas, e não tem amostra para a comparação por quartis, que deixaria quatro ou cinco municípios em cada extremo; a análise intragrupo concentra-se, assim, nos outros dois (201 municípios). A formação docente acompanha o gradiente de renda: 55,9%, 64,0% e 79,1% dos docentes dos anos iniciais têm ensino superior nos três grupos.

Fatores discriminantes no *cluster* vulnerável

Dentro do *cluster* vulnerável (n = 88), os 24 municípios que se encontram no quartil superior de IDEB (alto, $\geq 5{,}60$, média 6,08) são comparados aos 23 do quartil inferior (baixo, $\leq 4{,}80$, média 4,61). Na tabela 1, apresentam-se as variáveis com $p < 0{,}10$ no teste de Mann-Whitney nos dois *clusters*; as diferenças entre proporções são expressas em pontos percentuais (p.p.).

Tabela 1 – Variáveis com diferença entre municípios de alto e baixo IDEB nos *clusters* vulnerável e intermediário (Mann-Whitney bicaudal)

Variável	Alto	Baixo	Δ	δ	p	q
Cluster vulnerável (alto: n = 24; baixo: n = 23)						
% doc. com ensino superior	60,6%	49,0%	+11,6 p.p.	0,35	0,039	0,34
% doc. com licenciatura	59,1%	47,8%	+11,4 p.p.	0,34	0,049	0,34
Cluster intermediário (alto: n = 34; baixo: n = 29)						
% escolas com quadra	12,9%	5,4%	+7,5 p.p.	0,42	0,004	0,052
% turmas corr. fluxo (anos finais)	0,90%	0,07%	+0,8 p.p.	0,26	0,007	0,052
% doc. com ensino superior	69,2%	58,1%	+11,1 p.p.	0,29	0,047	0,18
% doc. com licenciatura	67,4%	57,4%	+10,1 p.p.	0,29	0,051	0,18
Renda *per capita* (R$)	753,15	719,13	+34,02	0,26	0,081	0,23

Nota: Alto e Baixo: médias dos grupos de alto e de baixo IDEB; Δ: diferença entre as médias; δ: delta de Cliff; q: valor q de Benjamini-Hochberg sobre as catorze variáveis de cada *cluster*.

Fonte: elaboração própria com base em INEP (2026a,b,c) e IBGE (2022a,b).

No *cluster* vulnerável, só a formação docente diferencia os grupos: os municípios de IDEB alto têm 11,6 p.p. a mais de *docentes com ensino superior* e 11,4 p.p. a mais com *licenciatura*, com efeito médio (δ de 0,35 e 0,34). Esses testes não resistem à correção para comparações múltiplas ($q = 0{,}34$), mas a correlação de Spearman com os 88 municípios confirma a associação ($\rho = 0{,}29$ e $0{,}28$; $p \leq 0{,}009$; $q = 0{,}063$), e nenhuma outra variável se mantém após a correção ($q > 0{,}40$). Medida apenas na rede municipal, a associação fica mais forte (δ de 0,38 e 0,42; $p \leq 0{,}026$), de modo que a

inclusão de docentes de outras redes na Sinopse não explica o resultado. Como quase todos os docentes com ensino superior são licenciados, as duas variáveis devem ser lidas como um único achado.

A renda *per capita* e a pobreza extrema não diferenciam os grupos ($p = 0{,}322$ e $p = 0{,}463$), o que é compatível com o propósito da segmentação, embora a ausência de significância, com grupos de 23 e 24 municípios, não demonstre equivalência.

Fatores discriminantes no *cluster* intermediário

Dentro do *cluster* intermediário (n = 113), os 34 municípios do quartil superior de IDEB (alto, $\geq 5{,}70$, média 6,07) são comparados aos 29 do quartil inferior (baixo, $\leq 5{,}00$, média 4,81). As variáveis com $p < 0{,}10$ estão na segunda parte da tabela 1.

A formação docente reaparece com magnitude semelhante: 11,1 p.p. a mais de *docentes com ensino superior* e 10,1 p.p. a mais com *licenciatura* nos municípios de IDEB alto ($\delta = 0{,}29$). A correlação de Spearman com os 113 municípios aponta na mesma direção ($\rho = 0{,}21$ e $0{,}20$; $p \leq 0{,}036$; $q \geq 0{,}12$), e a medida restrita à rede municipal reproduz o resultado (δ de 0,38 e 0,35; $p \leq 0{,}018$). Nenhum teste é conclusivo isoladamente; o que sustenta o achado é a repetição, com a mesma direção e magnitude, em dois grupos socioeconômicos e nos dois procedimentos de comparação.

A *quadra esportiva* apresenta a diferença mais expressiva do *cluster* ($p = 0{,}004$; $q = 0{,}052$; $\delta = 0{,}42$): as escolas com quadra são mais que o dobro nos municípios de IDEB alto (12,9% contra 5,4%), e a associação se mantém com todos os municípios do *cluster* ($\rho = 0{,}23$; $q = 0{,}090$). Como a medida é municipal, o resultado não indica efeito da atividade esportiva sobre os alunos; a presença de quadras pode sinalizar um padrão mais amplo de investimento da rede em infraestrutura, leitura compatível com estudos que associam a infraestrutura ao IDEB nos anos iniciais (Alves; Soares, 2013; Vasconcelos *et al.*, 2021). A proporção de turmas de correção de fluxo nos anos finais também é maior nos municípios de IDEB alto ($p = 0{,}007$; $q = 0{,}052$), mas os valores são pequenos (menos de 1% das turmas), o efeito é pequeno ($\delta = 0{,}26$), e não é possível inferir se a oferta de correção de fluxo é causa ou consequência do desempenho. A renda *per capita* ainda difere marginalmente ($p = 0{,}081$), sinal de heterogeneidade residual de renda no maior *cluster*.

Diálogo com a literatura sobre o IDEB

A centralidade da formação docente nos dois *clusters* é compatível com a ênfase da literatura no papel do professor e com a prioridade que a política nacional atribui à licenciatura (BRASIL, 2014; Gatti *et al.*, 2019). O estudo, porém, mede titulação no agregado municipal, e não qualidade docente, e Rivkin, Hanushek e Kain (2005) e Glewwe *et al.* (2013) encontraram pouca relação entre titulação e aprendizado. Uma leitura possível é que, em redes nas quais mais de 40% dos docentes ainda não concluíram a graduação, como as do *cluster* vulnerável, a titulação diferencie os municípios mais do que em contextos em que ela já é quase universal. O resultado se enquadra na pesquisa em eficácia escolar (Brooke; Soares, 2008) e na tese de Coleman *et al.* (1966): controlado o contexto, que explica a maior parte da variação, as diferenças que restam entre redes se associam a fatores escolares de magnitude menor. O poder preditivo confirma essa leitura: o *Random Forest* não separou os grupos de alto e de baixo IDEB melhor que o acaso (AUC de 0,51 no *cluster* vulnerável e de 0,57 no intermediário), e a regressão *ridge* não previu o IDEB melhor que a média (R^2 de $-0{,}01$ no estado, $-0{,}10$ e $-0{,}07$ nos *clusters*). Os fatores identificados são, portanto, associações de magnitude modesta, e a maior parte da variação do IDEB depende de fatores que as bases administrativas não captam.

Para a mineração de dados educacionais, o trabalho responde ao uso de modelos globais, que ignoram a heterogeneidade socioeconômica, e à concentração de estudos no Sul e no Sudeste (Baker; Yacef, 2009; Romero; Ventura, 2020). Quanto ao IDEB, a correlação entre fluxo e proficiência apontada por Soares e Xavier (2013) pede cautela, pois municípios podem priorizar a aprovação em detrimento da proficiência; como o índice incorpora a aprovação, as variáveis de fluxo guardam relação parcialmente mecânica com ele, o que pede a mesma cautela na leitura do achado sobre correção de fluxo.

Implicações para as políticas educacionais

A diferença na formação docente, repetida nos dois *clusters*, torna a formação continuada e a indução à licenciatura candidatas plausíveis de política pública em todo o estado, e não apenas nos municípios mais pobres. A ampliação do Programa Nacional de Formação de Professores da Educação Básica (Parfor) pode ser considerada,

com avaliação de impacto, já que a análise não quantifica o efeito esperado. No *cluster* intermediário, a quadra esportiva indica a infraestrutura física complementar como candidata a priorização no monitoramento e na alocação orçamentária, embora a análise não permita estimar o retorno desse investimento.

CONSIDERAÇÕES FINAIS

Este trabalho segmentou os 216 municípios maranhenses com IDEB 2025 divulgado em três grupos socioeconômicos, pela renda *per capita* e pela pobreza extrema, e comparou, dentro deles, os municípios de alto e de baixo desempenho. Nos dois grupos com amostra suficiente, o vulnerável e o intermediário, a proporção de professores com ensino superior e com licenciatura está associada ao desempenho de forma consistente, com diferenças de 10 a 12 pontos percentuais e efeito médio. No grupo intermediário, destaca-se também a presença de quadra esportiva. Esses resultados atendem ao objetivo de identificar fatores escolares associados ao desempenho entre municípios de contexto socioeconômico semelhante.

O estudo tem seis limitações. A primeira é que a segmentação se restringe à renda, sem dimensões não monetárias, como a escolaridade dos adultos e as condições de saúde. A segunda é que os 15 municípios de alta renda, que reúnem a capital e os polos regionais, não têm amostra para a comparação por quartis e permanecem sem investigação. A terceira é o nível de análise: as associações valem para as redes municipais, não para escolas, professores ou alunos. A quarta é a causalidade: a análise é associativa, e municípios com gestão mais eficaz podem, ao mesmo tempo, contratar docentes mais qualificados e obter melhores resultados. A quinta é o tamanho das amostras, de 23 a 34 municípios por grupo: após a correção para comparações múltiplas, só a quadra esportiva e a correção de fluxo mantêm valor q próximo de 0,05, e a formação docente se sustenta pela consistência entre *clusters* e procedimentos, o que dá aos resultados caráter exploratório. A sexta é o baixo poder explicativo das variáveis, já que o Censo Escolar não captura processos pedagógicos, gestão, clima escolar ou engajamento familiar.

Apesar dessas limitações, a abordagem produziu evidências que podem subsidiar a alocação de recursos educacionais em diferentes perfis socioeconômicos, ao apontar a formação docente como fator recorrentemente associado ao desempenho em municípios de renda baixa e intermediária. Verificar se a ampliação da formação

docente eleva o desempenho exige estudos com desenho longitudinal ou quase experimental.

REFERÊNCIAS

ABDI, Hervé; WILLIAMS, Lynne J. Principal Component Analysis. **WIREs Computational Statistics**, v. 2, n. 4, p. 433-459, 2010. DOI: 10.1002/wics.101. Disponível em: https://doi.org/10.1002/wics.101. Acesso em: 25 maio 2026.

ALBERNAZ, Ângela; FERREIRA, Francisco H. G.; FRANCO, Creso. Qualidade e Eqüidade no Ensino Fundamental Brasileiro. **Pesquisa e Planejamento Econômico**, v. 32, n. 3, p. 453-476, 2002. Disponível em: https://ppe.ipea.gov.br/index.php/ppe/article/view/139. Acesso em: 23 maio 2026.

ALVES, Maria Teresa Gonzaga; SOARES, José Francisco. Contexto escolar e indicadores educacionais: condições desiguais para a efetivação de uma política de avaliação educacional. **Educação e Pesquisa**, v. 39, n. 1, p. 177-194, 2013. DOI: 10.1590/S1517-97022013000100012. Disponível em: https://www.scielo.br/j/ep/a/PkVXrTbnCJDktQxLZNK7dDj/. Acesso em: 28 set. 2026.

ALVES, Maria Teresa Gonzaga; SOARES, José Francisco; XAVIER, Flavia Pereira. Índice socioeconômico das escolas de educação básica brasileiras. **Ensaio: Avaliação e Políticas Públicas em Educação**, v. 22, n. 84, p. 671-704, 2014. DOI: 10.1590/S0104-40362014000300005. Disponível em: https://www.scielo.br/j/ensaio/a/5mxhCjNhcVqywzyk79QdfPj/. Acesso em: 28 set. 2026.

BAKER, Ryan S. J. D.; YACEF, Kalina. The State of Educational Data Mining in 2009: A Review and Future Visions. **Journal of Educational Data Mining**, v. 1, n. 1, p. 3-16, 2009. DOI: 10.5281/zenodo.3554658. Disponível em: https://jedm.educationaldatamining.org/index.php/JEDM/article/view/8. Acesso em: 23 maio 2026.

BEN-HUR, Asa; ELISSEEFF, André; GUYON, Isabelle. A Stability Based Method for Discovering Structure in Clustered Data. *In:* PACIFIC SYMPOSIUM ON BIOCOMPUTING, 7., 2002, Lihue. **Proceedings [...].** Singapore: World Scientific, 2002. p. 6-17. Disponível em: https://psb.stanford.edu/psb-online/proceedings/psb02/benhur.pdf. Acesso em: 29 maio 2026.

BENJAMINI, Yoav; HOCHBERG, Yosef. Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 57, n. 1, p. 289-300, 1995. DOI: 10.1111/j.2517-6161.1995.tb02031.x. Disponível em: https://doi.org/10.1111/j.2517-6161.1995.tb02031.x. Acesso em: 28 set. 2026.

BRASIL. **Lei n.º 13.005, de 25 de junho de 2014: aprova o Plano Nacional de Educação – PNE e dá outras providências**. Brasília: Diário Oficial da União, 2014. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2011-2014/2014/lei/l13005.htm. Acesso em: 28 set. 2026.

BRASIL. **Lei n.º 8.742, de 7 de dezembro de 1993: dispõe sobre a organização da Assistência Social e dá outras providências**. Brasília: Diário Oficial da União, 1993. Disponível em: https://www2.camara.leg.br/legin/fed/lei/1993/lei-8742-7-dezembro-1993-363163-publicacaooriginal-1-pl.html. Acesso em: 27 set. 2026.

BREIMAN, Leo. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001. DOI: 10.1023/A:1010933404324. Disponível em: https://link.springer.com/article/10.1023/A:1010933404324. Acesso em: 25 maio 2026.

BROOKE, Nigel; SOARES, José Francisco (org.). **Pesquisa em eficácia escolar: origem e trajetórias**. Belo Horizonte: Editora UFMG, 2008.

CLIFF, Norman. Dominance Statistics: Ordinal Analyses to Answer Ordinal Questions. **Psychological Bulletin**, v. 114, n. 3, p. 494-509, 1993. DOI: 10.1037/0033-2909.114.3.494. Disponível em: https://doi.org/10.1037/0033-2909.114.3.494. Acesso em: 28 set. 2026.

COLEMAN, James S. *et al.* **Equality of Educational Opportunity**. Washington, D.C.: U.S. Government Printing Office, 1966. Disponível em: https://archive.org/details/equalityofeducat0000cole_a0h5. Acesso em: 23 maio 2026.

COLPANI, Rogério. Mineração de Dados Educacionais: um estudo da evasão no ensino médio com base nos indicadores do Censo Escolar. **Informática na Educação: Teoria & Prática**, v. 21, n. 3, 2018. DOI: 10.22456/1982-1654.87880. Disponível em: https://seer.ufrgs.br/InfEducTeoriaPratica/article/view/87880. Acesso em: 27 maio 2026.

FERNANDES, Reynaldo. **Índice de Desenvolvimento da Educação Básica (IDEB)**. Brasília: INEP, 2007. (Série Documental. Textos para Discussão, 26). Disponível em: https://rbep.inep.gov.br/ojs3/index.php/td/article/view/3850. Acesso em: 23 maio 2026.

GATTI, Bernardete Angelina *et al.* **Professores do Brasil: novos cenários de formação**. Brasília: UNESCO, 2019. Disponível em: https://unesdoc.unesco.org/ark:/48223/pf0000367919. Acesso em: 28 set. 2026.

GIL, Antonio Carlos. **Como elaborar projetos de pesquisa**. 6. ed. São Paulo: Atlas, 2017.

GLEWWE, Paul W. *et al.* School Resources and Educational Outcomes in Developing Countries: A Review of the Literature from 1990 to 2010. *In:* GLEWWE, Paul (org.).

Education Policy in Developing Countries. Chicago: University of Chicago Press, 2013. p. 13-64. Disponível em: https://www.nber.org/papers/w17554. Acesso em: 23 maio 2026.

HANUSHEK, Eric A.; WOESSMANN, Ludger. Do Better Schools Lead to More Growth? Cognitive Skills, Economic Outcomes, and Causation. **Journal of Economic Growth**, v. 17, n. 4, p. 267-321, 2012. DOI: 10.1007/s10887-012-9081-x. Disponível em: https://link.springer.com/article/10.1007/s10887-012-9081-x. Acesso em: 23 maio 2026.

HOERL, Arthur E.; KENNARD, Robert W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. **Technometrics**, v. 12, n. 1, p. 55-67, 1970. DOI: 10.1080/00401706.1970.10488634. Disponível em: https://doi.org/10.1080/00401706.1970.10488634. Acesso em: 28 set. 2026.

IBGE. **Censo Demográfico 2022: moradores por classes de rendimento nominal mensal domiciliar per capita, por município**. Rio de Janeiro: IBGE, 2022a. Sidra, tabela 10296. Disponível em: https://sidra.ibge.gov.br/tabela/10296. Acesso em: 27 set. 2026.

IBGE. **Censo Demográfico 2022: rendimento nominal médio mensal domiciliar per capita, por município**. Rio de Janeiro: IBGE, 2022b. Sidra, tabela 10295. Disponível em: https://sidra.ibge.gov.br/tabela/10295. Acesso em: 27 set. 2026.

INEP. **Microdados do Censo Escolar da Educação Básica 2025**. Brasília: INEP, 2026a. Disponível em: https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/censo-escolar. Acesso em: 27 set. 2026.

INEP. **Nota Informativa: IDEB 2025**. Brasília, 2026b. Disponível em: https://download.inep.gov.br/ideb/resultados/nota_informativa_ideb_2025.pdf. Acesso em: 27 set. 2026.

INEP. **Sinopse Estatística da Educação Básica 2025**. Brasília: INEP, 2026c. Disponível em: https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/sinopses-estatisticas/educacao-basica. Acesso em: 27 set. 2026.

KALITA, Emi *et al.* Educational Data Mining: A 10-Year Review. **Discover Computing**, v. 28, n. 1, 2025. DOI: 10.1007/s10791-025-09589-z. Disponível em: https://doi.org/10.1007/s10791-025-09589-z. Acesso em: 27 set. 2026.

MACQUEEN, James B. Some Methods for Classification and Analysis of Multivariate Observations. *In:* BERKELEY SYMPOSIUM ON MATHEMATICAL STATISTICS AND PROBABILITY, 5., 1965, Berkeley. **Proceedings [...].** Berkeley: University of California Press, 1967. v. 1, p. 281-297. Disponível em: https://projecteuclid.org/euclid.bsmsp/1200512992. Acesso em: 25 maio 2026.

MANN, Henry B.; WHITNEY, Donald R. On a Test of Whether One of Two Random Variables Is Stochastically Larger than the Other. **The Annals of Mathematical**

Statistics, v. 18, n. 1, p. 50-60, 1947. DOI: 10.1214/aoms/1177730491. Disponível em: https://projecteuclid.org/euclid.aoms/1177730491. Acesso em: 25 maio 2026.

RIVKIN, Steven G.; HANUSHEK, Eric A.; KAIN, John F. Teachers, Schools, and Academic Achievement. **Econometrica**, v. 73, n. 2, p. 417-458, 2005. DOI: 10.1111/j.1468-0262.2005.00584.x. Disponível em: https://www.nber.org/papers/w6691. Acesso em: 23 maio 2026.

ROBINSON, William S. Ecological Correlations and the Behavior of Individuals. **American Sociological Review**, v. 15, n. 3, p. 351-357, 1950. DOI: 10.2307/2087176. Disponível em: https://doi.org/10.2307/2087176. Acesso em: 28 set. 2026.

ROMERO, Cristóbal; VENTURA, Sebastián. Educational Data Mining and Learning Analytics: An Updated Survey. **WIREs Data Mining and Knowledge Discovery**, v. 10, n. 3, 2020. DOI: 10.1002/widm.1355. Disponível em: https://doi.org/10.1002/widm.1355. Acesso em: 23 maio 2026.

ROUSSEEUW, Peter J. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53-65, 1987. DOI: 10.1016/0377-0427(87)90125-7. Disponível em: https://www.sciencedirect.com/science/article/pii/0377042787901257. Acesso em: 25 maio 2026.

SIRIN, Selcuk R. Socioeconomic Status and Academic Achievement: A Meta-Analytic Review of Research. **Review of Educational Research**, v. 75, n. 3, p. 417-453, 2005. DOI: 10.3102/00346543075003417. Disponível em: https://doi.org/10.3102/00346543075003417. Acesso em: 27 set. 2026.

SOARES, José Francisco; XAVIER, Flávia Pereira. Pressupostos educacionais e estatísticos do IDEB. **Educação & Sociedade**, v. 34, n. 124, p. 903-923, 2013. DOI: 10.1590/S0101-73302013000300013. Disponível em: https://www.scielo.br/j/es/a/JLzr4qdx89rjrNXnydNcvcy/. Acesso em: 25 maio 2026.

VARGHA, András; DELANEY, Harold D. A Critique and Improvement of the CL Common Language Effect Size Statistics of McGraw and Wong. **Journal of Educational and Behavioral Statistics**, v. 25, n. 2, p. 101-132, 2000. DOI: 10.3102/10769986025002101. Disponível em: https://doi.org/10.3102/10769986025002101. Acesso em: 28 set. 2026.

VASCONCELOS, Joyciane Coelho *et al.* Infraestrutura escolar e investimentos públicos em Educação no Brasil: a importância para o desempenho educacional. **Ensaio: Avaliação e Políticas Públicas em Educação**, v. 29, n. 113, p. 874-898, 2021. DOI: 10.1590/S0104-40362020002802245. Disponível em: https://www.scielo.br/j/ensaio/a/w9HwRXMQ3FVZ9fzJJKBgLLt/. Acesso em: 23 maio 2026.

INFORMAÇÕES COMPLEMENTARES

Disponibilidade de dados

Os dados utilizados são públicos e foram disponibilizados pelo INEP e pelo IBGE.