DEBATES EM EDUCAÇÃO
ISSN: 2175-6600

Artigo | Article

Fatores intracontextuais do desempenho no IDEB: segmentação socioeconômica e análise intragrupo nos municípios do Maranhão

Intracontextual factors of IDEB performance: socioeconomic segmentation and within-group analysis in the municipalities of Maranhão

Factores intracontextuales del desempeño en el IDEB: segmentación socioeconómica y análisis intragrupo en los municipios de Maranhão

Resumo

O desempenho educacional dos municípios maranhenses permanece entre os mais baixos do país, e a desigualdade socioeconômica dificulta comparações diretas entre redes de ensino. Este artigo tem como objetivo identificar os fatores escolares que diferenciam municípios de alto e de baixo desempenho no Índice de Desenvolvimento da Educação Básica de 2023, nos anos iniciais do ensino fundamental da rede municipal, entre municípios de contexto socioeconômico semelhante. A pesquisa, de natureza quantitativa e descritiva, integra microdados do Censo Escolar de 2023, dados do Censo Demográfico de 2010 e o Índice de Desenvolvimento Humano Municipal dos 217 municípios do Maranhão. A análise ocorre em dois estágios: primeiro, o algoritmo *K-Means* agrupa os municípios segundo a renda *per capita* e o desenvolvimento humano; depois, dentro do grupo mais vulnerável, um classificador *Random Forest* e o teste de Mann-Whitney comparam os municípios do quartil superior e do quartil inferior de desempenho. Os resultados indicam que a formação docente em nível superior e em licenciatura, a presença de bibliotecas ou salas de leitura e, em menor grau, o acesso à internet estão associados ao desempenho superior, mesmo sob condições socioeconômicas semelhantes. Conclui-se que o aprendizado de máquina aplicado a dados administrativos públicos oferece subsídios para a formulação de políticas educacionais e para a alocação de recursos nos municípios, além de constituir uma estrutura analítica replicável em outras regiões.

Palavras-chave: desempenho educacional; aprendizado de máquina; políticas educacionais.

Abstract

The educational performance of municipalities in Maranhão remains among the lowest in Brazil, and socioeconomic inequality hinders direct comparisons between school systems. This article aims to identify the school factors that distinguish high- and low-performing municipalities in the 2023 Basic Education Development Index, in the early years of elementary education in municipal schools, among municipalities with similar socioeconomic contexts. The study, quantitative and descriptive in nature, integrates

https://doi.org/10.28998/2175-6600.2025v17n39
Artigo publicado sob a Licença Creative Commons 4.0
Submetido em: dd/mm/aaaa
Aceito em: dd/mm/aaaa
Publicado: dd/mm/aaaa
e-Location: xxxxxxx

microdata from the 2023 School Census, data from the 2010 Demographic Census and the Municipal Human Development Index for the 217 municipalities of Maranhão. The analysis is carried out in two stages: first, the K-Means algorithm groups municipalities according to per capita income and human development; then, within the most vulnerable group, a Random Forest classifier and the Mann-Whitney test compare municipalities in the upper and lower performance quartiles. The results indicate that teacher education at the higher education and teaching degree levels, the presence of libraries or reading rooms and, to a lesser extent, internet access are associated with higher performance, even under similar socioeconomic conditions. It is concluded that machine learning applied to public administrative data provides support for the design of educational policies and for resource allocation in municipalities, in addition to constituting an analytical framework replicable in other regions.

Keywords: *educational performance; machine learning; educational policies.*

Resumen

El desempeño educativo de los municipios de Maranhão sigue entre los más bajos de Brasil, y la desigualdad socioeconómica dificulta las comparaciones directas entre redes de enseñanza. Este artículo tiene como objetivo identificar los factores escolares que diferencian a los municipios de alto y de bajo desempeño en el Índice de Desarrollo de la Educación Básica de 2023, en los años iniciales de la enseñanza fundamental de la red municipal, entre municipios de contexto socioeconómico similar. La investigación, de naturaleza cuantitativa y descriptiva, integra microdatos del Censo Escolar de 2023, datos del Censo Demográfico de 2010 y el Índice de Desarrollo Humano Municipal de los 217 municipios de Maranhão. El análisis se realiza en dos etapas: primero, el algoritmo K-Means agrupa los municipios según la renta per cápita y el desarrollo humano; después, dentro del grupo más vulnerable, un clasificador Random Forest y la prueba de Mann-Whitney comparan los municipios del cuartil superior y del cuartil inferior de desempeño. Los resultados indican que la formación docente de nivel superior y en licenciatura, la presencia de bibliotecas o salas de lectura y, en menor medida, el acceso a internet están asociados a un desempeño superior, incluso en condiciones socioeconómicas similares. Se concluye que el aprendizaje automático aplicado a datos administrativos públicos ofrece subsidios para la formulación de políticas educativas y para la asignación de recursos en los municipios, además de constituir un marco analítico replicable en otras regiones.

Palabras-clave: *desempeño educativo; aprendizaje automático; políticas educativas.*

INTRODUÇÃO

A qualidade da educação básica é um dos principais determinantes do desenvolvimento humano e econômico de longo prazo (Hanushek; Woessmann, 2012). No Brasil, o Índice de Desenvolvimento da Educação Básica (IDEB) monitora o ensino público combinando fluxo escolar e proficiência em língua portuguesa e matemática numa

medida comparável entre municípios, estados e redes de ensino (Fernandes, 2007). Apesar dos avanços das últimas duas décadas, as disparidades regionais persistem: estados do Norte e do Nordeste ficam sistematicamente abaixo da média nacional, reflexo de desigualdades estruturais de renda, infraestrutura e serviços públicos (INEP, 2024b).

O Maranhão está entre os casos mais críticos. Com um dos menores Índices de Desenvolvimento Humano Municipal (IDHM) do país e indicadores educacionais historicamente abaixo da média nacional, o estado concentra municípios em alta vulnerabilidade socioeconômica, onde os obstáculos para melhorar o desempenho escolar superam a capacidade de gestão local (IBGE, 2010; INEP, 2024b). Isso coloca uma pergunta direta: o que diferencia, dentro de um mesmo patamar de vulnerabilidade, os municípios que sobem no IDEB daqueles que ficam estagnados?

A literatura internacional examinou amplamente a relação entre condições socioeconômicas, infraestrutura escolar, qualificação docente e o desempenho dos estudantes (Rivkin; Hanushek; Kain, 2005; Coleman et al., 1966). No Brasil, estudos com dados do IDEB e do Censo Escolar apontaram formação dos professores, tamanho das turmas e infraestrutura como variáveis relevantes (Vasconcelos et al., 2021; Soares; Xavier, 2013). Análises voltadas especificamente para o Maranhão que isolem fatores intracontextuais (aqueles que operam mesmo quando o contexto socioeconômico é semelhante) são escassas.

Métodos de aprendizado de máquina têm sido aplicados a dados educacionais com resultados promissores, especialmente pela capacidade que têm de lidar com bases administrativas grandes e heterogêneas (Ersozlu; Taheri; Koch, 2024; Kalita et al., 2025; Romero; Ventura, 2020). Algoritmos de agrupamento identificam estruturas nos dados sem categorias predefinidas, o que os torna úteis para segmentar contextos antes de comparações (Faceli; Lorena; Carvalho, 2021; Kalita et al., 2025). Quando combinados com medidas de importância de variáveis e testes não paramétricos, essa abordagem permite identificar os fatores que mais diferenciam grupos de desempenho.

O objetivo geral deste artigo é identificar, entre municípios maranhenses de contexto socioeconômico semelhante, os fatores escolares associados ao desempenho superior no IDEB. Para isso, a análise abrange os 217 municípios maranhenses com dados disponíveis no IDEB 2023 (anos iniciais do ensino fundamental, rede municipal). No primeiro estágio, os municípios são agrupados por contexto socioeconômico via *K-Means*, usando renda *per capita* e IDHM. No segundo, dentro de cada grupo, um

Random Forest Classifier combinado com o teste de Mann-Whitney identifica quais características escolares e socioeconômicas separam municípios de alto e baixo desempenho. As variáveis analisadas vêm do Censo Escolar 2023: infraestrutura (internet, biblioteca, laboratório de informática, saneamento), qualificação docente e indicadores de fluxo escolar.

O trabalho faz três contribuições principais. Primeiro, propõe e aplica ao contexto específico do Maranhão uma abordagem em dois estágios (segmentação socioeconômica seguida de análise intragrupo). Segundo, identifica os fatores escolares associados ao desempenho superior no IDEB entre municípios vulneráveis. Terceiro, disponibiliza um *pipeline* reprodutível para análises similares em outras unidades federativas. Os resultados têm uso direto para gestores e formuladores de políticas que precisam decidir onde concentrar recursos.

O restante do artigo está organizado da seguinte forma: a próxima seção discute a mineração de dados educacionais e os determinantes do desempenho no IDEB; em seguida, os procedimentos metodológicos descrevem as fontes de dados, as variáveis e os dois estágios da análise; a seção de resultados apresenta a segmentação dos municípios, os fatores discriminantes e a discussão desses fatores à luz da literatura; por fim, as considerações finais sintetizam os achados, as limitações e as direções futuras.

MINERAÇÃO DE DADOS EDUCACIONAIS E DETERMINANTES DO DESEMPENHO NO IDEB

Compreender os fatores associados ao desempenho escolar exige articular dois campos de conhecimento: os estudos educacionais sobre os determinantes do desempenho e os métodos computacionais capazes de extrair padrões de grandes bases administrativas. Esta seção reúne essas bases teórico-conceituais, que sustentam as escolhas metodológicas e a interpretação dos resultados do estudo. Inicialmente, discute-se o uso de aprendizado de máquina na análise educacional; em seguida, o agrupamento não supervisionado como estratégia de segmentação contextual; depois, os estudos brasileiros sobre o IDEB e os condicionantes socioeconômicos desse índice, que evidenciam a escassez de pesquisas voltadas ao Maranhão; por fim, delimita-se a contribuição deste estudo em relação a essa literatura.

Aprendizado de máquina na análise educacional

A mineração de dados educacionais (*Educational Data Mining*, EDM) consolidou-se como área de pesquisa a partir da segunda metade da década de 2000, quando Baker e Yacef (2009) mapearam o estado da arte e identificaram cinco grandes paradigmas: predição, agrupamento, mineração de regras de associação, descoberta com modelos e visualização. Em revisão atualizada, Romero e Ventura (2020) estenderam esse panorama e evidenciaram a predominância de técnicas supervisionadas para tarefas de classificação, especialmente para predizer aprovação, evasão e desempenho em avaliações padronizadas.

No Brasil, a aplicação de algoritmos de aprendizado supervisionado a dados administrativos educacionais ganhou tração com a ampla disponibilização de microdados do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP). Estudos baseados no Censo Escolar e no IDEB aplicaram técnicas de mineração de dados para identificar fatores associados a desempenho e evasão (Colpani, 2018). A capacidade dessas técnicas de lidar com bases de alta dimensionalidade e distribuições assimétricas as torna adequadas a dados como os do Censo Escolar, que apresentam essas características.

Apesar dos avanços, a literatura nacional apresenta três lacunas persistentes:

a) concentração de estudos em municípios das regiões Sul e Sudeste;
b) uso de modelos globais que ignoram a heterogeneidade socioeconômica entre municípios;
c) sub-representação de estados como o Maranhão, onde as condições de vulnerabilidade tornam inadequada a comparação direta com médias nacionais.

Aprendizado não supervisionado para segmentação contextual

O agrupamento (*clustering*) via *K-Means*, proposto por MacQueen (1967), é uma das técnicas de aprendizado não supervisionado mais amplamente utilizadas para segmentação de entidades em grupos homogêneos internamente e heterogêneos entre si. O algoritmo minimiza a inércia intragrupo por meio de iterações de atribuição e recentramento, requerendo apenas a especificação prévia do número de grupos k.

A seleção de k é um desafio clássico. O Método do Cotovelo (*Elbow Method*) avalia a variação da inércia, mas pode ser ambíguo em dados reais. O *Silhouette*

Score, introduzido por Rousseeuw (1987), oferece uma métrica mais interpretável: para cada ponto, mede a razão entre a coesão do ponto em relação ao próprio grupo e a separação dele em relação ao *cluster* mais próximo, produzindo um escore entre -1 e 1 (quanto mais alto, mais bem definido o agrupamento).

Em contextos educacionais, o *K-Means* tem sido empregado para segmentar escolas por perfil socioeconômico antes de comparações de desempenho, o que evita confusões entre o efeito do contexto e a eficácia escolar. A visualização dos *clusters* via Análise de Componentes Principais (Abdi; Williams, 2010) permite inspecionar graficamente a qualidade da separação em espaço bidimensional, mesmo quando as variáveis originais têm escalas incomparáveis.

A combinação de *K-Means* para segmentação contextual com testes intragrupo para identificação de fatores discriminantes representa uma abordagem metodológica que preserva a validade interna das comparações: ao comparar municípios dentro do mesmo *cluster* socioeconômico, reduz-se o risco de atribuir a fatores escolares diferenças que são, na verdade, determinadas pela renda ou pelo nível de desenvolvimento humano.

O IDEB e os fatores socioeconômicos do desempenho escolar no Brasil

O IDEB foi concebido por Fernandes (2007) como uma medida composta que combina taxa de aprovação (fluxo) e proficiência em Língua Portuguesa e Matemática (Saeb/Prova Brasil), resultando em um indicador comparável ao longo do tempo e entre redes de ensino. Soares e Xavier (2013) examinaram os pressupostos estatísticos do índice, alertando para o risco de interpretações simplistas que ignoram a correlação entre fluxo e proficiência.

A relação entre qualificação docente e desempenho escolar é um dos achados mais robustos da literatura internacional. Rivkin, Hanushek e Kain (2005), em análise com dados do Texas, demonstraram que a qualidade do professor é o fator intraescolar com maior impacto sobre o aprendizado dos estudantes, superando infraestrutura e tamanho de turma. O efeito-escola, por sua vez, foi documentado desde o clássico relatório de Coleman et al. (1966), que identificou nos Estados Unidos que o contexto socioeconômico familiar explica a maior parte da variância no desempenho, enquanto fatores escolares têm efeito residual (embora real e acionável por políticas públicas).

Albernaz, Ferreira e Franco (2002) identificaram que qualidade e equidade no

ensino fundamental variam sistematicamente com o nível socioeconômico das escolas, evidenciando que comparações entre municípios de contextos distintos tendem a confundir efeito-escola com efeito-contexto. No Brasil, Vasconcelos et al. (2021) analisaram a relação entre infraestrutura escolar e desempenho usando dados do Censo Escolar e do Saeb, encontrando associação positiva entre presença de laboratórios, bibliotecas e conexão à internet e os resultados dos estudantes. Em revisão da literatura sobre recursos escolares em países em desenvolvimento, Glewwe et al. (2014) confirmaram que qualidade docente e infraestrutura física têm efeitos positivos, mas heterogêneos, sobre o aprendizado, com magnitude dependente do contexto local. Hanushek e Woessmann (2012) demonstraram, em perspectiva comparada entre países, que habilidades cognitivas têm efeito causal sobre crescimento econômico de longo prazo, reforçando a relevância de investigar os determinantes do desempenho escolar em estados de baixo Índice de Desenvolvimento Humano (IDH), como o Maranhão.

O que foi observado é que análises centradas especificamente no Maranhão são escassas. O estado figurou sistematicamente entre os piores índices nacionais no IDEB das séries iniciais (INEP, 2024b), com média municipal abaixo de 5,0 na última edição. A concentração de municípios em condições de alta vulnerabilidade socioeconômica torna necessária uma abordagem que controle o contexto antes de comparar desempenhos, o que a literatura geral sobre IDEB raramente faz de forma sistemática.

Contribuição deste estudo à literatura

O presente trabalho distingue-se da literatura existente por três características:

a) adota uma abordagem em dois estágios que separa explicitamente a segmentação socioeconômica da análise de fatores intracontextuais;
b) aplica essa lógica exclusivamente aos 217 municípios maranhenses com dados disponíveis no IDEB 2023, contexto sub-representado na literatura de EDM;
c) combina importâncias do *Random Forest* (Breiman, 2001) com testes de Mann-Whitney (Mann; Whitney, 1947) para obter tanto uma ordenação de variáveis quanto evidência estatística de que as diferenças observadas não são atribuíveis ao acaso.

A análise intragrupo (restrita a municípios com contexto socioeconômico seme-

lhante) responde a uma pergunta que modelos globais não conseguem: quais fatores diferem, de forma consistente e estatisticamente significativa, entre municípios que superam e que ficam abaixo do desempenho esperado dado o contexto socioeconômico em que se encontram? Essa pergunta tem implicação direta para políticas educacionais, pois identifica alvos de intervenção que operam mesmo sob restrições socioeconômicas.

PROCEDIMENTOS METODOLÓGICOS

Trata-se de uma pesquisa de abordagem quantitativa, de caráter descritivo e exploratório, baseada exclusivamente em dados secundários de acesso público. O *pipeline* analítico segue as etapas do processo CRISP-DM (*Cross-Industry Standard Process for Data Mining*) (Shearer, 2000), adaptado ao contexto de análise de dados educacionais: compreensão do domínio, coleta e preparação dos dados, modelagem e avaliação dos resultados. Dentro desse processo, a análise é conduzida em dois estágios sequenciais, descritos a seguir, após a apresentação das fontes de dados, das variáveis e do tratamento dos dados.

Fontes de dados

Este estudo integra quatro bases de dados públicas referentes aos municípios do Maranhão:

- **IDEB EFAI 2023 (INEP).** O Índice de Desenvolvimento da Educação Básica dos anos iniciais do ensino fundamental (EFAI), divulgado pelo INEP (INEP, 2024b), é calculado conforme a metodologia proposta por Fernandes (2007): combina a taxa de aprovação escolar (fluxo) com a proficiência média em Língua Portuguesa e Matemática aferida pelo Sistema de Avaliação da Educação Básica (Saeb). Para este estudo, utilizou-se a edição 2023 da rede municipal, que cobriu os 217 (todos) municípios do estado com dados disponíveis.
- **Censo Escolar 2023 (INEP).** Os microdados do Censo Escolar (INEP, 2024a) fornecem informações em nível de escola sobre infraestrutura física (internet, biblioteca/sala de leitura, laboratório de informática, quadra esportiva, abastecimento de água e esgotamento sanitário) e sobre o corpo docente. Para as variáveis de formação docente nos anos iniciais do ensino fundamental (EF),

utilizou-se a Tabela 2.23 da Sinopse Estatística da Educação Básica 2023 (INEP, 2024c), que fornece o número de docentes EFAI por nível de formação de modo consistente entre numerador e denominador, eliminando o viés de dupla contagem presente nos microdados brutos.

- **Censo Demográfico 2010 (IBGE).** A renda *per capita* municipal de 2010 foi extraída do Censo Demográfico do Instituto Brasileiro de Geografia e Estatística (IBGE) (IBGE, 2010) e utilizada como *proxy* da capacidade econômica dos municípios. Embora defasada, essa variável é o indicador de renda municipal mais desagregado disponível com cobertura universal para os 217 municípios analisados.
- **IDHM 2010 (Atlas Brasil/PNUD).** O Índice de Desenvolvimento Humano Municipal, calculado pelo Programa das Nações Unidas para o Desenvolvimento (PNUD) com base no Censo 2010 (PNUD; IPEA; FJP, 2013), captura três dimensões do desenvolvimento humano (longevidade, educação e renda) em um índice composto entre 0 e 1. Junto com a renda *per capita*, compõe o espaço de segmentação socioeconômica utilizado na clusterização.

Variáveis

As variáveis são organizadas em quatro grupos, descritos no quadro 1.

Quadro 1 – Variáveis utilizadas na análise

Variável	Fonte	Definição operacional
Segmentação socioeconômica		
Renda *per capita* 2010	IBGE 2010	Renda domiciliar *per capita* média municipal (R$)
IDHM 2010	PNUD/Atlas	Índice de Desenvolvimento Humano Municipal
Infraestrutura escolar		
% escolas com internet	Censo 2023	Proporção de escolas municipais com acesso à internet
% escolas com biblioteca/sala de leitura	Censo 2023	Proporção com biblioteca, biblioteca-sala de leitura ou sala de leitura
% escolas com laboratório de informática	Censo 2023	Proporção com laboratório de informática
% escolas com quadra esportiva	Censo 2023	Proporção com quadra de esportes
% escolas com água adequada	Censo 2023	Proporção com água potável ou rede pública
% escolas com esgoto adequado	Censo 2023	Proporção com rede pública ou fossa séptica
Qualificação docente		
% docentes EFAI com ensino superior	Sinopse 2023	Proporção de docentes dos anos iniciais com graduação
% docentes EFAI com licenciatura	Sinopse 2023	Proporção de docentes dos anos iniciais com licenciatura
Fluxo e distorção		
Média de alunos/turma (EF)	Censo 2023	Total de matrículas no EF dividido pelo total de turmas do EF
Proxy distorção idade-série	Censo 2023	% matrículas com 15 anos ou mais na educação básica municipal

Fonte: elaboração própria (2026).

Coleta e pré-processamento dos dados

O *pipeline* de ingestão (`ingest.py`) automatiza a carga das quatro fontes descritas anteriormente. Para o IDEB, lê a planilha oficial do INEP e filtra os municípios maranhenses da rede municipal, tratando os códigos de não divulgação (ND, ND*, (*), (**)) como valores ausentes. Para o Censo Escolar, carrega os microdados em formato CSV (*Comma-Separated Values*, *encoding* latin-1, separador ponto-e-vírgula) e seleciona as colunas de infraestrutura, docentes e matrículas, filtrando as escolas de dependência municipal no Maranhão (TP_DEPENDENCIA = 3). Para os docentes dos anos iniciais, usa exclusivamente a Tabela 2.23 da Sinopse Estatística 2023 (planilha

no formato ODS, *OpenDocument Spreadsheet*), garantindo que numerador (docentes com superior) e denominador (total de docentes EFAI) venham da mesma fonte. Os dados do IBGE e do IDHM são lidos de planilhas Excel curadas previamente.

As variáveis de infraestrutura são agregadas ao nível municipal como proporção de escolas com cada atributo presente. As variáveis de docentes, como percentual sobre o total de docentes EFAI do município. As variáveis de fluxo, como médias ou proporções sobre o total de matrículas e turmas municipais.

O *pipeline* de transformação (`transform.py`) aplica as seguintes operações:

- **IDEB:** substituição de valores especiais por `NaN`, conversão de vírgula para ponto decimal, remoção de colunas redundantes (notas separadas de língua portuguesa e matemática, já incorporadas na nota média).
- **Censo Escolar:** remoção de colunas completamente vazias, conversão de colunas de quantidade para inteiro, normalização do código municipal para 7 dígitos.
- **IBGE:** remoção de linhas de totalização regional, normalização de nome de colunas.
- **IDHM:** remoção de linhas de totalização, renomeação de colunas para padrão interno.
- **Integração:** junção das quatro bases pela chave `NO_MUNICIPIO` (normalizada), com junção à esquerda a partir do IDEB. Resultado: 217 municípios com dados completos de IDEB, Censo Escolar, IBGE e IDHM.

Após a integração, não há valores ausentes nas variáveis de *cluster* nem nas variáveis-alvo (IDEB), mas algumas variáveis explicativas apresentam valores ausentes pontuais decorrentes de municípios sem turmas de correção de fluxo (alunos com atraso em relação à idade esperada para a série).

Estágio 1: segmentação socioeconômica por *K-Means*

O *K-Means* (MacQueen, 1967) agrupa os 217 municípios com base em renda *per capita* e IDHM. Antes da clusterização, as duas variáveis são normalizadas via `RobustScaler`, que centraliza na mediana e escala pelo intervalo interquartil, reduzindo a influência de municípios atípicos, isto é, com renda *per capita* e IDHM muito acima dos demais municípios do estado, como São Luís e Imperatriz, que, por esses valores extremos, poderiam distorcer a formação dos grupos.

O número de *clusters* k é selecionado pela inspeção conjunta do Método do Cotovelo, que avalia a inércia total em função de k, e do *Silhouette Score* médio (Rousseeuw, 1987), que mede a separação relativa dos grupos. O algoritmo é executado com $k \in \{2, \dots, 10\}$, inicialização `k-means++` e `n_init = 10`. A estabilidade dos *clusters* é avaliada por *bootstrap* de 25 iterações com 80% dos dados, seguindo a configuração de referência de Ben-Hur, Elisseeff e Guyon (2002), usando o *Adjusted Rand Index* (ARI) como métrica de concordância.

A visualização dos *clusters* é feita via Análise de Componentes Principais (PCA) (Abdi; Williams, 2010) com duas componentes, permitindo inspeção gráfica da separação em espaço reduzido.

Estágio 2: análise intragrupo

Dentro de cada *cluster* com amostra suficiente, os municípios são divididos em dois grupos por desempenho: *alto IDEB*, formado pelo quartil superior ($\geq Q_{75}$), e *baixo IDEB*, formado pelo quartil inferior ($\leq Q_{25}$). Os municípios do intervalo central são excluídos da análise comparativa, o que aumenta o contraste entre os grupos e reduz o ruído.

Para identificar quais variáveis diferenciam os dois grupos, aplica-se um *Random Forest Classifier* (Breiman, 2001) com 500 árvores, `class_weight='balanced'` e `min_samples_leaf=3`. A importância de cada variável é calculada pelo critério de redução média de impureza (*Mean Decrease in Impurity*), que quantifica a contribuição de cada variável para separar os dois grupos ao longo das 500 árvores. Em paralelo, o teste de Mann-Whitney (Mann; Whitney, 1947) bicaudal verifica se as distribuições das variáveis diferem significativamente entre os grupos alto e baixo IDEB. São utilizados três limiares de significância: $\alpha = 0{,}01$ (***), $\alpha = 0{,}05$ (**) e $\alpha = 0{,}10$ (*).

A combinação de importâncias do *Random Forest* com os p-valores do Mann-Whitney permite distinguir variáveis com alta relevância preditiva daquelas com diferença estatisticamente sustentada: uma variável é considerada fator discriminante relevante quando apresenta alta importância *e* diferença significativa ao nível de $\alpha = 0{,}10$.

Uso de ferramentas de inteligência artificial generativa

Este trabalho utilizou ferramentas de inteligência artificial generativa em três etapas do processo de pesquisa:

- **Revisão de código.** A primeira etapa do trabalho corresponde às fases de ciência de dados com Python. A ferramenta Claude (Anthropic) foi utilizada para correção e revisão dos *scripts* Python do *pipeline* de análise (`ingest.py`, `transform.py` e os módulos de modelagem), com validação e aprovação da autoria em cada alteração sugerida.
- **Revisão e edição de texto.** Na fase de produção escrita deste artigo, o Claude (Anthropic) e o ChatGPT (OpenAI) foram utilizados para revisar a redação e a clareza das seções. O texto original, a estrutura argumentativa e as interpretações dos resultados são de responsabilidade exclusiva da autoria.
- **Busca e validação de referências bibliográficas.** Claude (Anthropic) e SciSpace AI Research (PubGenius Inc.) foram utilizados para identificar trabalhos potencialmente relevantes e verificar metadados de citações. Cada referência foi conferida nas fontes originais antes da inclusão.

O uso dessas ferramentas está declarado em conformidade com as diretrizes de integridade científica do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), que exigem a identificação explícita das ferramentas de inteligência artificial generativa utilizadas, as finalidades de cada uma e a responsabilização integral do pesquisador pelos resultados produzidos.

RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados obtidos com a aplicação dos dois estágios descritos nos procedimentos metodológicos e os discute à luz da literatura. Inicialmente, caracterizam-se o contexto socioeconômico e educacional do Maranhão e a distribuição do IDEB entre os municípios, o que evidencia a variabilidade de desempenho que motiva a investigação. Em seguida, apresentam-se a segmentação socioeconômica obtida com o *K-Means* e, dentro do grupo de municípios vulneráveis, os fatores que diferenciam os municípios de alto e de baixo desempenho. Por fim, esses achados são confrontados com os estudos sobre o IDEB e traduzidos em implicações para as políticas educacionais.

Contexto socioeconômico e educacional do Maranhão

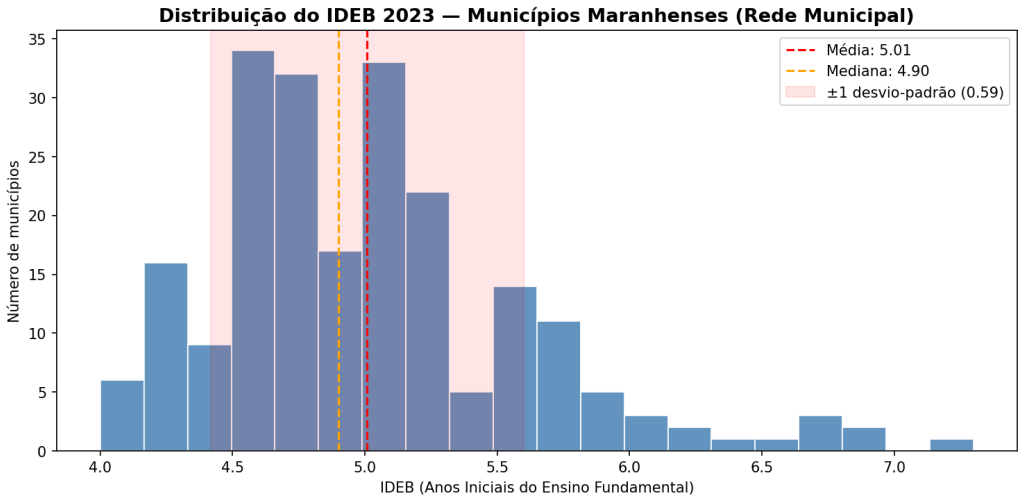
O Maranhão é o segundo maior estado do Nordeste em extensão territorial e um dos mais populosos, com 217 municípios distribuídos em cinco mesorregiões. Em indicadores socioeconômicos, ocupa posições críticas: IDHM médio de 0,639 em 2010 (um dos mais baixos do país) e renda *per capita* municipal mediana em torno de R$ 200 no mesmo período (IBGE, 2010). Esse contexto reflete-se diretamente nos resultados educacionais: na edição 2023 do IDEB, a média dos municípios maranhenses nos anos iniciais da rede municipal ficou em 5,01, com metade dos municípios abaixo de 4,90, valores que evidenciam tanto o atraso histórico quanto a dispersão expressiva do desempenho entre municípios.

A questão central desta investigação é identificar, entre municípios com contexto socioeconômico semelhante, quais fatores escolares estão associados ao desempenho superior no IDEB. Respondê-la exige, primeiro, neutralizar o efeito do contexto por meio de uma segmentação explícita e, depois, comparar, dentro de cada grupo, os municípios de alto e baixo desempenho.

Distribuição do IDEB entre os municípios

A distribuição do IDEB dos 217 municípios maranhenses é apresentada no gráfico 1. A distribuição é aproximadamente unimodal, ligeiramente assimétrica à direita, com média de 5,01 (desvio-padrão de 0,59), mediana de 4,90, mínimo de 4,00 e máximo de 7,30.

Gráfico 1 – Distribuição do IDEB 2023 dos municípios maranhenses – rede municipal, anos iniciais do ensino fundamental



Nota: linha vermelha tracejada: média (5,01); linha laranja tracejada: mediana (4,90); faixa vermelha: intervalo de ± 1 desvio-padrão.

Fonte: elaboração própria com base em INEP (2024b).

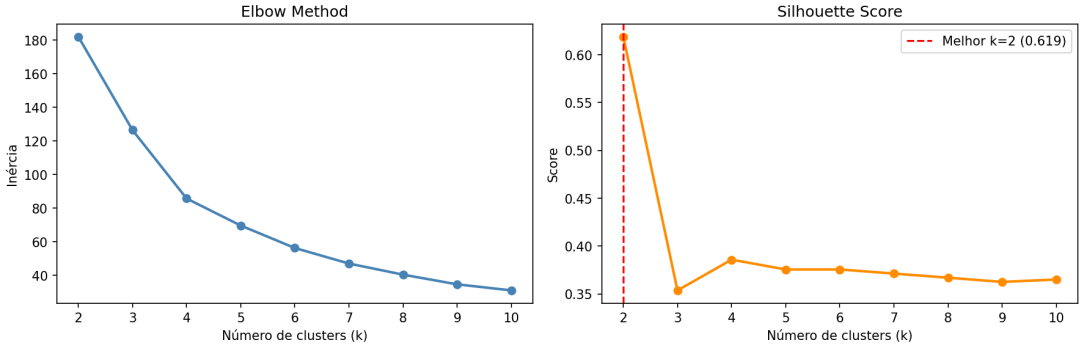
A amplitude de 3,30 pontos (4,00 a 7,30) é expressiva dado que o IDEB varia de 0 a 10. Isso indica que, mesmo dentro do Maranhão (estado homogeneamente vulnerável em termos nacionais), existe variabilidade interna substancial que justifica investigar os fatores associados aos destaques positivos.

Segmentação socioeconômica dos municípios

A clusterização *K-Means* foi aplicada sobre as variáveis *renda per capita* e *IDHM* (normalizadas via RobustScaler), testando $k \in \{2, \ldots, 10\}$, conforme descrito nos procedimentos metodológicos.

No gráfico 2, são apresentadas as curvas de inércia (cotovelo) e de *Silhouette Score* para $k \in \{2, \ldots, 10\}$. O *Silhouette Score* atinge o valor máximo em $k = 2$ (0,619), indicando dois grupos bem separados na relação *renda/IDHM*. O Método do Cotovelo confirma a escolha: a queda marginal de inércia entre $k = 2$ e $k = 3$ é consideravelmente menor que entre $k = 1$ e $k = 2$. A estabilidade *bootstrap* (ARI médio = 0,89 em 25 iterações) confirma que a partição é robusta.

Gráfico 2 – Curvas de inércia e de *Silhouette Score* para $k \in \{2, \ldots, 10\}$

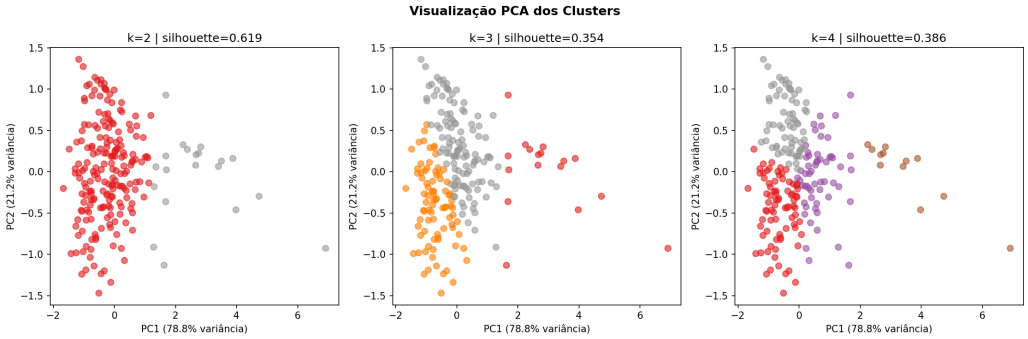


Nota: à esquerda, inércia; à direita, *Silhouette Score*. A linha vertical vermelha indica o k ótimo segundo o *Silhouette Score*.

Fonte: dados da pesquisa (2026).

No gráfico 3, são exibidos os *clusters* projetados nas duas primeiras componentes principais (a primeira componente, PC1, explica 88,4% da variância; a segunda, PC2, explica 11,6%). A separação visual entre os dois grupos é clara, confirmando a coerência da partição; entre as alternativas testadas ($k \in \{2, 3, 4\}$), a separação em dois grupos é a mais nítida.

Gráfico 3 – Projeção dos *clusters* de municípios maranhenses nas duas primeiras componentes principais para $k \in \{2, 3, 4\}$



Fonte: dados da pesquisa (2026).

Os dois *clusters* obtidos são denominados pelo critério de renda média:

- ***Cluster* vulnerável** (n = 197): renda *per capita* média de R$ 210, IDHM médio de 0,737, IDEB médio de 4,96.
- ***Cluster* maior renda** (n = 20): renda *per capita* média de R$ 447, IDHM médio de 0,780, IDEB médio de 5,45. Inclui municípios como Açailândia, Balsas, Bacabal e Alto Parnaíba.

O *cluster* de maior renda conta com apenas 20 municípios, número insuficiente para a análise intragrupo por quantis (que requereria ao menos 20 observações em cada subgrupo extremo). A análise comparativa detalhada é portanto conduzida exclusivamente no *cluster* vulnerável.

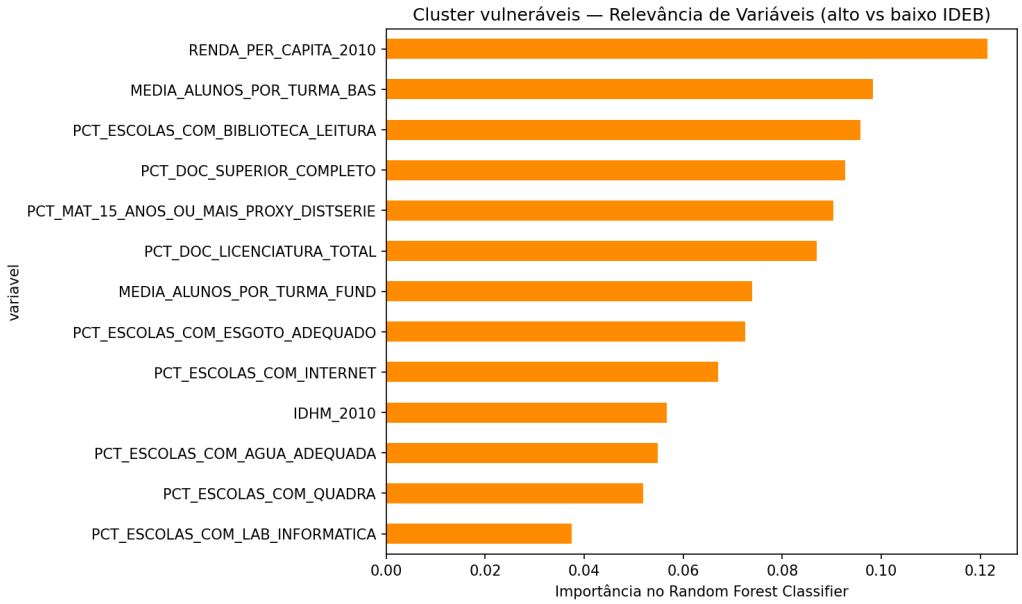
Os percentuais médios das variáveis de infraestrutura revelam disparidades: a *conectividade à internet* está presente em 73,7% das escolas municipais do *cluster* vulnerável e em 81,9% das escolas do *cluster* de maior renda; já o acesso a *biblioteca ou sala de leitura* é notavelmente baixo em ambos os grupos (12,5% nas escolas vulneráveis), sugerindo que esse recurso pode ser um diferencial relevante justamente por ser raro. A proporção média de *docentes EFAI com ensino superior* é de 60,5% nos municípios mais vulneráveis e de 73,9% naqueles de maior renda, diferença que antecipa uma das hipóteses testadas no estágio intragrupo.

Fatores discriminantes no *cluster* vulnerável

Dentro do *cluster* vulnerável (n = 197), os 57 municípios que se encontram no quartil superior de IDEB (alto, $\geq 5{,}20$, média 5,65) são comparados aos 50 do quartil inferior (baixo, $\leq 4{,}50$, média 4,35). A diferença média de 1,30 ponto de IDEB entre os grupos é substancial: equivale a mais de dois desvios-padrão da distribuição estadual.

No gráfico 4, apresentam-se as importâncias do *Random Forest Classifier* para o *cluster* vulnerável. As oito variáveis de maior importância são, em ordem decrescente: *renda per capita* (0,121), *média de alunos por turma no EF básico* (0,098), *% escolas com biblioteca/sala de leitura* (0,096), *% docentes com ensino superior* (0,093), *proxy de distorção idade-série* (0,090), *% docentes com licenciatura* (0,087), *média de alunos por turma no EF anos finais* (0,074) e *% escolas com esgoto adequado* (0,073).

Gráfico 4 – Importância das variáveis no *Random Forest Classifier* para diferenciar municípios de alto e baixo IDEB no *cluster* vulnerável



Fonte: dados da pesquisa (2026).

O teste de Mann-Whitney complementa a análise ao indicar quais variáveis apresentam diferenças estatisticamente significativas entre os grupos. Na tabela 1, resumem-se os resultados para as variáveis com $p < 0{,}10$; as diferenças entre proporções são expressas em pontos percentuais (p.p.).

Tabela 1 – Variáveis com diferença significativa entre municípios de alto e baixo IDEB no *cluster* vulnerável (Mann-Whitney bicaudal)

Variável	Média alto	Média baixo	Δ	p-valor
% doc. com licenciatura	68,0%	59,4%	+8,6 p.p.	0,023**
% doc. com ensino superior	66,8%	58,5%	+8,3 p.p.	0,026**
% escolas com biblioteca	13,8%	10,5%	+3,3 p.p.	0,030**
% escolas com internet	77,1%	69,5%	+7,6 p.p.	0,062*
Alunos/turma EF (média)	22,9	21,9	+1,0	0,066*

Nota: ** $p < 0{,}05$; * $p < 0{,}10$.

Fonte: dados da pesquisa (2026).

A formação docente emerge como o fator intracontextual mais consistentemente associado ao desempenho superior: municípios vulneráveis de alto IDEB têm, em média, 8,5 p.p. a mais de *docentes com ensino superior* e 8,6 p.p. a mais com *licenciatura* em comparação aos de baixo IDEB. Esse achado é convergente com a literatura internacional. Rivkin, Hanushek e Kain (2005) demonstraram que a qualidade do professor

é o fator intraescolar de maior impacto sobre o aprendizado. Estudos nacionais também apontam formação docente como variável central nos resultados do IDEB (Vasconcelos et al., 2021).

O acesso a *biblioteca ou sala de leitura*, ainda que presente em apenas 10–14% das escolas, também aparece como fator discriminante ($p = 0{,}030$). A baixa presença desses espaços torna essa variável um alvo direto de intervenção: pequenas expansões na proporção de escolas com espaços de leitura estruturados podem fazer diferença mensurável no IDEB municipal.

A *conectividade à internet* ($p = 0{,}062$) e o *tamanho médio de turma* ($p = 0{,}066$) são significativos ao nível de 10%, sinalizando tendências relevantes para políticas, embora com menor robustez estatística dada a variabilidade intragrupo.

A *renda per capita* aparece com a maior importância no *Random Forest* (0,121) mesmo dentro do *cluster* vulnerável, onde a variação de renda é estruturalmente menor. Isso sugere que, mesmo após a segmentação socioeconômica, a heterogeneidade residual de renda dentro do grupo tem poder preditivo, o que reforça a importância de controles socioeconômicos em análises educacionais, mesmo dentro de grupos nominalmente homogêneos.

Diálogo com a literatura sobre o IDEB

Os achados dialogam com a literatura de maneiras específicas. A centralidade da qualificação docente confirma o achado seminal de Rivkin, Hanushek e Kain (2005) no contexto norte-americano e é convergente com estudos brasileiros que identificaram formação superior como fator associado ao IDEB (Vasconcelos et al., 2021). A relevância da infraestrutura de leitura reforça a tese de Coleman et al. (1966) de que recursos escolares têm efeito real, embora secundário ao contexto familiar, o que, no caso de municípios igualmente vulneráveis, pode ganhar destaque justamente porque o efeito do contexto é controlado.

Em relação à literatura de mineração de dados educacionais, o trabalho contribui com uma aplicação metodológica que supera duas limitações frequentes: o uso de modelos globais que ignoram a heterogeneidade socioeconômica entre municípios e a concentração de estudos EDM nas regiões Sul e Sudeste (Baker; Yacef, 2009; Romero; Ventura, 2020). A abordagem em dois estágios é replicável para outros estados e pode ser adaptada a outros níveis de ensino (anos finais do ensino fundamental,

ensino médio) ou outras medidas de desempenho.

Quanto ao IDEB como métrica, os pressupostos estatísticos identificados por Soares e Xavier (2013) (especialmente a correlação entre fluxo e proficiência) não invalidam a análise, mas sugerem cautela na interpretação: municípios com IDEB elevado podem estar priorizando aprovação em detrimento da proficiência. A combinação de variáveis de fluxo (*distorção idade-série*, *correção de fluxo*) com os indicadores estruturais na mesma análise ajuda a mitigar parcialmente esse risco.

Implicações para as políticas educacionais

Os resultados têm implicações diretas para gestores municipais e formuladores de políticas educacionais do Maranhão. Três direções de ação emergem dos achados:

- **Formação e habilitação docente.** A diferença de 8,5 p.p. na proporção de *docentes com ensino superior* entre municípios de alto e baixo IDEB, dentro do mesmo contexto socioeconômico, indica que programas de formação continuada e de indução à licenciatura específica têm potencial de impacto real sobre o IDEB. Políticas estaduais e federais de financiamento de graduação a distância para docentes em exercício (como o Programa Nacional de Formação de Professores da Educação Básica — Parfor) são alvos naturais de expansão nos municípios do *cluster* vulnerável.
- **Espaços de leitura nas escolas.** A escassez de *bibliotecas e salas de leitura* (presentes em apenas 10–14% das escolas) e a associação significativa desses espaços com o desempenho superior sugerem que investimentos relativamente modestos em acervo e espaço físico podem ser custo-efetivos. Municípios com IDEB baixo dentro do *cluster* vulnerável têm, em média, 3,3 p.p. menos escolas com esse recurso.
- **Conectividade digital.** A diferença de 7,6 p.p. na proporção de *escolas com internet* aponta para o efeito mediado da conectividade sobre o IDEB: embora o impacto seja apenas marginalmente significativo ($p = 0{,}062$), a convergência com a importância no *Random Forest* justifica o monitoramento desse indicador como parte de estratégias de melhoria educacional.

CONSIDERAÇÕES FINAIS

Este trabalho propôs e aplicou uma abordagem em dois estágios (segmentação socioeconômica por *K-Means* seguida de análise intragrupo com *Random Forest Classifier* e teste de Mann-Whitney) aos 217 municípios maranhenses com dados no IDEB 2023 (anos iniciais do ensino fundamental, rede municipal). Os resultados identificaram *formação docente*, *acesso a bibliotecas* e *conectividade à internet* como os fatores intracontextuais mais consistentemente associados ao desempenho superior dentro do grupo de municípios vulneráveis, o que atende ao objetivo de isolar fatores escolares que operam mesmo sob contexto socioeconômico semelhante.

Este estudo apresenta quatro limitações relevantes que devem ser consideradas na interpretação dos resultados.

- **Defasagem dos dados socioeconômicos.** A *renda per capita* e o IDHM utilizados são provenientes do Censo Demográfico de 2010, com 14 anos de defasagem em relação ao IDEB 2023. Mudanças na estrutura econômica e social dos municípios nesse período (como a expansão de programas de transferência de renda e variações na atividade econômica regional) podem não estar refletidas na segmentação. A atualização com os dados do Censo Demográfico 2022 e do IDHM correspondente, quando disponíveis, é a principal direção de melhoria metodológica.
- **Tamanho do *cluster* de maior renda.** O *cluster* composto por 20 municípios de maior renda não atingiu o número mínimo de amostras para a análise intragrupo por quartis, impedindo a identificação de fatores discriminantes nesse grupo. Uma possível solução é adotar um limiar de corte mais amplo (por exemplo, tercis em vez de quartis) ou combinar esse *cluster* com dados de outros estados nordestinos para ampliar a amostra.
- **Causalidade.** A análise é descritiva e associativa, não causal. Não é possível afirmar que *formação docente* ou *infraestrutura escolar* causam IDEB mais alto. Municípios com gestão mais eficaz tendem a contratar mais docentes qualificados e a obter melhores resultados ao mesmo tempo, tornando difícil separar o efeito de cada variável do efeito da qualidade de gestão municipal. Estudos de painel com variação longitudinal do IDEB (2019–2023) permitiriam estimativas mais robustas do efeito causal.
- **Variáveis de gestão escolar ausentes.** O Censo Escolar não captura variá-

veis de processos pedagógicos, gestão, clima escolar ou engajamento familiar, que são mediadores importantes do desempenho. A inclusão de dados de avaliações de escola (como avaliações próprias do estado) em pesquisas futuras poderia complementar o diagnóstico aqui apresentado.

Apesar dessas limitações, a abordagem em dois estágios mostrou-se útil para orientar a alocação de recursos educacionais em contextos de vulnerabilidade, ao apontar fatores escolares passíveis de intervenção mesmo sob restrições socioeconômicas semelhantes.

REFERÊNCIAS

ABDI, Hervé; WILLIAMS, Lynne J. Principal Component Analysis. **WIREs Computational Statistics**, v. 2, n. 4, p. 433–459, 2010. DOI: 10.1002/wics.101. Disponível em: <https://doi.org/10.1002/wics.101>. Acesso em: 25 mai. 2026.

ALBERNAZ, Ângela; FERREIRA, Francisco H. G.; FRANCO, Creso. Qualidade e Eqüidade no Ensino Fundamental Brasileiro. **Pesquisa e Planejamento Econômico**, v. 32, n. 3, p. 453–476, 2002. Disponível em: <https://ppe.ipea.gov.br/index.php/ppe/article/view/139>. Acesso em: 23 mai. 2026.

BAKER, Ryan S. J. D.; YACEF, Kalina. The State of Educational Data Mining in 2009: A Review and Future Visions. **Journal of Educational Data Mining**, v. 1, n. 1, p. 3–16, 2009. DOI: 10.5281/zenodo.3554658. Disponível em: <https://jedm.educationaldatamining.org/index.php/JEDM/article/view/8>. Acesso em: 23 mai. 2026.

BEN-HUR, Asa; ELISSEEFF, André; GUYON, Isabelle. A Stability Based Method for Discovering Structure in Clustered Data. In: PACIFIC Symposium on Biocomputing. [S.l.: s.n.], 2002. v. 7, p. 6–17. Disponível em: <https://psb.stanford.edu/psb-online/proceedings/psb02/benhur.pdf>. Acesso em: 29 mai. 2026.

BREIMAN, Leo. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: 10.1023/A:1010933404324. Disponível em: <https://link.springer.com/article/10.1023/A:1010933404324>. Acesso em: 25 mai. 2026.

COLEMAN, James S. et al. **Equality of Educational Opportunity**. Washington, D.C.: U.S. Government Printing Office, 1966. Disponível em: <https://archive.org/details/equalityofeducat0000cole_a0h5>. Acesso em: 23 mai. 2026.

COLPANI, Rogério. Mineração de Dados Educacionais: um estudo da evasão no ensino médio com base nos indicadores do Censo Escolar. **Informática na Educação: Teoria & Prática**, v. 21, n. 3, 2018. DOI: 10.22456/1982-1654.87880. Disponível em: <https://seer.ufrgs.br/InfEducTeoriaPratica/article/view/87880>. Acesso em: 27 mai. 2026.

ERSOZLU, Zara; TAHERI, Sona; KOCH, Inge. A Review of Machine Learning Methods Used for Educational Data. **Education and Information Technologies**, v. 29, n. 16, p. 22125–22145, 2024. DOI: 10.1007/s10639-024-12704-0. Disponível em: <https://doi.org/10.1007/s10639-024-12704-0>. Acesso em: 27 set. 2026.

FACELI, Katti; LORENA, Ana Carolina; CARVALHO, André Carlos Paulo de Leon Ferreira de. **Inteligência Artificial: uma abordagem de aprendizado de máquina**. 2. ed. Rio de Janeiro: LTC, 2021. 424 p. ISBN 9788521637349.

FERNANDES, Reynaldo. **Índice de Desenvolvimento da Educação Básica (IDEB)**. Brasília, 2007. Disponível em: <https://rbep.inep.gov.br/ojs3/index.php/td/article/view/3850>. Acesso em: 23 mai. 2026.

GLEWWE, Paul W. et al. School Resources and Educational Outcomes in Developing Countries: A Review of the Literature from 1990 to 2010. In: GLEWWE, Paul (Ed.). **Education Policy in Developing Countries**. Chicago: University of Chicago Press, 2014. P. 13–64. Disponível em: <https://www.nber.org/papers/w17554>. Acesso em: 23 mai. 2026.

HANUSHEK, Eric A.; WOESSMANN, Ludger. Do Better Schools Lead to More Growth? Cognitive Skills, Economic Outcomes, and Causation. **Journal of Economic Growth**, v. 17, n. 4, p. 267–321, 2012. DOI: 10.1007/s10887-012-9081-x. Disponível em: <https://link.springer.com/article/10.1007/s10887-012-9081-x>. Acesso em: 23 mai. 2026.

IBGE. **Censo Demográfico 2010**. Rio de Janeiro: IBGE, 2010. Disponível em: <https://www.ibge.gov.br/estatisticas/sociais/saude/9662-censo-demografico-2010.html>. Acesso em: 23 mai. 2026.

INEP. **Microdados do Censo Escolar da Educação Básica 2023**. Brasília: INEP, 2024a. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/censo-escolar>. Acesso em: 26 set. 2026.

_____. **Nota Informativa: IDEB 2023**. Brasília, 2024b. Disponível em: <https://download.inep.gov.br/ideb/nota_informativa_ideb_2023.pdf>. Acesso em: 23 mai. 2026.

_____. **Sinopse Estatística da Educação Básica 2023**. Brasília: INEP, 2024c. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/sinopses-estatisticas/educacao-basica>. Acesso em: 26 set. 2026.

KALITA, Emi et al. Educational Data Mining: A 10-Year Review. **Discover Computing**, v. 28, n. 1, 2025. DOI: 10.1007/s10791-025-09589-z. Disponível em: <https://doi.org/10.1007/s10791-025-09589-z>. Acesso em: 27 set. 2026.

MACQUEEN, James B. Some Methods for Classification and Analysis of Multivariate Observations. In: PROCEEDINGS of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. Berkeley, CA: University of California Press, 1967. v. 1, p. 281–297. Disponível em: <https://projecteuclid.org/euclid.bsmsp/1200512992>. Acesso em: 25 mai. 2026.

MANN, Henry B.; WHITNEY, Donald R. On a Test of Whether One of Two Random Variables Is Stochastically Larger than the Other. **The Annals of Mathematical Statistics**, v. 18, n. 1, p. 50–60, 1947. DOI: 10.1214/aoms/1177730491. Disponível em: <https://projecteuclid.org/euclid.aoms/1177730491>. Acesso em: 25 mai. 2026.

PNUD; IPEA; FJP. **Atlas do Desenvolvimento Humano no Brasil**. Brasília: PNUD; IPEA; FJP, 2013. Disponível em: <http://www.atlasbrasil.org.br>. Acesso em: 26 set. 2026.

RIVKIN, Steven G.; HANUSHEK, Eric A.; KAIN, John F. Teachers, Schools, and Academic Achievement. **Econometrica**, v. 73, n. 2, p. 417–458, 2005. DOI: 10.1111/j.1468-0262.2005.00584.x. Disponível em: <https://www.nber.org/papers/w6691>. Acesso em: 23 mai. 2026.

ROMERO, Cristóbal; VENTURA, Sebastián. Educational Data Mining and Learning Analytics: An Updated Survey. **WIREs Data Mining and Knowledge Discovery**, v. 10, n. 3, e1355, 2020. DOI: 10.1002/widm.1355. Disponível em: <https://doi.org/10.1002/widm.1355>. Acesso em: 23 mai. 2026.

ROUSSEEUW, Peter J. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987. DOI: 10.1016/0377-0427(87)90125-7. Disponível em: <https://www.sciencedirect.com/science/article/pii/0377042787901257>. Acesso em: 25 mai. 2026.

SHEARER, Colin. The CRISP-DM Model: The New Blueprint for Data Mining. **Journal of Data Warehousing**, v. 5, n. 4, p. 13–22, 2000. Disponível em: <https://mineracaodedados.wordpress.com/wp-content/uploads/2012/04/the-crisp-dm-model-the-new-blueprint-for-data-mining-shearer-colin.pdf>. Acesso em: 29 mai. 2026.

SOARES, José Francisco; XAVIER, Flávia Pereira. Pressupostos educacionais e estatísticos do IDEB. **Educação & Sociedade**, v. 34, n. 124, p. 903–923, 2013. DOI: 10.1590/S0101-73302013000300013. Disponível em: <https://www.scielo.br/j/es/a/JLzr4qdx89rjrNXnydNcvcy/>. Acesso em: 25 mai. 2026.

VASCONCELOS, Joyciane Coelho et al. Infraestrutura escolar e investimentos públicos em Educação no Brasil: a importância para o desempenho educacional. **Ensaio: Avaliação e Políticas Públicas em Educação**, v. 29, n. 113, p. 874–898, 2021. DOI: 10.1590/S0104-40362020002802245. Disponível em: <https://www.scielo.br/j/ensaio/a/w9HwRXMQ3FVZ9fzJJKBgLLt/>. Acesso em: 23 mai. 2026.

INFORMAÇÕES COMPLEMENTARES

Disponibilidade de dados

Os dados utilizados neste trabalho são de acesso público e foram disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), vinculado ao Ministério da Educação, pelo Instituto Brasileiro de Geografia

e Estatística (IBGE) e pelo Programa das Nações Unidas para o Desenvolvimento (PNUD). Os resultados e interpretações são de responsabilidade exclusiva da autoria e não representam posição oficial dessas instituições.